



Universidade Federal de Sergipe
Centro de Ciências Exatas e Tecnologia
Programa de Pós-Graduação em Ciência da Computação

Democratizando o Acesso à Informação Legislativa: Inteligência Artificial Generativa para Análise de Dados Parlamentares

Proposta de Dissertação

Ana Beatriz Carvalho Oliveira



São Cristóvão – Sergipe

2026

Universidade Federal de Sergipe
Centro de Ciências Exatas e Tecnologia
Programa de Pós-Graduação em Ciência da Computação

Ana Beatriz Carvalho Oliveira

**Democratizando o Acesso à Informação Legislativa:
Inteligência Artificial Generativa para Análise de Dados
Parlamentares**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Sergipe como requisito parcial para a obtenção do título de mestre em Ciência da Computação.

Orientador(a): Prof. Dr. Gilton José Ferreira da Silva

São Cristóvão – Sergipe

2026

Resumo

A crescente produção de dados brutos pelo Senado Federal impõe desafios à sua organização, consulta e interpretação, limitando a efetividade da transparência pública. Este trabalho insere-se nesse contexto, adotando a metodologia *Design Science Research* (DSR) para investigar a aplicação de Inteligência Artificial Generativa na análise de dados parlamentares abertos. O objetivo é projetar, desenvolver e avaliar tecnicamente um artefato computacional capaz de estruturar dados legislativos, classificar discursos e apoiar consultas em linguagem natural. A solução proposta, denominada AgentAI, consiste em uma aplicação *web* interativa que automatiza a extração de dados da API do Senado e utiliza o modelo Mistral 7B Instruct executado localmente para classificação temática e geração de respostas ancoradas nos dados recuperados. A avaliação será conduzida sem coleta de dados com participantes humanos, por meio de cenários representativos de consulta, comparação com gabaritos de referência, verificação de rastreabilidade e análise factual das respostas. A pesquisa busca investigar em que medida a combinação entre dados abertos, IA Generativa local e interfaces visual/conversacional pode reduzir barreiras técnicas de acesso à informação legislativa.

Palavras-chave: Inteligência Artificial Generativa. Dados Abertos. Design Science Research. Transparência Pública. Processamento de Linguagem Natural.

Abstract

The growing production of raw data by the Federal Senate poses challenges to organization, querying, and interpretation, limiting the effectiveness of public transparency. Within this context, this work adopts the Design Science Research (DSR) methodology to investigate the application of Generative Artificial Intelligence in the analysis of open parliamentary data. The objective is to design, develop, and technically evaluate a computational artifact capable of structuring legislative data, classifying speeches, and supporting natural-language queries. The proposed solution, named AgentAI, consists of an interactive web application that automates data extraction from the Senate API and uses the locally executed Mistral 7B Instruct model for thematic classification and data-grounded response generation. The evaluation will be conducted without collecting data from human participants, using representative query scenarios, comparison with reference answers, traceability checks, and factual analysis of generated responses. The research investigates to what extent combining open data, local Generative AI, and visual/conversational interfaces can reduce technical barriers to accessing legislative information.

Keywords: Generative Artificial Intelligence. Open Data. Design Science Research. Public Transparency. Natural Language Processing.

Lista de ilustrações

Figura 1 – Processo de publicação e estruturação de dados abertos	14
Figura 2 – Diagrama das 5 estrelas de Dados Abertos	15
Figura 3 – Abordagem Clássica de PLN	15
Figura 4 – Abordagem Generativa com LLMs	16
Figura 5 – Fluxo de Treinamento e Refinamento de um LLM	16
Figura 6 – Arquitetura de interação do usuário com os dados parlamentares: Dashboard e Chatbot integrados	21
Figura 7 – Fluxo metodológico baseado em Design Science Research (adaptado de Peffers et al. 2007)	23
Figura 8 – Interface Swagger da API de Dados Abertos do Senado Federal	25
Figura 9 – Interface da Aplicação	26
Figura 10 – Fases do Mapeamento Sistemático da Literatura	34
Figura 11 – Fluxograma de seleção dos estudos (PRISMA-ScR)	38
Figura 12 – Interface do Agente Conversacional (Chatbot) do AgentAI	46

Lista de quadros

Quadro 1 – Cronograma de Execução e Finalização da Dissertação	32
Quadro 2 – Questões de Pesquisa do Mapeamento Sistemático	35
Quadro 3 – Campos de Extração de Dados	35
Quadro 4 – Palavras-Chave da Busca	36
Quadro 5 – Strings de Busca (Conceituais)	36
Quadro 6 – Critérios de Inclusão e Exclusão	37
Quadro 7 – Progresso das Fases de Design Science Research	48
Quadro 8 – Status e Planejamento das Fases Finais da Dissertação	48

Sumário

1	Introdução	9
1.1	Contexto	9
1.2	Motivação	10
1.3	Problemática, Questão de Pesquisa e Hipótese	10
1.3.1	Problemática	10
1.3.2	Questão de Pesquisa	11
1.3.3	Hipótese de Pesquisa	11
1.4	Objetivos	11
1.4.1	Objetivo Geral	11
1.4.2	Objetivos Específicos	11
1.5	Estrutura do Documento	12
2	Fundamentação Teórica	13
2.1	Dados Abertos	13
2.1.1	As 5 Estrelas dos Dados Abertos	14
2.2	Processamento de Linguagem Natural (PLN) e Modelos de Linguagem	15
2.3	Inteligência Artificial Generativa	16
2.3.1	Recuperação Aumentada por Geração	17
2.3.2	Mistral 7B Instruct vs. Alternativas	17
2.4	Design Science Research	18
2.4.1	Fases da Design Science Research	18
2.4.2	DSR no Contexto desta Pesquisa	19
2.5	Interação Humano-Dados e Acessibilidade de Informação	19
2.5.1	Desafios de Visualização de Dados	19
2.5.2	Barreiras Cognitivas para Usuários Não-Especialistas	20
2.5.3	Interfaces Conversacionais como Estratégia de Acessibilidade	20
3	Metodologia	22
3.1	Abordagem Metodológica: Design Science Research	22
3.2	Fases da Pesquisa	23
3.2.1	Fase 1: Identificação do Problema e Motivação	23
3.2.2	Fase 2: Definição dos Objetivos da Solução	24
3.3	Fase 3: Design e Desenvolvimento do Artefato	24
3.3.1	Coleta e Processamento de Dados (Camada de Dados)	24
3.3.2	Análise com IA Generativa (Camada de Inteligência)	25
3.3.3	Interface Interativa (Camada de Apresentação)	25

3.4	Fundamentos Teóricos para as Escolhas de Design	26
3.4.1	Por que Dashboard?	26
3.4.2	Por que Chatbot?	27
3.4.3	Complementaridade: Dashboard + Chatbot	28
3.5	Fase 4: Demonstração	28
3.6	Fase 5: Avaliação do Artefato	28
3.6.1	Avaliação da Coleta e Estruturação dos Dados	29
3.6.1.1	Pergunta	29
3.6.1.2	Método	29
3.6.1.3	Métricas	29
3.6.2	Avaliação da Classificação Temática	29
3.6.2.1	Pergunta	29
3.6.2.2	Método	29
3.6.2.3	Métricas	30
3.6.2.4	Critério de Interpretação	30
3.6.3	Avaliação Factual das Respostas do Agente Conversacional	30
3.6.3.1	Pergunta	30
3.6.3.2	Método	30
3.6.3.3	Métricas	30
3.6.4	Avaliação de Rastreabilidade	31
3.6.4.1	Pergunta	31
3.6.4.2	Método	31
3.6.4.3	Métricas	31
3.6.5	Avaliação de Cenários de Uso	31
3.7	Fase 6: Reflexão e Aprendizados	31
3.8	Cronograma de Execução	32
4	Estado da Arte	33
4.1	Protocolo do Mapeamento Sistemático	33
4.1.1	Planejamento	34
4.1.2	Execução e Resultados	37
4.2	Análise Temática dos Resultados	39
4.2.1	Tema 1: IA Generativa para Estruturação de Dados Legislativos	39
4.2.2	Tema 2: Interfaces Conversacionais para Acessibilidade	39
4.2.3	Tema 3: Análise de Dados Legislativos com PLN Clássico	40
4.2.4	Tema 4: Desafios e Lacunas na Literatura	40
4.3	Lacunas Identificadas e Contribuições Desta Pesquisa	41
4.4	Conclusões do Mapeamento Sistemático	42
5	Desenvolvimento e Resultados Preliminares	43

5.1	Estágio Atual do Desenvolvimento	43
5.2	Arquitetura e Componentes do Artefato	44
5.2.1	Camada de Dados: Coleta e Processamento	44
5.2.2	Camada de Inteligência: Análise com Mistral 7B	44
5.2.3	Camada de Apresentação: Interfaces Acessíveis	45
5.2.3.1	Dashboard Visual	45
5.2.3.2	Chatbot Conversacional	46
5.3	Fluxo de Funcionamento do Sistema	46
5.4	Dados Legislativos Utilizados	47
5.5	Status de Conclusão das Fases DSR	47
5.6	Cronograma de Execução da Dissertação	48
5.7	Próximas Ações Imediatas (Próximas 8 Semanas)	49
6	Considerações Parciais e Trabalhos Futuros	50
6.1	Progresso do Ciclo de Design Science Research	50
6.2	Resultados Preliminares do Artefato	51
6.2.1	Viabilidade Técnica	51
6.2.2	Verificação Funcional Preliminar	51
6.3	Desafios e Limitações Identificadas	52
6.3.1	Desafios Técnicos	52
6.3.2	Desafios Metodológicos	52
6.4	Contribuições Esperadas da Pesquisa	53
6.4.1	Contribuições Científicas	53
6.4.2	Contribuições Práticas	53
6.5	Trabalhos Futuros: Fases de Avaliação e Conclusão	54
6.6	Perspectivas de Conclusão	54
	Referências	56

1

Introdução

A crescente abertura de dados governamentais no Brasil criou um paradoxo pouco discutido: os dados estão tecnicamente disponíveis, mas permanecem inacessíveis para a maior parte da população. Esta dissertação parte desse problema concreto para investigar se — e em que medida — a Inteligência Artificial Generativa pode reduzir essa distância entre disponibilidade técnica e acesso efetivo à informação parlamentar.

1.1 Contexto

A busca por um governo transparente é um pilar fundamental da democracia, onde a visibilidade do poder legitima as instituições (BOBBIO, 1986). No século XXI, essa premissa é potencializada pelo movimento de dados abertos (Open Data), que defende que os dados governamentais devam ser livremente utilizados, reutilizados e redistribuídos (Open Knowledge Brasil, 2024). Contudo, a simples disponibilização das informações sobre as atividades parlamentares não assegura, por si só, a efetividade da transparência. A proliferação de dados brutos, como os debates e discursos políticos, requer métodos de organização, recuperação e análise para que a informação pública possa ser consultada de modo inteligível — pois, como argumentam Oliveira e Ckagnazaroff (2022), a transparência efetiva exige que os dados sejam não apenas públicos, mas também claros, contextualizados e utilizáveis. Quando essa mediação não se realiza, o fosso entre o que está formalmente disponível e o que é efetivamente acessível contribui para aprofundar o distanciamento entre representados e representantes — condição que Levitsky e Ziblatt (2018) identificam como uma das precursoras do enfraquecimento das instituições democráticas. Nesse cenário, a Inteligência Artificial (IA), com destaque para a IA Generativa, apresenta potencial para processar, classificar e sintetizar grandes volumes de dados textuais, apoiando novas formas de consulta à informação pública.

1.2 Motivação

A motivação central deste trabalho está na distância entre o que os dados parlamentares abertos prometem e o que efetivamente entregam. A API do Senado Federal disponibiliza volumes crescentes de informações sobre sessões, discursos e votações, mas consultá-la exige familiaridade com estruturas técnicas (endpoints, formatos XML/JSON) que escapam ao repertório da maioria dos cidadãos. Não se trata de um problema de vontade política na abertura dos dados — trata-se de um problema de mediação entre dado bruto e informação compreensível. A aplicação da IA Generativa nesse contexto não é uma solução trivial: ela carrega consigo riscos conhecidos de imprecisão factual e viés algorítmico que precisam ser investigados antes de qualquer uso em contextos cívicos. É exatamente essa tensão — potencial de democratização versus riscos de desinformação — que motiva a pesquisa aqui proposta.

O artefato desenvolvido nesta dissertação, denominado *AgentAI*, é uma aplicação web que integra coleta automatizada de dados parlamentares via API do Senado Federal, classificação temática de discursos com IA Generativa executada localmente, visualizações interativas e um agente conversacional para consultas em linguagem natural. A escolha por execução local — em vez de APIs proprietárias — responde a critérios científicos concretos: replicabilidade do experimento, soberania dos dados e independência de custos operacionais.

1.3 Problemática, Questão de Pesquisa e Hipótese

1.3.1 Problemática

A principal problemática abordada decorre do fato de que o volume e a complexidade dos dados parlamentares abertos, embora publicamente disponíveis, representam uma barreira significativa para consulta e análise. Como discutido por [Oliveira e Ckagnazaroff \(2022\)](#), para que a transparência seja efetiva, os dados devem ser não apenas públicos, mas também claros, contextualizados e utilizáveis. Atualmente, a análise proficiente desses dados exige conhecimentos técnicos, familiaridade com as estruturas das APIs e o dispêndio de tempo considerável.

Complementarmente, [Lee, Kim e Kwon \(2017\)](#), através do VLAT (*Visualization Literacy Assessment Test*), demonstraram que a interpretação das visualizações gráficas pode variar conforme a literacia visual dos usuários. [Hornung, Pereira e Baranauskas \(2015\)](#) apontam que as pessoas sem formação em estatística ou ciência de dados podem enfrentar barreiras cognitivas ao analisar os dados complexos. Portanto, a mera disponibilização dos dados legislativos não garante, por si só, que essas informações sejam facilmente consultáveis ou compreensíveis.

Nesse contexto, a Inteligência Artificial Generativa, exemplificada pelos modelos como o Mistral 7B Instruct ([Mistral AI, 2024](#)), apresenta-se como uma abordagem promissora para apoiar a organização e a consulta dos dados legislativos textuais. Diferentemente das técnicas

tradicionais de Processamento de Linguagem Natural (PLN) que dependem de palavras-chave rígidas, os modelos de linguagem podem apoiar tarefas de classificação temática, sumarização e geração de respostas em linguagem natural. A execução local do modelo também contribui para a privacidade, replicabilidade e independência das APIs proprietárias.

1.3.2 Questão de Pesquisa

Diante desse cenário, este trabalho norteia-se pela seguinte questão de pesquisa central:

QP: Em que medida um artefato computacional baseado em *dashboard* visual e agente conversacional com IA Generativa local pode estruturar, classificar e tornar consultáveis os dados parlamentares abertos do Senado Federal?

1.3.3 Hipótese de Pesquisa

Para responder a esta questão, foi formulada a seguinte hipótese de trabalho:

Hipótese: A combinação do processamento dos dados abertos, classificação temática com o Mistral 7B Instruct e interface visual/conversacional é capaz de estruturar e tornar consultáveis dados parlamentares abertos, de modo que: (a) a classificação temática automática dos discursos apresente acurácia superior à de um classificador por palavras-chave utilizado como linha de base; (b) as respostas do agente conversacional sejam factualmente coerentes com os dados recuperados em pelo menos 70% dos cenários de consulta avaliados; e (c) as respostas apresentem rastreabilidade explícita — isto é, possam ser associadas aos registros de origem — em pelo menos 80% dos casos. Caso esses limiares não sejam alcançados, a hipótese será refutada e as causas do insucesso constituirão o principal resultado científico da dissertação.

1.4 Objetivos

1.4.1 Objetivo Geral

Investigar como a aplicação da Inteligência Artificial Generativa local nos dados legislativos abertos pode apoiar a estruturação, classificação e consulta das informações parlamentares, mediante o design, implementação e avaliação técnica de um artefato computacional interativo que integra interface visual e conversacional.

1.4.2 Objetivos Específicos

Para que o objetivo geral seja alcançado, foram definidos os seguintes objetivos específicos, alinhados às etapas da metodologia *Design Science Research*:

- Realizar um mapeamento sistemático da literatura para identificar os fundamentos teóricos sobre os dados abertos, IA Generativa em contextos cívicos, interação humano-dados e consulta aos dados legislativos.

- Descrever e justificar os fundamentos teóricos para as escolhas de design do artefato, especificamente a combinação do *dashboard* visual e agente conversacional baseado na IA Generativa local.
- Implementar um protótipo funcional (*artefato computacional*) capaz de processar os dados legislativos abertos da API do Senado Federal, classificar tematicamente os discursos e responder às perguntas em linguagem natural utilizando o modelo Mistral 7B Instruct.
- Avaliar a eficácia técnica do artefato, verificando a qualidade da coleta e estruturação dos dados, a acurácia da classificação temática e a qualidade factual das respostas geradas em comparação com os dados oficiais.
- Avaliar a rastreabilidade das respostas geradas pelo agente conversacional, verificando se as informações apresentadas podem ser associadas aos dados recuperados, como discurso, votação, data, parlamentar ou matéria legislativa.
- Documentar o conhecimento científico gerado sobre o design e a avaliação dos artefatos computacionais para consulta aos dados parlamentares abertos com IA Generativa local.

1.5 Estrutura do Documento

O documento está organizado em seis capítulos. A Fundamentação Teórica (Cap. 2) apresenta os conceitos de dados abertos, PLN, IA Generativa, RAG, DSR e interação humano-dados. A Metodologia (Cap. 3) detalha as seis fases DSR e o protocolo de avaliação do artefato. O Estado da Arte (Cap. 4) mapeia sistematicamente a literatura existente e posiciona esta pesquisa em relação ao campo. O Desenvolvimento (Cap. 5) descreve a arquitetura do AgentAI e os resultados preliminares. As Considerações Parciais (Cap. 6) analisam o progresso alcançado, os desafios identificados e as perspectivas de conclusão.

A adjacência intencional entre os capítulos de Metodologia e Estado da Arte permite que o leitor conheça primeiro as decisões metodológicas adotadas — inclusive o protocolo de avaliação — para então confrontá-las com as práticas documentadas pela literatura, tornando explícita a contribuição original desta dissertação.

2

Fundamentação Teórica

2.1 Dados Abertos


Este trabalho se fundamenta na disponibilização de dados governamentais em formato aberto, livre de restrições de direitos autorais ou outros mecanismos de controle. Conforme definido pelo movimento OK Brasil ([Open Knowledge Brasil, 2024](#)) e pelo Arquivo Nacional do Reino Unido ([Arquivo Nacional, 2023](#)), os "dados abertos" são aqueles disponibilizados livremente para acesso, uso, reutilização e redistribuição por qualquer indivíduo. Para que sejam considerados como tal, é crucial que os dados estejam em formatos abertos e não proprietários, permitindo a sua fácil integração com outros sistemas e ferramentas.

No contexto da pesquisa científica, os dados abertos são essenciais para a aceleração de descobertas e a promoção da colaboração ([SAYÃO; SALES, 2014](#)). Ao tornar dados disponíveis em formato aberto, pesquisadores e cientistas sociais ganham condições concretas para replicar estudos, contestar resultados e explorar perspectivas de análise que dependem do acesso livre a fontes primárias. Sayão e Sales ([SAYÃO; SALES, 2014](#)) argumentam que essa abertura não é apenas uma mudança técnica, mas uma transformação nas práticas de comunicação científica, exigindo novas formas de gerenciamento, preservação e compartilhamento de dados ao longo do tempo.

Na gestão pública, os dados abertos são fundamentais para a transparência e a accountability. Ao disponibilizar dados sobre gastos públicos e contratos governamentais, os governos aumentam sua transparência e permitem um controle social mais rigoroso ([ZUIDERWIJK; JANSSEN, 2014](#)). No Brasil, a API do Senado Federal configura-se como uma ferramenta essencial para a democracia participativa, oferecendo dados brutos sobre o funcionamento da Instituição. Contudo, a efetividade dessa abertura depende da qualidade com que os dados são entregues aos cidadãos. Conforme argumentado por Vetro et al. ([VETRÒ et al., 2016](#)), a qualidade dos dados deve ser observada em todas as etapas de sua disponibilização, desde a

coleta até a apresentação. A Figura 1 ilustra o processo de publicação de dados abertos e os pontos críticos onde a intervenção técnica é necessária para assegurar que o dado bruto se torne informação útil.

Figura 1 – Processo de publicação e estruturação de dados abertos



Fonte: Adaptado de Villazón-Terrazas et al. (2011).

2.1.1 As 5 Estrelas dos Dados Abertos


Para maximizar o potencial de reutilização e interoperabilidade dos dados abertos, Tim Berners-Lee propôs um sistema de classificação de 5 estrelas (Figura 2), que gradua o nível de abertura e estruturação dos dados (ISOTANI; BITTENCOURT, 2015). A seguir, são descritas cada uma das etapas:

- **1 estrela:** Disponível na web (qualquer formato) com licença aberta. Este é o nível mais básico de abertura de dados.
- **2 estrelas:** Disponível como dados estruturados (por exemplo, em formatos CSV ou Excel). Nesse estágio, os dados são organizados em tabelas ou outras estruturas que facilitam a sua manipulação e análise.
- **3 estrelas:** Como 2 estrelas, mas em formato não proprietário. Aqui, os dados estão disponíveis em formatos abertos padronizados (como CSV), o que facilita sua integração com diversas ferramentas de visualização e análise.
- **4 estrelas:** Como 3 estrelas, mais uso de URIs e padrões W3C (RDF, SPARQL). Neste estágio, os dados são identificáveis na web através de URIs, o que permite a sua ligação

com outras fontes de informação. Os dados também podem ser descritos em formato RDF, permitindo a sua integração com recursos semânticos padronizados.

- **5 estrelas:** Como 4 estrelas, mais ligação (link) com outros dados para fornecer contexto (*Linked Data*). Neste ponto, os dados não apenas são abertos e interoperáveis, mas também estão conectados a outras fontes de informação relevantes. Isso permite a construção de aplicações que fornecem uma visão holística dos dados.

Figura 2 – Diagrama das 5 estrelas de Dados Abertos



Fonte: 5stardata.info.

2.2 Processamento de Linguagem Natural (PLN) e Modelos de Linguagem

O Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência Artificial que se dedica a capacitar os computadores para processar e compreender a linguagem humana (JURAFSKY; MARTIN, 2023). A abordagem clássica do PLN exigia um *pipeline* complexo de pré-processamento manual e intensivo (Figura 3), onde o texto era convertido em representações vetoriais numéricas.

Figura 3 – Abordagem Clássica de PLN




Fonte: Produção da autora.

Com o advento dos Modelos de Linguagem de Larga Escala (LLMs), essa abordagem mudou drasticamente. Como ilustrado na Figura 4, os LLMs são capazes de realizar tarefas

complexas, como tradução, resumo e geração de texto, de forma *end-to-end*, sendo instruídos por comandos em linguagem natural (*prompts*).

Figura 4 – Abordagem Generativa com LLMs




Fonte: Produção da autora.

Este trabalho adota a abordagem generativa, utilizando o modelo Mistral 7B Instruct (Mistral AI, 2024), que roda em ambiente local para executar tarefas de classificação temática e resposta a perguntas (*Question Answering*), dispensando a necessidade de treinamento de modelos específicos para cada tarefa e evitando dependência de APIs externas.

2.3 Inteligência Artificial Generativa

Os Modelos de Linguagem de Larga Escala (LLMs) são modelos fundamentados em arquiteturas de redes neurais profundas (*deep learning*), treinados com volumes massivos de dados para compreender e gerar linguagem com alta fluência (Red Hat, 2023). O fluxo típico de desenvolvimento desses modelos envolve coleta, treinamento e refinamento por *feedback* humano (RLHF), conforme a Figura 5.

Figura 5 – Fluxo de Treinamento e Refinamento de um LLM



Fonte: Produção da autora.

No contexto desta pesquisa, a IA Generativa é empregada para classificar discursos parlamentares por tema e gerar respostas em linguagem natural a partir de dados legislativos estruturados (TAMPER; TUOMINEN; HYVÖNEN, 2022). Esse uso, porém, não é isento de riscos: alucinações — respostas factualmente incorretas geradas com aparente confiança pelo modelo — e vieses presentes nos dados de treinamento representam ameaças concretas à confiabilidade do sistema (MARQUES; LAIPELT, 2023). Em contextos cívicos, onde informação imprecisa pode influenciar a percepção pública sobre representantes políticos, esses riscos não

podem ser tratados apenas como limitações técnicas; eles exigem mecanismos explícitos de verificação e rastreabilidade, que constituem, precisamente, um dos focos desta dissertação.

2.3.1 Recuperação Aumentada por Geração

Além da geração textual, este trabalho adota uma estratégia de Recuperação Aumentada por Geração (*Retrieval-Augmented Generation* – RAG). Em linhas gerais, RAG combina uma etapa de recuperação de informações relevantes em uma base de dados ou coleção documental com uma etapa de geração de resposta por modelo de linguagem (LEWIS et al., 2020). Essa abordagem é adequada para domínios em que a resposta deve permanecer ancorada em fontes verificáveis, pois o modelo não responde apenas com base em seus parâmetros internos: ele recebe, no *prompt*, um contexto recuperado previamente.

No AgentAI, adota-se uma versão simplificada de RAG: em vez de indexação vetorial densa com modelos de *embedding* e operações de similaridade semântica, o sistema recupera registros legislativos a partir de busca estruturada na base local — filtrando por parlamentar, período, tema ou palavras presentes no texto — e fornece esse contexto diretamente ao Mistral 7B Instruct para geração da resposta. Essa escolha implica um *trade-off* explícito: perde-se a capacidade de recuperar documentos por paráfrase ou sinônimo (limitação que será documentada na avaliação), mas ganha-se rastreabilidade total — cada resposta pode ser associada aos registros exatos que a fundamentaram. Para o objetivo desta dissertação, que é justamente investigar a qualidade factual e a rastreabilidade das respostas em contexto legislativo, essa abordagem é metodologicamente coerente.

2.3.2 Mistral 7B Instruct vs. Alternativas

A escolha do modelo Mistral 7B Instruct justifica-se por múltiplos aspectos técnicos e científicos. Diferentemente de APIs proprietárias como Google Gemini, Mistral 7B oferece:

- **Privacidade e Soberania de Dados:** O modelo roda localmente, garantindo que os dados legislativos brasileiros não sejam transmitidos para servidores externos, o que se alinha com princípios de soberania digital.
- **Replicabilidade:** Por ser *open-source*, permite que outros pesquisadores reproduzam exatamente o experimento e validem os resultados de forma independente, atendendo aos critérios de rigor científico.
- **Custo Operacional:** Elimina dependência de APIs pagas, reduzindo barreiras financeiras para a replicação da pesquisa.
- **Performance Adequada:** Apesar de menor em parâmetros que os grandes modelos proprietários, o Mistral 7B Instruct apresenta desempenho competitivo em tarefas de

compreensão e geração de linguagem em benchmarks gerais (JIANG et al., 2023); sua adequação específica ao domínio legislativo em português constitui, precisamente, uma das questões investigadas nesta dissertação.

Este trade-off entre capacidade absoluta (modelos proprietários maiores) e replicabilidade (modelo local open-source) representa uma escolha metodológica consciente que prioriza a sustentabilidade e transparência da pesquisa.

2.4 Design Science Research

O Design Science Research (DSR) é um paradigma metodológico específico para a pesquisa em Ciência da Computação, que combina rigor científico com a construção prática de artefatos tecnológicos (PEFFERS et al., 2007). Conforme definido por Peffers et al. (PEFFERS et al., 2007), DSR diferencia-se da pesquisa puramente teórica porque investiga não apenas se um artefato funciona, mas como e por que ele funciona, gerando conhecimento científico sobre seu design, sua implementação, suas limitações e sua avaliação.

Runeson et al. (RUNESON; ENGSTRÖM; STOREY, 2020) complementam ao argumentar que, em Engenharia de Software e Computação, construir um artefato (seja software, hardware ou framework) em si não constitui automaticamente conhecimento científico. O conhecimento emerge quando se documenta e avalia sistematicamente o processo e os impactos daquele artefato. Conforme Pimentel et al. (PIMENTEL; FILIPPO; SANTOS, 2020), a pesquisa em Design Science visa "a construção de artefatos como estratégia para o avanço do conhecimento".

2.4.1 Fases da Design Science Research

O ciclo de DSR, conforme proposto por Peffers et al. (PEFFERS et al., 2007), compreende seis fases que orientam o desenvolvimento de pesquisa em Computação:

1. **Motivação e Identificação do Problema:** Definição clara do problema prático que o artefato propõe-se a resolver, fundamentado em literatura e observação empírica.
2. **Objetivos da Solução:** Especificação do que a solução deve atingir e justificativa teórica para as escolhas de design.
3. **Design e Desenvolvimento:** Construção do artefato, documentando decisões técnicas e sua fundamentação.
4. **Demonstração:** Apresentação do artefato funcionando em cenários reais ou controlados, validando a viabilidade técnica.

5. **Avaliação:** Avaliação rigorosa da efetividade técnica, qualidade das respostas, rastreabilidade e limitações, comparando contra critérios pré-definidos.
6. **Reflexão e Aprendizados:** Documentação do conhecimento científico gerado, contribuições à teoria, limitações e trabalhos futuros.

2.4.2 DSR no Contexto desta Pesquisa

Este trabalho adota DSR porque seu objetivo central é a construção e avaliação de um artefato computacional (AgentAI) cuja utilidade e eficácia técnica devem ser validadas. Diferentemente de uma pesquisa exploratória que investiga "o que está acontecendo" em um contexto natural, esta pesquisa propõe e testa uma solução, investigando em que medida ela apoia a estruturação, classificação e consulta de dados parlamentares abertos. Conforme argumentado por Thuan et al. (THUAN; DRECHSLER; ANTUNES, 2019), ao formular a questão de pesquisa em DSR, deve-se focar em "Como?" (design e implementação) e "Em que medida?" (efetividade do artefato), não apenas "O quê?"

2.5 Interação Humano-Dados e Acessibilidade de Informação

Um dos desafios fundamentais na democratização de dados é garantir que os cidadãos consigam não apenas acessar informações, mas também compreendê-las e interpretá-las adequadamente. Este problema é abordado pela comunidade de pesquisa em Interação Humano-Dados.

2.5.1 Desafios de Visualização de Dados

Lee et al. (LEE; KIM; KWON, 2017), através do desenvolvimento do VLAT (*Visualization Literacy Assessment Test*), demonstraram que nem todos os usuários conseguem interpretar visualizações gráficas complexas. Especificamente, o estudo aponta que:

- Usuários com pouca exposição a gráficos estatísticos frequentemente cometem erros na leitura de eixos, escalas e representações multidimensionais.
- Visualizações sofisticadas (heatmaps, scatter plots 3D) podem confundir mais do que esclarecer para usuários sem expertise.
- A compreensão visual de dados é uma competência que varia significativamente entre indivíduos.

2.5.2 Barreiras Cognitivas para Usuários Não-Especialistas

Hornung et al. ([HORNUNG; PEREIRA; BARANAUSKAS, 2015](#)) apontam que usuários sem formação em estatística ou ciência de dados frequentemente enfrentam barreiras cognitivas significativas ao tentar analisar dados complexos. Especificamente:

- Falta de familiaridade com conceitos como mediana, distribuição, correlação etc.
- Dificuldade em construir hipóteses e validá-las contra dados.
- Sobrecarga cognitiva ao lidar simultaneamente com múltiplas dimensões de informação.


Consequentemente, a mera disponibilização de dados e interfaces visuais não garante compreensão ou participação democrática efetiva. Conforme Brito et al. ([BRITO; FRANÇA; VIVACQUA, 2024](#)), em seu trabalho sobre "Literacia de Dados para Todos", a solução requer abordagens múltiplas que reduzam progressivamente barreiras de entrada.

2.5.3 Interfaces Conversacionais como Estratégia de Acessibilidade

Neste contexto, interfaces conversacionais alimentadas por modelos de linguagem generativa representam uma estratégia complementar à visualização tradicional. Ao permitir que os usuários formulem perguntas em linguagem natural (por exemplo: "Como votou o Senador X sobre educação?"), reduz-se a necessidade de expertise técnica ou estatística. A IA Generativa traduz a pergunta em operações sobre os dados, apresentando resultados em linguagem acessível.

A combinação de duas modalidades de interação—Dashboard visual e Chatbot conversacional—permite que diferentes usuários escolham a interface que melhor se adequa ao seu estilo cognitivo e nível de expertise, aumentando a acessibilidade global da solução. A arquitetura da aplicação desenvolvida neste trabalho (Figura 6) combina essas duas abordagens para maximizar a acessibilidade.

Figura 6 – Arquitetura de interação do usuário com os dados parlamentares: Dashboard e Chatbot integrados



Fonte: Produção da autora.

Os conceitos discutidos neste capítulo não são independentes entre si: a teoria de dados abertos delimita o corpus e justifica a escolha da API do Senado Federal; os estudos sobre literacia de dados e barreiras cognitivas sustentam a decisão de oferecer duas modalidades de interação (visual e conversacional) em vez de apenas uma; o DSR fundamenta a abordagem metodológica que orienta todo o ciclo de pesquisa; e a discussão sobre RAG e alucinações em LLMs antecipa os desafios concretos que o protocolo de avaliação precisará endereçar. A articulação entre essas dimensões é o que diferencia a proposta de uma simples implementação técnica.

3

Metodologia


Quando o objetivo central de uma pesquisa é construir e avaliar um artefato computacional — e não apenas observar ou descrever um fenômeno —, a escolha metodológica deve refletir essa natureza construtiva. É nesse sentido que se adota o *Design Science Research* (DSR), um paradigma consolidado em Ciência da Computação que orienta não apenas a construção do artefato, mas a geração de conhecimento científico a partir do processo de design, implementação e avaliação (PEFFERS et al., 2007). O risco de trabalhos dessa natureza é reduzir-se a um relatório técnico de desenvolvimento de software; a DSR evita isso ao exigir que cada decisão de design seja justificada teoricamente e que os resultados sejam avaliados com rigor comparável ao de pesquisas empíricas (RUNESON; ENGSTRÖM; STOREY, 2020; PIMENTEL; FILIPPO; SANTOS, 2020). As seis fases que estruturam esta pesquisa são descritas a seguir.

3.1 Abordagem Metodológica: Design Science Research

A metodologia foi estruturada seguindo o ciclo de processo proposto por Peffers et al. (PEFFERS et al., 2007), adaptado para o contexto deste trabalho em seis fases principais, conforme ilustrado na Figura 7:

1. Identificação do Problema e Motivação
2. Definição dos Objetivos da Solução
3. Design e Desenvolvimento do Artefato
4. Demonstração
5. Avaliação
6. Reflexão e Aprendizados

Figura 7 – Fluxo metodológico baseado em Design Science Research (adaptado de Peffers et al. 2007)



Fonte: Adaptado de Peffers et al. (2007).

3.2 Fases da Pesquisa

3.2.1 Fase 1: Identificação do Problema e Motivação

A primeira etapa consistiu no reconhecimento da opacidade prática dos dados parlamentares. Embora disponíveis em formato aberto através da API do Senado Federal, a complexidade técnica e o volume massivo desses dados impedem que cidadãos comuns exerçam controle social efetivo. Segundo Oliveira e Ckagnazaroff ([OLIVEIRA; CKAGNAZAROFF, 2022](#)), para que a transparência seja efetiva, os dados devem ser não apenas públicos, mas também claros, contextualizados e utilizáveis.

Conforme apontado por Lee et al. ([LEE; KIM; KWON, 2017](#)) através do VLAT, nem todos conseguem interpretar visualizações gráficas complexas. Complementarmente, Hornung et al. ([HORNUNG; PEREIRA; BARANAUSKAS, 2015](#)) demonstram que usuários sem

formação estatística frequentemente não conseguem analisar dados de forma autônoma. Consequentemente, a mera disponibilização de dados não garante compreensão ou participação democrática.

Esta fase foi fundamentada em revisão de literatura e análise exploratória da API do Senado Federal, identificando-se a lacuna entre disponibilidade técnica de dados e acessibilidade cognitiva para cidadãos.

3.2.2 Fase 2: Definição dos Objetivos da Solução

Definiu-se que o artefato a ser construído deveria reduzir as barreiras cognitivas de acesso aos dados parlamentares. Para isso, estabeleceu-se que a solução deveria:

1. **Automatizar a extração de dados brutos:** Implementar pipeline de ETL para processar dados da API do Senado, convertendo formatos não estruturados (XML/JSON) em estruturas tabulares otimizadas para análise.
2. **Traduzir linguagem parlamentar:** Utilizar IA Generativa para categorizar e resumir discursos parlamentares complexos, tornando-os compreensíveis para cidadãos sem expertise na área.
3. **Permitir interação em linguagem natural:** Implementar interface conversacional que permita ao usuário formular perguntas em linguagem comum, dispensando conhecimento técnico de queries ou programação.
4. **Oferecer múltiplas modalidades de exploração:** Combinar Dashboard visual (para exploração livre) com Chatbot conversacional (para consultas diretas), atendendo diferentes estilos cognitivos de usuários.

3.3 Fase 3: Design e Desenvolvimento do Artefato

Nesta fase, correspondente à construção técnica da solução, a aplicação foi desenvolvida em Python sob uma arquitetura modular, visando garantir manutenibilidade e escalabilidade. A solução foi segmentada em três camadas principais:


3.3.1 Coleta e Processamento de Dados (Camada de Dados)

A coleta foi efetuada via API de Dados Abertos do Senado Federal ([Senado Federal do Brasil, s.d.](#)). O processo de ETL (*Extract, Transform, Load*) incluiu:

- **Requisição:** Uso da biblioteca *Requests* ([Python Software Foundation, 2024](#)) para extração de dados brutos (XML/JSON) dos *endpoints* mapeados via Swagger (Figura 8).

- **Estruturação:** Conversão e limpeza dos dados utilizando *Pandas* (Pandas Development Team, 2023), organizando discursos e votações em estruturas tabulares otimizadas para análise.

Figura 8 – Interface Swagger da API de Dados Abertos do Senado Federal



Fonte: Senado Federal.

3.3.2 Análise com IA Generativa (Camada de Inteligência)

O núcleo analítico utiliza o modelo Mistral 7B Instruct (Mistral AI, 2024), que roda em ambiente local. Diferente de abordagens que dependem de APIs proprietárias, esta etapa emprega engenharia de *prompts* para duas funções críticas:

- **Classificação Temática:** Categorização automática de discursos em temas (ex: "Saúde", "Educação", "Infraestrutura") utilizando *prompts* estruturados e exemplos de Few-Shot Learning.
- **Motor de Resposta (RAG Simplificado):** O módulo recebe perguntas do usuário em linguagem natural, recupera dados relevantes do banco de dados estruturado e instrui o modelo Mistral 7B a gerar respostas contextualizadas e didáticas que sejam compreensíveis para cidadãos não-especialistas.

A escolha de Mistral 7B em ambiente local oferece vantagens críticas para pesquisa científica: replicabilidade total (código aberto), soberania de dados (não transmite informações legislativas para servidores externos) e sustentabilidade operacional.

3.3.3 Interface Interativa (Camada de Apresentação)


Para materializar o acesso democrático aos dados, desenvolveu-se uma interface *web* utilizando o *framework* Streamlit (Streamlit Inc., 2024), oferecendo dois modos de interação complementares:

- **Dashboard Visual:** Gráficos interativos gerados com *Plotly* (Plotly Technologies Inc., 2024) para exploração de tendências legislativas. O dashboard permite que usuários

visualizem panoramicamente os dados, seguindo o princípio de Shneiderman ([SHNEIDERMAN, 1996](#)) de "zoom and filter"(Figura 9).

- **Agente Conversacional:** Interface de *chat* que abstrai a complexidade dos dados, permitindo consultas diretas em linguagem natural como "Como votou o Senador X sobre educação?"ou "Qual foi o tema mais debatido em 2025?"(Figura 9).

Figura 9 – Interface da Aplicação



Fonte: Produção da autora.

3.4 Fundamentos Teóricos para as Escolhas de Design

A combinação de Dashboard e Chatbot não é arbitrária, mas fundamentada em teorias de Interação Humano-Computador e Acessibilidade de Dados. Esta seção justifica essas escolhas.

3.4.1 Por que Dashboard?

Dashboards e visualizações de dados oferecem exploração livre e visão holística de um corpus de dados. Contudo, conforme Lee et al. ([LEE; KIM; KWON, 2017](#)) demonstram através do VLAT, nem todos os usuários possuem "visualization literacy"— a capacidade de compreender visualizações gráficas complexas.

Apesar desta limitação, dashboards permitem que usuários:

- Obtenham visão panorâmica dos dados (principal → detalhe, conforme Shneiderman ([SHNEIDERMAN, 1996](#)))
- Explore dados autonomamente sem intermediário
- Identifiquem padrões visuais (tendências, anomalias)

- Filtem e segmentem dados interativamente

Portanto, a solução proposta inclui um Dashboard que prioriza:

- Paleta de cores intuitiva e acessível
- Títulos e rótulos em linguagem comum (não jargão legislativo)
- Representações visuais simples (barras, linhas) preferidas sobre heatmaps ou scatter plots
- Interatividade básica (filtros, hover para detalhe)

3.4.2 Por que Chatbot?

Interfaces conversacionais, especialmente aquelas alimentadas por Modelos de Linguagem Generativa, reduzem significativamente a barreira de entrada cognitiva. Um usuário sem expertise estatística pode formular perguntas em linguagem natural em vez de construir queries SQL ou manipular dados brutos.

Conforme pesquisa em HCI e Interação Humano-Dados ([HORNUNG; PEREIRA; BARANAUSKAS, 2015](#); [BRITO; FRANÇA; VIVACQUA, 2024](#)), interfaces conversacionais oferecem:

- **Redução de barreira de entrada:** Usuário não precisa saber estrutura de dados ou linguagem de queries
- **Interface familiar:** Conversação é natural para humanos
- **Customização por usuário:** Cada usuário pode formular perguntas de formas diferentes
- **Mediação de compreensão:** IA pode traduzir resultados técnicos em explicações compreensíveis

Limitações conhecidas de chatbots com LLMs incluem risco de alucinação (respostas factualmente incorretas) e opacidade. Para mitigar, a implementação proposta:

- Utiliza o Mistral 7B Instruct ([JIANG et al., 2023](#)), cujo porte paramétrico reduz a incidência de alucinações em relação a modelos de menor escala
- Implementa validação de respostas contra dados reais
- Fornece rastreabilidade: chatbot cita quais dados foram utilizados na resposta

3.4.3 Complementaridade: Dashboard + Chatbot

A literatura em Interação Humano-Dados distingue dois padrões primários de uso em sistemas de informação pública: a exploração orientada à descoberta, em que o usuário navega pelo corpus sem uma pergunta pré-definida, e a consulta orientada a objetivos, em que há uma pergunta específica a ser respondida (SHNEIDERMAN, 1996). Esses padrões raramente são atendidos com igual eficácia por uma única modalidade de interface.

O *Dashboard* atende principalmente o primeiro padrão: permite ao usuário identificar tendências, comparar parlamentares e detectar anomalias por navegação visual, sem exigir que ele formule uma pergunta antes de começar. O *Chatbot*, por sua vez, é mais adequado ao segundo padrão: reduz a carga cognitiva de quem sabe o que quer perguntar mas não sabe como navegar em dados estruturados. A integração de ambos em um único sistema não busca cobrir todos os perfis de usuário possíveis — uma afirmação que exigiria validação empírica — mas reconhece que restringir a interação a uma única modalidade excluiria sistematicamente parte dos potenciais usuários. Essa decisão de design será discutida nas considerações finais à luz dos resultados da avaliação.

3.5 Fase 4: Demonstração

Nesta fase, o artefato foi colocado em ambiente de homologação, processando dados reais da API do Senado Federal. A demonstração inclui:

- Processamento automático de sessões legislativas reais
- Classificação temática de discursos
- Resposta a consultas em linguagem natural
- Visualização de tendências legislativas

A aplicação encontra-se estável e funcional, habilitando o início imediato da fase de avaliação rigorosa.

3.6 Fase 5: Avaliação do Artefato

A fase de avaliação será conduzida sem entrevistas, questionários, observação comportamental ou qualquer coleta de dados com participantes humanos. A avaliação incidirá sobre o artefato computacional, os dados públicos processados e as respostas geradas pelo modelo. Dessa forma, a pesquisa utiliza exclusivamente dados abertos, informações de domínio público e análises técnicas do sistema.

A avaliação foi organizada em quatro frentes complementares: qualidade da coleta e estruturação dos dados, classificação temática, qualidade factual das respostas e rastreabilidade das informações apresentadas pelo agente conversacional.

3.6.1 Avaliação da Coleta e Estruturação dos Dados

3.6.1.1 Pergunta

Em que medida o pipeline de coleta e processamento estrutura corretamente os dados parlamentares obtidos da API do Senado Federal?

3.6.1.2 Método

Será selecionado um conjunto de endpoints e períodos de coleta definidos no escopo do estudo. Os dados retornados pela API serão comparados com as estruturas armazenadas localmente pelo AgentAI, verificando se os campos essenciais foram preservados e se o processo de transformação não introduziu inconsistências.

3.6.1.3 Métricas

- **Completeness:** proporção de registros coletados e armazenados com campos essenciais preenchidos.
- **Consistência:** ausência de duplicidades, datas inválidas, campos incompatíveis ou vínculos incorretos entre parlamentar, discurso, votação e matéria.
- **Reprodutibilidade:** capacidade de reexecutar o pipeline e obter uma base equivalente para o mesmo recorte temporal.

3.6.2 Avaliação da Classificação Temática

3.6.2.1 Pergunta

Em que medida o modelo Mistral 7B Instruct classifica corretamente os temas dos discursos parlamentares?

3.6.2.2 Método

Será construída uma amostra de discursos reais do Senado Federal (mínimo de 150 registros, distribuídos entre as categorias temáticas definidas) para compor o gabarito de referência. A anotação será realizada de forma independente por dois avaliadores — a pesquisadora e o orientador —, com base em critérios documentados explicitamente antes do início da anotação. O nível de concordância entre os avaliadores será medido pelo coeficiente Kappa de Cohen

(COHEN, 1960); casos de discordância serão resolvidos por discussão e registrados como sub-categoria de análise qualitativa. A classificação gerada pelo modelo será então comparada com o gabarito final consensuado.

3.6.2.3 Métricas

- **Acurácia:** proporção de classificações coincidentes com o gabarito de referência.
- **Precisão:** proporção de discursos classificados em um tema que efetivamente pertencem a esse tema no gabarito.
- **Revocação:** proporção de discursos de um tema que foram corretamente identificados pelo modelo.
- **F1-Score:** média harmônica entre precisão e revocação.

3.6.2.4 Critério de Interpretação

Os resultados serão interpretados comparativamente em relação a um *baseline* de referência: uma classificação por correspondência de palavras-chave temáticas predefinidas (abordagem clássica sem LLM). Essa comparação permite dimensionar o ganho — ou ausência de ganho — que o Mistral 7B Instruct oferece em relação a uma solução mais simples. A análise qualitativa complementará os números, identificando os tipos de discurso que geram maior ambiguidade e os casos em que o modelo produz classificações inconsistentes com o gabarito.

3.6.3 Avaliação Factual das Respostas do Agente Conversacional

3.6.3.1 Pergunta

As respostas geradas pelo agente conversacional são coerentes com os dados públicos recuperados da base local?

3.6.3.2 Método

Será elaborado um conjunto de cenários representativos de consulta, contemplando perguntas sobre votações, discursos, parlamentares, temas e períodos. Para cada cenário, será definida uma resposta esperada com base nos dados oficiais coletados da API do Senado Federal. As respostas geradas pelo AgentAI serão classificadas em: correta, parcialmente correta, incorreta ou não respondida.

3.6.3.3 Métricas

- Percentual de respostas corretas.

- Percentual de respostas parcialmente corretas.
- Percentual de respostas incorretas ou sem respaldo nos dados.
- Tipos de erro observados, como omissão, generalização indevida, interpretação incorreta ou ausência de evidência recuperada.

3.6.4 Avaliação de Rastreabilidade

3.6.4.1 Pergunta

As respostas do agente conversacional permitem identificar os dados utilizados para sua geração?

3.6.4.2 Método

Cada resposta gerada pelo agente será analisada quanto à presença de elementos de rastreabilidade, como parlamentar, data, sessão, matéria, votação, discurso ou trecho de dados recuperado. Essa análise busca verificar se o sistema evita respostas genéricas e se mantém ligação explícita com a base de dados consultada.

3.6.4.3 Métricas

- Percentual de respostas com referência explícita aos dados utilizados.
- Percentual de respostas sem rastreabilidade suficiente.
- Frequência de respostas em que o modelo extrapola além do contexto recuperado.

3.6.5 Avaliação de Cenários de Uso

A avaliação final consolidará os resultados das etapas anteriores em cenários de uso definidos pela pesquisadora. Esses cenários não envolvem participantes externos; funcionam como casos de teste do artefato. Exemplos incluem: consultar o posicionamento de um parlamentar em uma votação, identificar temas recorrentes em discursos de um período e solicitar uma síntese de votações relacionadas a uma área temática.

3.7 Fase 6: Reflexão e Aprendizados

A fase final documenta o conhecimento científico gerado através da pesquisa. Não se trata apenas de documentar que o artefato funciona tecnicamente, mas de analisar sistematicamente:

- O que aprendemos sobre design de interfaces para acessibilidade de dados?

- Que padrões emergiram dos cenários de avaliação técnica?
- Quais são as limitações da abordagem com IA Generativa?
- Que contribuições esta pesquisa oferece para a comunidade científica?

3.8 Cronograma de Execução

O planejamento para os próximos 12 meses foca na execução das Fases 5 e 6 (Avaliação e Reflexão) e na produção textual. O Quadro 1 detalha as atividades previstas até a defesa final.

Quadro 1 – Cronograma de Execução e Finalização da Dissertação

Atividades (Fase Final)	Trim. 1 2026	Trim. 2 2026	Trim. 3 2026	Trim. 4 2026
Ajustes pós-Qualificação (Metodologia DSR)	X			
Preparação do Gabarito Ouro (Classificação Manual)	X	X		
Execução do Experimento de Acurácia (IA)	X	X		
Avaliação factual das respostas geradas		X	X	
Avaliação de rastreabilidade e cenários de consulta		X	X	
Análise Estatística e Qualitativa dos Resultados		X	X	
Escrita de Artigo Científico (PROPOR 2026)		X	X	
Escrita Final da Dissertação (Resultados + Conclusão)			X	X
Revisão e Depósito				X
Defesa da Dissertação				X

Fonte: Produção da autora.

As atividades estão distribuídas da seguinte forma:

- **1º Trimestre 2026:** Refinamento do texto da proposta conforme feedback da banca, implementação de melhorias metodológicas, preparação do dataset de controle (Gabarito Ouro) para experimento de acurácia.
- **2º Trimestre 2026:** Execução dos testes técnicos para validação de acurácia, avaliação factual das respostas, verificação de rastreabilidade e execução de cenários representativos de consulta. Início paralelo da escrita de artigo científico visando a conferência PROPOR 2026.
- **3º Trimestre 2026:** Consolidação estatística e qualitativa dos dados obtidos na avaliação, redação dos capítulos finais da dissertação (Análise de Resultados e Conclusão), finalização e submissão do artigo científico.
- **4º Trimestre 2026:** Revisão final do texto completo da dissertação, submissão para a banca examinadora, defesa pública.

4

Estado da Arte

Este capítulo mapeia sistematicamente as pesquisas existentes na interseção entre Inteligência Artificial e dados parlamentares, com o objetivo de identificar o que já foi feito, onde estão as lacunas, e como este trabalho se posiciona em relação à literatura.


Optou-se pelo Mapeamento Sistemático da Literatura (MSL) em vez de uma revisão narrativa porque o escopo do tema é amplo e interdisciplinar — abrangendo PLN, dados abertos, transparência governamental e interação humano-dados —, o que exige um protocolo estruturado para evitar seleção tendenciosa de fontes ([KITCHENHAM, 2004](#)). A diferença entre MSL e revisão sistemática é relevante aqui: enquanto a revisão sistemática busca sintetizar evidências sobre uma intervenção específica, o mapeamento tem por objetivo caracterizar o espaço de pesquisa, identificar tendências e delimitar lacunas, o que é mais adequado para áreas emergentes como a aplicação de IA Generativa em contextos legislativos ([KITCHENHAM, 2004](#)).

O protocolo seguiu as diretrizes de Kitchenham ([KITCHENHAM, 2004](#)), estruturado em três fases: Planejamento, Execução e Análise.

4.1 Protocolo do Mapeamento Sistemático

O processo adotado seguiu as três fases críticas recomendadas pela literatura: Planejamento, Execução e Análise. Tal abordagem estruturada assegura o rigor na seleção dos estudos. A Figura 10 ilustra o fluxo de trabalho.

Figura 10 – Fases do Mapeamento Sistemático da Literatura



Fonte: Adaptado de Kitchenham (2004).

Para a organização e condução do mapeamento, utilizou-se a ferramenta *Parsifal*¹, que oferece suporte computacional para a aplicação dos critérios de seleção e extração de dados.

4.1.1 Planejamento

Nesta etapa, definiu-se a necessidade do mapeamento e o protocolo de pesquisa (BRETON et al., 2007). O objetivo central foi responder às questões de pesquisa detalhadas no Quadro 2, que orientaram a estratégia de busca.

¹ <<https://parsif.al/>>

Quadro 2 – Questões de Pesquisa do Mapeamento Sistemático

ID da Questão	Questões de Pesquisa
Q1:	Quais técnicas de Inteligência Artificial ou PLN são mais utilizadas na literatura para a análise de dados parlamentares abertos?
Q2:	Existem trabalhos que aplicam IA Generativa (LLMs) ou interfaces conversacionais (<i>chatbots</i>) para facilitar o acesso do cidadão a dados legislativos?
Q3:	Quais são as principais lacunas e desafios apontados pela literatura na democratização do acesso à informação parlamentar?
Q4:	Como a literatura trata interação humano-dados e acessibilidade de informação legislativa?

Fonte: Produção da autora.

Para responder a essas questões, foram definidos os campos de extração apresentados no Quadro 3.

Quadro 3 – Campos de Extração de Dados

Campo de Extração
Ano de Publicação
Técnica/Método de IA/PLN Utilizado
Uso de IA Generativa ou <i>Chatbot</i> ?
Contexto Legislativo (Nacional vs. Internacional)
Enfoque em Acessibilidade ou Interação Humano-Dados
Desafios/Lacunas Identificados

Fonte: Produção da autora.

Fontes de Busca:

Para esta pesquisa, a busca foi conduzida em cinco bases de dados de alto impacto internacional e nacional:

- **IEEE Xplore:** Base multidisciplinar de Engenharia e Computação
- **Scopus:** Indexador de citações com cobertura de múltiplas disciplinas
- **ACM Digital Library:** Publicações especializadas em Ciência da Computação
- **Web of Science (WoS):** Base multidisciplinar de alto fator de impacto, incluída para ampliar a cobertura de publicações internacionais em Ciências da Computação e Sistemas de Informação

- **SOL - Biblioteca Digital da SBC:** Repositório da Sociedade Brasileira de Computação (<https://sol.sbc.org.br/>) para capturar produção científica nacional relevante

O escopo temporal compreendeu o período de 2014 a 2026, refletindo a evolução das políticas de dados abertos no Brasil e a emergência recente de aplicações baseadas em IA Generativa.

Data da busca: Maio de 2026.

As palavras-chave e *strings* de busca utilizadas estão detalhadas nos Quadros 4 e 5.

Quadro 4 – Palavras-Chave da Busca

Palavras-Chave (PT)	Termos em Inglês
Dados Parlamentares	Parliamentary Data, Legislative Data, Plenary Sessions
IA Generativa	Generative Artificial Intelligence, LLM, Large Language Models
Análise de Discursos	Information Extraction, Text Analysis, Speech Mining
Dados Abertos	Open Government Data, Open Data
Interface Conversacional	Chatbot, Conversational AI, Dialog Systems
Acessibilidade de Dados	Data Accessibility, Data Literacy
Transparência Legislativa	Legislative Transparency, Open Parliament

Fonte: Produção da autora.

Quadro 5 – Strings de Busca (Conceituais)

String de Busca
(“Parliamentary Data”OR “Legislative Data”) AND (“Generative AI”OR “Large Language Models”OR “LLM”OR “Chatbot”) (“Open Government Data”) AND (“Natural Language Processing”OR “NLP”OR “Text Mining”) AND (“Parliament”OR “Legislature”) (“Legislative Transparency”) AND (“Artificial Intelligence”OR “Machine Learning”) (“Data Accessibility”) AND (“Chatbot”OR “Conversational AI”)

Fonte: Produção da autora.

O Quadro 6 apresenta os critérios estabelecidos para filtrar os trabalhos.

Quadro 6 – Critérios de Inclusão e Exclusão

Critérios de Inclusão	Critérios de Exclusão
CI1: Aborda IA/PLN/LLM para dados governamentais ou parlamentares.	CE1: Estudos duplicados em múltiplas bases.
CI2: Discute transparência ou participação política em contexto legislativo.	CE2: Literatura cinzenta ou não revisada por pares.
CI3: Aborda dados abertos em contexto público/legislativo.	CE3: Estudos secundários (revisões de revisões).
CI4: Investiga interação humano-dados ou acessibilidade.	CE4: Artigos que abordam exclusivamente aspectos legais/políticos sem componente técnico.


Fonte: Produção da autora.

4.1.2 Execução e Resultados

A execução seguiu o protocolo estabelecido, compreendendo identificação, seleção, elegibilidade e inclusão. A busca inicial nas cinco bases retornou 47 estudos: IEEE Xplore (0), Scopus (6), ACM Digital Library (39), Web of Science (2) e SOL/SBC (0). A ausência de retorno na SOL/SBC e no IEEE para as *strings* aplicadas foi registrada como resultado negativo esperado — dado o recorte temporal e temático definido — e não implica ausência de produção nacional na área. Após remoção de 2 duplicatas e aplicação dos critérios de inclusão/exclusão (triagem por título e resumo, seguida de leitura de texto completo), selecionaram-se 7 trabalhos primários como mais relevantes para contextualizar esta dissertação.

O fluxo de seleção é detalhado na Figura 11.

Figura 11 – Fluxograma de seleção dos estudos (PRISMA-ScR)



Fonte: Produção da autora.

4.2 Análise Temática dos Resultados

Diferentemente de uma mera listagem de resumos, a análise temática busca identificar padrões, convergências e divergências entre os trabalhos, conectando-os explicitamente aos objetivos desta pesquisa e às lacunas identificadas.

4.2.1 Tema 1: IA Generativa para Estruturação de Dados Legislativos

Os trabalhos de Colombo et al. (2025), Colombo (2024) e Von Lucke e Frank (2025) convergem em um ponto fundamental: **modelos de linguagem generativa conseguem, quando bem orientados, transformar dados legislativos complexos em estruturas de conhecimento compreensíveis.**

Especificidades de cada trabalho:

- [Colombo, Bernasconi e Ceri \(2025\)](#) propõem um *pipeline* assistido por LLM para construção automática de *knowledge graphs* da legislação italiana. O trabalho demonstra que IA pode extrair entidades jurídicas (leis, artigos, interpretações) de textos legislativos não estruturados e organizá-las em grafos semânticos. Limitação: foca em estruturação técnica, não em acessibilidade para cidadãos.
- [Colombo \(2024\)](#) aprofunda a discussão anterior, explorando explicitamente a sinergia entre grafos de conhecimento e LLMs para *monitoring* de sistemas legislativos — rastreamento de como leis evoluem. Contribuição: metodologia de versionamento de legislação.
- [Lucke e Frank \(2025\)](#) analisam a aplicação prática de ferramentas como ChatGPT em parlamentos, levantando questões críticas sobre potencialidades (rapidez, síntese) e riscos (alucinação, imprecisão factual). Este trabalho é particularmente relevante pois trata de LLMs em contexto parlamentar e aponta desafios de confiabilidade.

Padrão Emergente: LLMs conseguem estruturar legislação, mas confiabilidade das respostas é crítica. A literatura aponta a necessidade de validação humana.

Conexão com Este Trabalho: Esta pesquisa avança ao (1) avaliar tecnicamente a confiabilidade das respostas geradas, (2) combinar estruturação de dados com interfaces visual e conversacional, (3) focar em dados parlamentares brasileiros.

4.2.2 Tema 2: Interfaces Conversacionais para Acessibilidade

[Kim et al. \(2025\)](#) descrevem o “LegisFlow”, uma interface conversacional com “consciência temporal” para pesquisa jurídica na Coreia. Este trabalho é diretamente alinhado aos objetivos desta dissertação.

Especificidades:

- Implementa chatbot para consultas em linguagem natural sobre legislação
- Incorpora noção de tempo (como leis mudaram ao longo do tempo)
- Avalia usabilidade com usuários reais
- Contexto: público coreano sem expertise jurídica

Padrão Emergente: Interfaces conversacionais reduzem barreira de entrada para acesso legislativo. Dimensão temporal é importante.

Conexão com Este Trabalho: Este trabalho dialoga com LegisFlow ao adaptar a ideia de consulta conversacional para o contexto brasileiro/português, combinando agente conversacional com *dashboard* visual e avaliação técnica de respostas baseadas em dados parlamentares.

4.2.3 Tema 3: Análise de Dados Legislativos com PLN Clássico

Mendes, Ali e Charalabidis (2025) utilizam *Topic Modeling* (técnica clássica de PLN, não IA Generativa) para analisar Pedidos de Acesso à Informação brasileiros. BOJĀRS et al. (2019) apresentam “LinkedSaeima”, um dataset de dados abertos conectados (*Linked Data*) do parlamento da Letônia.

Padrão Emergente: Abordagens clássicas de PLN conseguem extrair insights, mas requerem expertise técnica. IA Generativa oferece potencial para democratizar acesso.

Conexão com Este Trabalho: Enquanto esses trabalhos usam técnicas sofisticadas (Topic Modeling, RDF/Linked Data), o foco desta pesquisa é em acessibilidade para cidadãos não-especialistas. Essa é a lacuna que esta dissertação endereça.

4.2.4 Tema 4: Desafios e Lacunas na Literatura

Papadopoulos e Charalabidis (2020) aplicam PLN para extrair *insights* de documentos de estratégias nacionais de IA, focando em mineração de textos governamentais. O trabalho, embora não focado em legislação, aponta desafios gerais na análise de textos públicos.

Lacunas Identificadas Pela Literatura:

1. **Falta de foco em acessibilidade para cidadãos:** A maioria dos trabalhos trata estruturação técnica ou análise especializada, não democratização de acesso.
2. **Confiabilidade de LLMs não é plenamente abordada:** Von Lucke e Frank apontam riscos, mas nenhum trabalho apresenta estratégia sistemática de validação.
3. **Contexto brasileiro pouco explorado:** Dos 7 trabalhos, apenas Mendes et al. e Bojārs et al. abordam contexto nacional (coreano, letão, brasileiro). Falta pesquisa em português sobre legislação brasileira com IA Generativa.

4. **Avaliação de respostas e rastreabilidade ainda é pouco explorada:** A literatura aponta riscos de alucinação e imprecisão factual em LLMs, mas ainda há espaço para protocolos de avaliação voltados à coerência entre respostas geradas e dados legislativos de origem.
5. **Combinação Dashboard + Chatbot não é explorada:** Trabalhos tratam uma ou outra modalidade, raramente ambas integradas.

4.3 Lacunas Identificadas e Contribuições Desta Pesquisa

Com base na análise sistemática, identificam-se as seguintes lacunas que esta pesquisa propõe-se a preencher:

1. Lacuna 1: Falta de foco em acessibilidade para cidadãos não-especialistas

- **O que a literatura oferece:** Técnicas sofisticadas de IA para estruturação de legislação
- **O que está faltando:** Investigação de como essas técnicas podem ser comunicadas de forma compreensível ao cidadão médio
- **Como esta pesquisa aborda:** Design deliberado de interfaces acessíveis (Dashboard + Chatbot) e avaliação técnica de sua capacidade de organizar e consultar dados parlamentares

2. Lacuna 2: Confiabilidade e validação de respostas IA não é sistemática

- **O que a literatura oferece:** Identificação de riscos (alucinação, imprecisão)
- **O que está faltando:** Metodologia sistemática de validação antes de deploy em contexto cívico
- **Como esta pesquisa aborda:** Avaliação técnica rigorosa por meio de comparação com gabarito de referência, análise factual das respostas e verificação de rastreabilidade

3. Lacuna 3: Contexto e idioma brasileiros pouco explorados

- **O que a literatura oferece:** Exemplos internacionais (Itália, Coreia, Letônia)
- **O que está faltando:** Pesquisa em português sobre Senado Federal brasileiro
- **Como esta pesquisa aborda:** Dados reais da API do Senado Federal, legislação e dados parlamentares em língua portuguesa, contexto brasileiro até então ausente na literatura

4. Lacuna 4: Avaliação factual e rastreável de respostas em linguagem natural

- **O que a literatura oferece:** Discussões sobre potencial de LLMs e riscos de imprecisão
- **O que está faltando:** Protocolos explícitos para verificar se respostas geradas estão ancoradas em dados legislativos oficiais
- **Como esta pesquisa aborda:** Avaliação das respostas do AgentAI por cenários de consulta, comparação com dados oficiais e análise de rastreabilidade

5. Lacuna 5: Integração de múltiplas modalidades de interação

- **O que a literatura oferece:** Dashboards OU Chatbots, raramente ambos
- **O que está faltando:** Investigação de como diferentes modalidades se complementam para diferentes usuários
- **Como esta pesquisa aborda:** Design deliberado de Dashboard + Chatbot com avaliação de como ambos contribuem ao acesso democrático

4.4 Conclusões do Mapeamento Sistemático

O mapeamento revela um campo em formação: trabalhos sobre IA Generativa aplicada a legislação são recentes (predominantemente pós-2022), concentrados em contextos europeus e asiáticos, e orientados predominantemente à estruturação técnica — não à acessibilidade para cidadãos comuns. A ausência de trabalhos em português sobre dados parlamentares brasileiros com LLMs, combinada à falta de protocolos sistemáticos para avaliação de rastreabilidade e qualidade factual de respostas geradas, configura o espaço em que esta dissertação se insere.

É importante registrar uma limitação do próprio mapeamento: o corpus de 7 estudos primários selecionados é pequeno para afirmações categóricas sobre o estado da área, o que pode refletir tanto a emergência da temática quanto eventuais restrições das *strings* de busca utilizadas. Futuras iterações desta pesquisa poderiam ampliar a busca com *snowballing* a partir dos estudos incluídos, capturando trabalhos relevantes não indexados nas bases consultadas.

5

Desenvolvimento e Resultados Preliminares

Neste capítulo, detalha-se o estágio atual do projeto e o planejamento para a conclusão da dissertação. Como esta proposta é apresentada em um estágio avançado do mestrado, a fase de construção do artefato (aplicação *web*, *backend* e integração com IA) já se encontra concluída (Fase de Design e Desenvolvimento), permitindo que os esforços futuros se concentrem na validação científica (Fase de Avaliação) e na escrita final.

5.1 Estágio Atual do Desenvolvimento

Sob a ótica da *Design Science Research*, o artefato computacional proposto já atingiu um nível de maturidade funcional que permite a execução de testes. As seguintes etapas do ciclo de pesquisa foram concluídas:

- **Identificação do Problema e Motivação:** Mapeamento das dificuldades de acesso aos dados brutos do Senado Federal e definição da relevância para o controle social e participação democrática.
- **Definição da Solução:** Projeto de uma arquitetura baseada em Dashboard (visualização) + Chatbot (interação conversacional) para reduzir barreiras cognitivas ao acesso legislativo.
- **Design e Desenvolvimento:** Implementação completa dos módulos de coleta (ETL via API Senado), análise (Mistral 7B Instruct em ambiente local) e interface (*Streamlit* com *Plotly*), resultando em um protótipo funcional capaz de processar dados reais.
- **Demonstração:** Validação técnica preliminar mostrando que o artefato consegue processar dados parlamentares e gerar respostas coerentes.

A aplicação encontra-se implantada em ambiente de homologação, processando dados da API do Senado Federal e respondendo a consultas em linguagem natural. Esse estágio habilita

a fase de avaliação técnica do artefato, com foco em qualidade dos dados processados, acurácia da classificação temática, qualidade factual das respostas e rastreabilidade das informações geradas.

5.2 Arquitetura e Componentes do Artefato

5.2.1 Camada de Dados: Coleta e Processamento

A coleta de dados é efetuada via API de Dados Abertos do Senado Federal ([Senado Federal do Brasil, s.d.](#)). O processo de ETL (*Extract, Transform, Load*) é automatizado e inclui:

- **Extração:** Utilização da biblioteca *Requests* ([Python Software Foundation, 2024](#)) para requisição de dados brutos (XML/JSON) dos *endpoints* da API Swagger, mapeando informações sobre sessões legislativas, discursos, votações e senadores.
- **Transformação:** Conversão e limpeza dos dados utilizando *Pandas* ([Pandas Development Team, 2023](#)), normalizando formatos, removendo duplicatas, preenchendo valores ausentes e estruturando informações em tabelas relacionais otimizadas para análise.
- **Carregamento:** Armazenamento em banco de dados local (SQLite) para consulta rápida durante operações de Chatbot e Dashboard.

Este pipeline é executado em intervalos regulares (por exemplo, diariamente) para manter dados atualizados.

5.2.2 Camada de Inteligência: Análise com Mistral 7B

O núcleo analítico utiliza o modelo Mistral 7B Instruct ([Mistral AI, 2024](#)), executado em ambiente local. A escolha de Mistral 7B em vez de APIs proprietárias (como Google Gemini ou OpenAI GPT-4) justifica-se por:

1. **Privacidade e Soberania:** O modelo roda localmente, garantindo que dados legislativos brasileiros não sejam transmitidos para servidores externos de terceiros.
2. **Replicabilidade:** Por ser *open-source*, permite que outros pesquisadores reproduzam exatamente a pesquisa e validem os resultados de forma independente.
3. **Custo:** Elimina custos operacionais de API, tornando a solução sustentável para pesquisa acadêmica e possível adoção por organizações civis.
4. **Performance Adequada:** Apesar de menor em parâmetros que os grandes modelos proprietários, o Mistral 7B Instruct apresenta desempenho competitivo em tarefas de

compreensão e geração de linguagem (JIANG et al., 2023); sua adequação ao domínio legislativo em português é uma das questões que esta dissertação se propõe a avaliar.

O modelo é utilizado para duas funções críticas:

- **Classificação Temática:** Engenharia de *prompts* estruturados instrui o modelo a categorizar discursos legislativos em temas predefinidos (Saúde, Educação, Infraestrutura, Segurança, etc.). A classificação permite organização e análise dos debates por assunto.
- **Motor de Resposta (RAG Simplificado):** O módulo recebe perguntas do usuário em linguagem natural via Chatbot, recupera dados relevantes do banco de dados estruturado (usando busca estruturada por palavras-chave sobre a base local), e instrui o Mistral 7B a gerar respostas contextualizadas, didáticas e alinhadas aos dados reais.

5.2.3 Camada de Apresentação: Interfaces Acessíveis

Para materializar o acesso democrático aos dados, desenvolveu-se uma interface *web* utilizando o *framework* *Streamlit* (Streamlit Inc., 2024), oferecendo dois modos de interação complementares:

5.2.3.1 Dashboard Visual

Gráficos interativos gerados com *Plotly* (Plotly Technologies Inc., 2024) permitem exploração visual de tendências legislativas. O design segue o mantra de Shneiderman (SHNEIDERMAN, 1996): "primeiro o panorama geral, depois zoom e filtros, e então detalhes sob demanda".

Exemplos de visualizações disponíveis:

- Tendências de votação ao longo do tempo (linha temporal)
- Distribuição de votos por tema (gráfico de barras)
- Padrões de voto de senadores específicos (matriz ou radar)
- Comparação entre posições de diferentes grupos parlamentares (gráficos comparativos)

O Dashboard permite que usuários explorem livremente, filtrem por tema, senador ou período, e identifiquem padrões visuais em dados legislativos.

O uso do Streamlit é uma escolha compatível com o estágio de prototipação científica do artefato, pois permite rápida construção de interfaces interativas para análise de dados. Entretanto, reconhece-se que o framework possui limitações para uso em produção em larga escala,

especialmente em autenticação, controle fino de permissões, escalabilidade e separação entre camadas de serviço. Assim, neste trabalho, o Streamlit é tratado como tecnologia de prototipação e demonstração do artefato, não como decisão definitiva para implantação institucional.

5.2.3.2 Chatbot Conversacional

Interface de *chat* que abstrai a complexidade dos dados legislativos, permitindo consultas em linguagem natural:

Exemplos de perguntas que o usuário pode fazer:

- "Como votou o Senador [Nome] sobre educação?"
- "Qual foi o resultado da votação em [Projeto de Lei]?"
- "Quais são os temas mais debatidos em 2025?"
- "Como o partido [X] votou no projeto sobre saúde?"
- "Qual senador votou diferente de seu partido nesta votação?"

O Chatbot traduz perguntas em linguagem comum para operações sobre o banco de dados, recupera as informações relevantes e retorna respostas em linguagem natural acessível a cidadãos sem expertise legislativa ou tecnológica. A Figura 12 ilustra a interface conversacional em operação com dados reais do Senado Federal.

Figura 12 – Interface do Agente Conversacional (Chatbot) do AgentAI



Fonte: Produção da autora.

5.3 Fluxo de Funcionamento do Sistema

O sistema opera conforme descrito abaixo:

1. **Inicialização:** Aplicação *Streamlit* carrega dados pré-processados do banco de dados local.

2. **Interação Usuário - Dashboard:** Usuário pode explorar Dashboard sem necessidade de entrada, aplicando filtros interativos para ver visualizações customizadas.
3. **Interação Usuário - Chatbot:** Usuário digita pergunta em linguagem natural.
4. **Processamento:**
 - Sistema faz *retrieval* de dados relevantes (busca estruturada por palavras-chave sobre a base local)
 - Constrói contexto com os dados recuperados
 - Instrui Mistral 7B com *prompt* que inclui: pergunta do usuário, contexto de dados e instruções para responder de forma didática
5. **Resposta:** Mistral 7B gera resposta em linguagem natural, citando quais dados foram utilizados.
6. **Exibição:** Resposta é exibida no Chatbot. Usuário pode fazer pergunta de acompanhamento.

5.4 Dados Legislativos Utilizados

O artefato processa dados da API de Dados Abertos do Senado Federal, incluindo:

- **Senadores:** Nomes, partidos, estados, contatos
- **Sessões Plenárias:** Datas, tipo (ordinária, extraordinária, etc.)
- **Discursos:** Texto completo, senador autor, data, tema (quando disponível)
- **Votações:** Descrição da matéria votada, resultado, votos individuais de cada senador

Os dados cobrem o período de 2024 a 2026 e permitem a investigação de padrões legislativos contemporâneos. Esse recorte temporal poderá ser ampliado na etapa final da pesquisa, conforme a disponibilidade da API e os limites de processamento do ambiente local.

5.5 Status de Conclusão das Fases DSR

Conforme a metodologia Design Science Research (Cap. 3), o projeto encontra-se no seguinte estágio:

Quadro 7 – Progresso das Fases de Design Science Research

Fase DSR	Status	Descrição
1. Identificação do Problema	Concluída	Problema definido, fundamentado em literatura
2. Objetivos da Solução	Concluída	Objetivos do artefato claramente especificados
3. Design e Desenvolvimento	Concluída	Artefato implementado e funcional
4. Demonstração	Concluída	Artefato operacional em ambiente de homologação
5. Avaliação	<i>Em Execução</i>	Testes técnicos, factuais e de rastreabilidade planejados (Trim. 2-3)
6. Reflexão e Aprendizados	<i>Planejada</i>	A executar após fase de avaliação (Trim. 3-4)

Fonte: Produção da autora.

5.6 Cronograma de Execução da Dissertação

O planejamento para os próximos 12 meses foca na fase de **Avaliação rigorosa** (garantir rigor científico) e na produção textual final. O Quadro 8 detalha as atividades previstas até a defesa final, planejada para janeiro de 2027.

Quadro 8 – Status e Planejamento das Fases Finais da Dissertação

Atividades (Fase Final)	Trim. 1 2026	Trim. 2 2026	Trim. 3 2026	Trim. 4 2026
Ajustes pós-Qualificação (Metodologia DSR)	X			
Preparação do Gabarito Ouro (Classificação Manual)	X	X		
Execução do Experimento de Acurácia (IA)	X	X		
Avaliação factual das respostas geradas		X	X	
Avaliação de rastreabilidade e cenários de consulta		X	X	
Análise Estatística e Qualitativa dos Resultados		X	X	
Escrita de Artigo Científico (PROPOR 2026)		X	X	
Escrita Final da Dissertação (Resultados + Conclusão)			X	X
Revisão e Depósito				X
Defesa da Dissertação				X

Fonte: Produção da autora.

As atividades estão distribuídas da seguinte forma:

- **1º Trimestre 2026 (Abr-Jun):** Refinamento do texto da proposta conforme feedback da banca examinadora, implementação de melhorias metodológicas (conforme críticas

do parecer), preparação do *dataset* de controle (Gabarito Ouro) para o experimento de acurácia.

- **2º Trimestre 2026 (Jul-Set):** Execução dos testes técnicos de acurácia, avaliação factual das respostas do agente conversacional, verificação de rastreabilidade e execução de cenários representativos de consulta. Início paralelo da escrita de artigo científico visando a conferência PROPOR 2026.
- **3º Trimestre 2026 (Out-Dez):** Consolidação estatística e qualitativa dos dados obtidos na avaliação, redação dos capítulos de Análise de Resultados e Discussão, finalização e submissão de artigo científico.
- **4º Trimestre 2026-Q1 2027 (Jan):** Revisão final do texto completo da dissertação, submissão para a banca examinadora, realização de defesa pública.

5.7 Próximas Ações Imediatas (Próximas 8 Semanas)

1. Implementar melhorias apontadas pelo parecer de qualificação
2. Finalizar dataset de controle para experimento de acurácia
3. Preparar o conjunto de cenários representativos de consulta
4. Executar primeira rodada de teste técnico (IA vs. Gabarito)
5. Documentar detalhes finais do protocolo de avaliação técnica

6

Considerações Parciais e Trabalhos Futuros

Este capítulo apresenta uma avaliação honesta do estágio atual da pesquisa: o que foi concluído, o que permanece em aberto, quais desafios emergiram durante o desenvolvimento e o que se espera produzir na fase final. O objetivo não é apenas reportar progresso, mas identificar onde os riscos metodológicos ainda precisam ser mitigados antes da defesa.

6.1 Progresso do Ciclo de Design Science Research

Conforme a metodologia DSR adotada, o ciclo de pesquisa estrutura-se em seis fases. À data desta proposta (maio de 2026), quatro fases encontram-se concluídas ou em conclusão avançada:

1. **Fase 1 - Identificação do Problema: Concluída.** Mapeamento das dificuldades de acesso aos dados parlamentares e definição da relevância para transparência e participação cívica foram estabelecidas.
2. **Fase 2 - Objetivos da Solução: Concluída.** Especificação clara dos objetivos que o artefato deve atingir (redução de barreiras cognitivas, interface acessível, múltiplas modalidades) foi documentada.
3. **Fase 3 - Design e Desenvolvimento: Concluída.** O artefato AgentAI encontra-se tecnicamente funcional, integrando coleta de dados (API Senado), processamento com IA Generativa (Mistral 7B local), e interfaces acessíveis (Dashboard + Chatbot).
4. **Fase 4 - Demonstração: Concluída.** A aplicação encontra-se em ambiente de homologação, processando dados reais da API do Senado Federal e respondendo a consultas em linguagem natural.

5. **Fase 5 - Avaliação: Em Execução.** Conforme cronograma (Capítulo 3, Quadro 1), iniciaram-se preparações para testes técnicos, avaliação factual das respostas e verificação de rastreabilidade.
6. **Fase 6 - Reflexão e Aprendizados: Planejada para Q3/Q4 2026.** Documentação do conhecimento científico gerado será realizada após conclusão dos testes.

6.2 Resultados Preliminares do Artefato

Do ponto de vista técnico e funcional, o artefato demonstrou viabilidade nas seguintes dimensões:

6.2.1 Viabilidade Técnica

A solução computacional materializa-se como uma aplicação *web* funcional que integra:

- **Coleta de Dados:** Pipeline de ETL automatizado que processa dados da API do Senado Federal com sucesso, utilizando Python e *Pandas* para estruturação.
- **Processamento com IA:** Modelo Mistral 7B Instruct, rodando localmente, consegue executar classificação temática de discursos legislativos e gerar respostas em linguagem natural alinhadas aos dados reais.
- **Interfaces:** Aplicação Streamlit com Dashboard interativo (*Plotly*) e Chatbot conversacional funcionam de forma estável em ambiente de homologação.
- **Performance:** O sistema processa um corpus legislativo realista (sessões do Senado de 2024-2026) em ambiente local, com latência preliminarmente adequada ao estágio de prototipação.

6.2.2 Verificação Funcional Preliminar

Antes da fase de avaliação formal, o artefato passou por uma verificação funcional conduzida pela pesquisadora e pelo orientador, com foco exclusivo em identificar falhas de execução — não em medir desempenho. Nessa etapa, confirmou-se que: o pipeline de ETL processa e armazena dados da API sem perda de campos essenciais; o modelo Mistral 7B Instruct gera classificações temáticas para os discursos ingeridos; e a interface Streamlit responde a consultas sem erros de execução em ambiente local.

É importante distinguir essa verificação funcional da avaliação científica planejada para as próximas etapas. Saber que o sistema funciona não é o mesmo que saber se ele funciona bem o suficiente para o propósito declarado. A avaliação sistemática — com gabarito de referência

anotado por dois avaliadores, métricas quantitativas e comparação com baseline — é o que determinará se a hipótese formulada se sustenta ou não.

6.3 Desafios e Limitações Identificadas

A execução das fases anteriores revelou desafios que constituem ameaças à validade da pesquisa e que serão tratados ou documentados nas próximas etapas:

6.3.1 Desafios Técnicos

- **Ambiguidade Semântica em Jargões Legislativos:** O modelo Mistral 7B, apesar de competente em tarefas genéricas, demonstrou limitações na interpretação de termos específicos do domínio legislativo (ex: "desarquivamento", "tramitação em urgência", "voto por delegação"). Em alguns casos, isso resultou em classificações genéricas ou imprecisas.

Plano de Mitigação: Engenharia de *prompt* avançada com Few-Shot Learning (fornecer exemplos ao modelo de cada jargão) e possível fine-tuning limitado do modelo.

- **Alucinações e Opacidade dos LLMs:** A natureza "caixa preta" (*black box*) de modelos de linguagem impõe um desafio para confiabilidade das respostas. Observou-se ocasionalmente que o Chatbot gera informações que parecem plausíveis mas não estão fundamentadas nos dados reais.

Plano de Mitigação: Implementação de mecanismo de rastreabilidade: toda resposta do Chatbot cita quais dados (senador, data, votação) foram utilizados, permitindo verificação humana.

- **Limitações de Infraestrutura:** Restrições de memória e processamento em ambiente local impactam volume de dados que podem ser processados simultaneamente. Em alguns casos, há lentidão quando processando sessões legislativas muito longas.

Plano de Mitigação: Otimização de código, caching de resultados, e possível upgrade de hardware.

6.3.2 Desafios Metodológicos

- **Construção de Gabaritos de Referência:** Avaliar classificação temática e respostas em linguagem natural exige a construção de conjuntos de referência consistentes. Há risco de subjetividade na definição das categorias e respostas esperadas.

Plano de Mitigação: Documentação explícita dos critérios de anotação, revisão pelo orientador e registro dos casos ambíguos encontrados durante a avaliação.

- **Validade dos Cenários de Consulta:** Os cenários usados para avaliar o agente conversacional precisam representar perguntas relevantes sobre dados parlamentares, sem depender de participantes externos.

Plano de Mitigação: Definição de cenários com base nas funcionalidades reais do artefato, nos dados disponíveis na API do Senado e nas lacunas identificadas no mapeamento sistemático.

6.4 Contribuições Esperadas da Pesquisa

Conforme apontado pelo Mapeamento Sistemático da Literatura (Capítulo 4), esta pesquisa posiciona-se para fazer contribuições em áreas onde há lacunas identificadas:

6.4.1 Contribuições Científicas

1. **Conhecimento sobre Design de Interfaces para Acessibilidade de Dados Legislativos:** Investigação empiricamente fundamentada de como combinar múltiplas modalidades (Dashboard visual + Chatbot conversacional) melhora acesso democrático a informação.
2. **Compreensão de Efetividade Técnica de IA Generativa em Contextos Cívicos:** Avaliação rigorosa de como IA Generativa local pode apoiar classificação temática, consulta em linguagem natural e geração de respostas rastreáveis sobre dados parlamentares.
3. **Metodologia para Validação de Confiabilidade de LLMs em Contextos Críticos:** Documentação de estratégia de validação de respostas IA contra dados reais, aplicável a outros domínios além legislação.
4. **Conhecimento Localizado (Brasil/Português):** Investigação situada no contexto brasileiro, em língua portuguesa, contribuindo para uma lacuna ainda pouco explorada na literatura sobre IA Generativa e dados parlamentares.

6.4.2 Contribuições Práticas

1. **Artefato Funcional:** Protótipo funcional que pode subsidiar futuras aplicações por pesquisadores, organizações civis e instituições interessadas em transparência legislativa.
2. **Código Aberto:** Publicação do código-fonte no GitHub permite que outros pesquisadores repliquem, modifiquem e estendam a solução.
3. **Guidelines de Design:** Recomendações práticas para design de interfaces cívicas que combinam IA com acessibilidade.

6.5 Trabalhos Futuros: Fases de Avaliação e Conclusão

As fases restantes do ciclo DSR — Avaliação e Reflexão — constituem o núcleo científico da dissertação. É nelas que a hipótese será testada e o conhecimento gerado. O cronograma detalhado das atividades está descrito no Capítulo 3, Quadro 1; registra-se aqui apenas a priorização das atividades críticas:

A construção do protocolo de anotação e do gabarito de referência precede qualquer execução de experimento — sem um gabarito metodologicamente sólido, as métricas de acurácia e F1 carecem de validade. Em seguida, a execução dos testes de classificação com baseline comparativo permitirá dimensionar o real ganho do uso do LLM. Por fim, a avaliação de rastreabilidade e os cenários de consulta fecharão o ciclo de evidências sobre a hipótese central.

6.6 Perspectivas de Conclusão

A fase que determina o valor científico desta dissertação ainda está por ser executada: a avaliação rigorosa do artefato. O desenvolvimento do AgentAI demonstrou viabilidade técnica, mas viabilidade não é o mesmo que efetividade — e é exatamente a distinção entre essas duas condições que a fase de avaliação precisa endereçar.

O principal risco no horizonte imediato é a construção do gabarito de referência: se os critérios de anotação não forem documentados com precisão antes do início da classificação, a avaliação perde credibilidade metodológica. Por isso, a primeira atividade do próximo trimestre é a elaboração do protocolo de anotação — incluindo definição operacional das categorias temáticas, exemplos de casos limítrofes e regras de desempate — antes que qualquer discurso seja anotado.

Se as fases de Avaliação e Reflexão forem executadas com o rigor descrito neste documento, o trabalho poderá contribuir com dois resultados concretos para a comunidade: um protocolo replicável para avaliação de sistemas RAG sobre dados parlamentares em português, e um conjunto de dados anotados sobre discursos do Senado Federal que pode ser disponibilizado para pesquisas futuras. Esses resultados têm valor independente do desempenho absoluto do modelo — porque documentam tanto o que funciona quanto o que não funciona, e ambos são contribuições científicas legítimas.

Próximas Ações Imediatas:

1. Refinamento final do documento de proposta conforme feedback da banca examinadora
2. Preparação do dataset de controle (Gabarito Ouro) para experimento de acurácia
3. Preparação de cenários representativos de consulta
4. Implementação de melhorias metodológicas apontadas por este parecer

5. Execução da primeira rodada de avaliação técnica (próximas 8 semanas)

Referências

Arquivo Nacional. *Dados Abertos*. 2023. Acesso em: maio de 2026. Disponível em: <https://www.gov.br/arquivonacional/>. Citado na página 13.

BOBBIO, N. *O Futuro da Democracia*. São Paulo: Companhia das Letras, 1986. Citado na página 9.

BOJĀRS, U. et al. Linkedsaime: A linked open dataset of latvia's parliamentary debates. In: *Proceedings of the 15th SEMANTiCS Conference*. [S.l.]: Springer, 2019. v. 11702, p. 50–56. Citado na página 40.

BRERETON, P. et al. Lessons from applying the systematic literature review process within the software engineering domain. *Journal of Systems and Software*, v. 80, n. 4, p. 571–583, 2007. Citado na página 34.

BRITO, L.; FRANÇA, J.; VIVACQUA, A. Literacia de dados para todos: Desafios da educação em computação na era da interação humano-dados. In: *I Seminário dos Grandes Desafios da Educação em Computação no Brasil*. São Paulo: [s.n.], 2024. Citado 2 vezes nas páginas 20 e 27.

COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960. Citado na página 30.

COLOMBO, A. *Knowledge Graphs and Large Language Models for Legislative Monitoring*. 2024. Preprint. Citado na página 39.

COLOMBO, A.; BERNASCONI, A.; CERI, S. An llm-assisted etl pipeline to build a high-quality knowledge graph of the italian legislation. *Information Processing & Management*, v. 62, n. 4, p. 104082, 2025. Citado na página 39.

HORNUNG, H. R.; PEREIRA, R.; BARANAUSKAS, M. C. C. Challenges for human-data interaction – a semiotic perspective. In: *Human-Computer Interaction: Part I, HCII 2015*. Cham: Springer, 2015. (Lecture Notes in Computer Science, v. 9169), p. 37–48. Citado 4 vezes nas páginas 10, 20, 23 e 27.

ISOTANI, S.; BITTENCOURT, I. I. *Dados Abertos Conectados*. São Paulo: Novatec, 2015. Citado na página 14.

JIANG, A. Q. et al. Mistral 7b. *arXiv preprint arXiv:2310.06825*, 2023. Disponível em: <https://arxiv.org/abs/2310.06825>. Disponível em: <https://arxiv.org/abs/2310.06825>. Citado 3 vezes nas páginas 18, 27 e 45.

JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.: s.n.], 2023. Draft. Citado na página 15.

KIM, J. et al. Legisflow: Enhancing korean legal research with temporal-aware llm interfaces. In: *Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology*. [S.l.: s.n.], 2025. p. 1–29. Citado na página 39.

KITCHENHAM, B. *Procedures for Performing Systematic Reviews*. [S.l.], 2004. Citado na página 33.

LEE, S.; KIM, S. H.; KWON, B. C. Vlat: Development of a visualization literacy assessment test. *IEEE Transactions on Visualization and Computer Graphics*, v. 23, n. 1, p. 551–560, 2017. Citado 4 vezes nas páginas 10, 19, 23 e 26.

LEVITSKY, S.; ZIBLATT, D. *Como as Democracias Morrem*. Rio de Janeiro: Zahar, 2018. Citado na página 9.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2020. v. 33, p. 9459–9474. Citado na página 17.

LUCKE, J. von; FRANK, A. Approaching the integration of large language models in the parliamentary workspace. *Frontiers in Political Science*, v. 7, p. 1625394, 2025. Citado na página 39.

MARQUES, R. M.; LAIPELT, R. d. C. F. Inteligência artificial generativa e desafios informacionais. *Ciência da Informação em Revista*, v. 10, 2023. Citado na página 16.

MENDES, M.; ALI, M.; CHARALABIDIS, Y. Analyzing the freedom of information requests using topic modeling: Towards user-driven open government data ecosystems. In: *Proceedings of the International Conference on Theory and Practice of Electronic Governance*. [S.l.: s.n.], 2025. Citado na página 40.

Mistral AI. *Mistral 7B Instruct: A High-Quality Open-Source Language Model*. 2024. Acesso em: maio de 2026. Disponível em: <<https://mistral.ai/>>. Citado 4 vezes nas páginas 10, 16, 25 e 44.

OLIVEIRA, G.; CKAGNAZAROFF, I. Transparência no poder legislativo brasileiro: Um desafio para a democracia. *Revista de Administração Pública*, v. 56, n. 2, p. 145–165, 2022. Citado 3 vezes nas páginas 9, 10 e 23.

Open Knowledge Brasil. *Guia de Dados Abertos*. 2024. Acesso em: maio de 2026. Disponível em: <<https://www.ok.org.br/>>. Citado 2 vezes nas páginas 9 e 13.

Pandas Development Team. *Pandas: Python Data Analysis Library*. 2023. Acesso em: maio de 2026. Disponível em: <<https://pandas.pydata.org/>>. Citado 2 vezes nas páginas 25 e 44.

PAPADOPOULOS, T.; CHARALABIDIS, Y. What do governments plan in the field of artificial intelligence? analysing national ai strategies using nlp. In: *Proceedings of the 13th International Conference on Theory and Practice of Electronic Governance*. [S.l.: s.n.], 2020. Citado na página 40.

PEFFERS, K. et al. A design science research methodology for information systems research. *Journal of Management Information Systems*, v. 24, n. 3, p. 45–77, 2007. Citado 2 vezes nas páginas 18 e 22.

PIMENTEL, M.; FILIPPO, D.; SANTOS, T. M. Design science research: pesquisa científica atrelada ao design de artefatos. *RE@D - Revista de Educação a Distância e Elearning*, v. 3, n. 1, p. 1–20, 2020. Citado 2 vezes nas páginas 18 e 22.

Plotly Technologies Inc. *Plotly: The Open-Source Graphing Library for Python*. 2024. Acesso em: maio de 2026. Disponível em: <<https://plotly.com/python/>>. Citado 2 vezes nas páginas 25 e 45.

Python Software Foundation. *Requests: HTTP Library for Python*. 2024. Acesso em: maio de 2026. Disponível em: <<https://requests.readthedocs.io/>>. Citado 2 vezes nas páginas 24 e 44.

Red Hat. *What are Large Language Models?* 2023. Acesso em: maio de 2026. Disponível em: <<https://www.redhat.com/>>. Citado na página 16.

RUNESON, P.; ENGSTRÖM, E.; STOREY, M.-A. The design science paradigm as a frame for empirical software engineering. In: FELDERER, M.; TRAVASSOS, G. H. (Ed.). *Contemporary Empirical Methods in Software Engineering*. Cham: Springer International Publishing, 2020. p. 127–147. Citado 2 vezes nas páginas 18 e 22.

SAYÃO, L. F.; SALES, L. F. Dados abertos de pesquisa: ampliando o conceito de acesso livre. *Revista Eletrônica de Comunicação, Informação e Inovação em Saúde*, v. 8, n. 2, 2014. Citado na página 13.

Senado Federal do Brasil. *Portal de Dados Abertos do Senado Federal*. s.d. Acesso em: maio de 2026. Disponível em: <<https://www.senado.gov.br/transparencia/dados-abertos>>. Citado 2 vezes nas páginas 24 e 44.

SHNEIDERMAN, B. The eyes have it: A task by data type taxonomy for information visualizations. *Proceedings of IEEE Symposium on Visual Languages*, p. 336–343, 1996. Citado 3 vezes nas páginas 26, 28 e 45.

Streamlit Inc. *Streamlit: The Fastest Way to Build Data Apps*. 2024. Acesso em: maio de 2026. Disponível em: <<https://streamlit.io/>>. Citado 2 vezes nas páginas 25 e 45.

TAMPER, M.; TUOMINEN, J.; HYVÖNEN, E. Knowledge graphs and parliamentsampo: Linked open data services for parliamentary data. *Semantic Web*, v. 13, n. 6, p. 1003–1021, 2022. Citado na página 16.

THUAN, N. H.; DRECHSLER, A.; ANTUNES, P. Construction of design science research questions. *Communications of the Association for Information Systems*, v. 44, n. 1, p. 84–106, 2019. Citado na página 19.

VETRÒ, A. et al. Open data quality measurement framework: Definition and application to open government data. *Government Information Quarterly*, v. 33, n. 2, p. 325–337, 2016. Citado na página 13.

ZUIDERWIJK, A.; JANSSEN, M. Open data policies, their implementation and impact: A framework for comparison. *Government Information Quarterly*, v. 31, n. 1, p. 17–29, 2014. Citado na página 13.