



Universidade Federal de Sergipe
Centro de Ciências Exatas e Tecnologia
Programa de Pós-Graduação em Ciência da Computação

Democratizando o Acesso à Informação Legislativa: Inteligência Artificial Generativa para Análise de Dados Parlamentares

Proposta de Dissertação

Ana Beatriz Carvalho Oliveira



São Cristóvão – Sergipe

2026

Universidade Federal de Sergipe
Centro de Ciências Exatas e Tecnologia
Programa de Pós-Graduação em Ciência da Computação

Ana Beatriz Carvalho Oliveira

**Democratizando o Acesso à Informação Legislativa:
Inteligência Artificial Generativa para Análise de Dados
Parlamentares**

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Sergipe como requisito parcial para a obtenção do título de mestre em Ciência da Computação.

Orientador(a): Prof. Dr. Gilton José Ferreira da Silva

São Cristóvão – Sergipe

2026

Resumo

A crescente produção de dados brutos pelo Senado Federal impõe desafios à sua organização, consulta e interpretação, limitando a efetividade da transparência pública. Este trabalho insere-se nesse contexto, adotando a metodologia *Design Science Research* (DSR) para investigar a aplicação de Inteligência Artificial Generativa na análise de dados parlamentares abertos. O objetivo é projetar, desenvolver e avaliar tecnicamente um artefato computacional capaz de estruturar dados legislativos, classificar discursos e apoiar consultas em linguagem natural. A solução proposta, denominada AgentAI, consiste em uma aplicação *web* interativa que automatiza a extração de dados da API do Senado e utiliza o modelo Mistral 7B Instruct executado localmente para classificação temática e geração de respostas ancoradas nos dados recuperados. A avaliação será conduzida sem coleta de dados com participantes humanos, por meio de cenários representativos de consulta, comparação com gabaritos de referência, verificação de rastreabilidade e análise factual das respostas. O artefato encontra-se funcional e já passou por verificação funcional preliminar; esta proposta detalha o protocolo de avaliação científica — classificação temática, coerência factual e rastreabilidade —, cuja execução constitui a etapa em andamento. A pesquisa investiga em que medida a combinação entre dados abertos, IA Generativa local e interfaces visual/conversacional pode reduzir barreiras cognitivas e técnicas de acesso à informação legislativa.

Palavras-chave: Inteligência Artificial Generativa. Dados Abertos. Design Science Research. Transparência Pública. Processamento de Linguagem Natural.

Abstract

The growing production of raw data by the Federal Senate poses challenges to organization, querying, and interpretation, limiting the effectiveness of public transparency. Within this context, this work adopts the Design Science Research (DSR) methodology to investigate the application of Generative Artificial Intelligence in the analysis of open parliamentary data. The objective is to design, develop, and technically evaluate a computational artifact capable of structuring legislative data, classifying speeches, and supporting natural-language queries. The proposed solution, named AgentAI, consists of an interactive web application that automates data extraction from the Senate API and uses the locally executed Mistral 7B Instruct model for thematic classification and data-grounded response generation. The evaluation will be conducted without collecting data from human participants, using representative query scenarios, comparison with reference answers, traceability checks, and factual analysis of generated responses. The artifact is functional and has undergone preliminary functional verification; this proposal details the scientific evaluation protocol — thematic classification, factual coherence, and traceability —, whose execution constitutes the ongoing stage. The research investigates to what extent combining open data, local Generative AI, and visual/conversational interfaces can reduce cognitive and technical barriers to accessing legislative information.

Keywords: Generative Artificial Intelligence. Open Data. Design Science Research. Public Transparency. Natural Language Processing.

Lista de ilustrações

Figura 1 – Processo de publicação e estruturação de dados abertos	16
Figura 2 – Diagrama das 5 estrelas de Dados Abertos	17
Figura 3 – Abordagem Clássica de PLN	17
Figura 4 – Abordagem Generativa com LLMs	18
Figura 5 – Fluxo de Treinamento e Refinamento de um LLM	18
Figura 6 – Arquitetura de interação do usuário com os dados parlamentares: Dashboard e Chatbot integrados	23
Figura 7 – Fluxo metodológico baseado em Design Science Research (adaptado de Peffers et al. 2007)	25
Figura 8 – Interface Swagger da API de Dados Abertos do Senado Federal	27
Figura 9 – Interface da Aplicação	28
Figura 10 – Fases do Mapeamento Sistemático da Literatura	40
Figura 11 – Fluxograma de seleção dos estudos (PRISMA-ScR)	44
Figura 12 – Interface do Agente Conversacional (Chatbot) do AgentAI	52

Lista de quadros

Quadro 1 – Matriz de rastreabilidade entre objetivos, frentes de avaliação, métricas e cláusulas da hipótese	31
Quadro 2 – Cronograma de Execução e Finalização da Dissertação	37
Quadro 3 – Questões de Pesquisa do Mapeamento Sistemático	41
Quadro 4 – Campos de Extração de Dados	41
Quadro 5 – Palavras-Chave da Busca	42
Quadro 6 – Strings de Busca (Conceituais)	42
Quadro 7 – Critérios de Inclusão e Exclusão	43
Quadro 8 – Progresso das Fases de Design Science Research	55
Quadro 9 – Avaliação comparativa dos quatro modelos geradores ($n = 40$ por modelo; quantização Q4_K_M)	58

Sumário

1	Introdução	10
1.1	Contexto	10
1.2	Motivação	11
1.3	Problemática, Questão de Pesquisa e Hipótese	12
1.3.1	Problemática	12
1.3.2	Questão de Pesquisa	12
1.3.3	Hipótese de Pesquisa	12
1.4	Objetivos	13
1.4.1	Objetivo Geral	13
1.4.2	Objetivos Específicos	13
1.5	Estrutura do Documento	14
2	Fundamentação Teórica	15
2.1	Dados Abertos	15
2.1.1	As 5 Estrelas dos Dados Abertos	16
2.2	Processamento de Linguagem Natural (PLN) e Modelos de Linguagem	17
2.3	Inteligência Artificial Generativa	18
2.3.1	Recuperação Aumentada por Geração	19
2.3.2	Mistral 7B Instruct vs. Alternativas	19
2.4	Design Science Research	20
2.4.1	Fases da Design Science Research	21
2.4.2	DSR no Contexto desta Pesquisa	21
2.5	Interação Humano-Dados e Acessibilidade de Informação	21
2.5.1	Desafios de Visualização de Dados	22
2.5.2	Barreiras Cognitivas para Usuários Não-Especialistas	22
2.5.3	Interfaces Conversacionais como Estratégia de Acessibilidade	22
3	Metodologia	24
3.1	Abordagem Metodológica: Design Science Research	24
3.2	Fases da Pesquisa	25
3.2.1	Fase 1: Identificação do Problema e Motivação	25
3.2.2	Fase 2: Definição dos Objetivos da Solução	26
3.3	Fase 3: Design e Desenvolvimento do Artefato	26
3.3.1	Coleta e Processamento de Dados (Camada de Dados)	26
3.3.2	Análise com IA Generativa (Camada de Inteligência)	27
3.3.3	Interface Interativa (Camada de Apresentação)	28

3.4	Fundamentos Teóricos para as Escolhas de Design	28
3.4.1	Por que Dashboard?	28
3.4.2	Por que Chatbot?	29
3.4.3	Complementaridade: Dashboard + Chatbot	29
3.5	Fase 4: Demonstração	30
3.6	Fase 5: Avaliação do Artefato	30
3.6.1	Avaliação da Coleta e Estruturação dos Dados	31
3.6.1.1	Pergunta	31
3.6.1.2	Método	31
3.6.1.3	Métricas	31
3.6.2	Avaliação da Classificação Temática	32
3.6.2.1	Pergunta	32
3.6.2.2	Método	32
3.6.2.3	Métricas	32
3.6.2.4	Critério de Interpretação	32
3.6.3	Avaliação Factual das Respostas do Agente Conversacional	33
3.6.3.1	Pergunta	33
3.6.3.2	Método	33
3.6.3.3	Métricas	34
3.6.4	Avaliação de Rastreabilidade	34
3.6.4.1	Pergunta	34
3.6.4.2	Método	34
3.6.4.3	Métricas	34
3.6.4.4	Limitações Assumidas	35
3.6.5	Avaliação de Cenários de Uso	35
3.7	Fase 6: Reflexão e Aprendizados	35
3.8	Ameaças à Validade	36
3.8.1	Validade de Construto	36
3.8.2	Validade Interna	36
3.8.3	Validade Externa	36
3.8.4	Validade de Conclusão	37
3.9	Cronograma de Execução	37
4	Estado da Arte	39
4.1	Protocolo do Mapeamento Sistemático	39
4.1.1	Planejamento	40
4.1.2	Execução e Resultados	43
4.2	Análise Temática dos Resultados	45
4.2.1	Tema 1: IA Generativa para Estruturação de Dados Legislativos	45
4.2.2	Tema 2: Interfaces Conversacionais para Acessibilidade	45

4.2.3	Tema 3: Análise de Dados Legislativos com PLN Clássico	46
4.2.4	Tema 4: Desafios e Lacunas na Literatura	46
4.3	Lacunas Identificadas e Contribuições Desta Pesquisa	47
4.4	Conclusões do Mapeamento Sistemático	48
5	Desenvolvimento e Resultados Preliminares	49
5.1	Estágio Atual do Desenvolvimento	49
5.2	Arquitetura e Componentes do Artefato	50
5.2.1	Camada de Dados: Coleta e Processamento	50
5.2.2	Camada de Inteligência: Análise com Mistral 7B	50
5.2.3	Camada de Apresentação: Interfaces Acessíveis	51
5.2.3.1	Dashboard Visual	51
5.2.3.2	Chatbot Conversacional	52
5.2.4	Rastreabilidade das Respostas	53
5.3	Fluxo de Funcionamento do Sistema	53
5.4	Dados Legislativos Utilizados	54
5.5	Status de Conclusão das Fases DSR	54
5.6	Cronograma de Execução da Dissertação	55
5.7	Próximas Ações Imediatas (Próximas 8 Semanas)	55
6	Resultados da Avaliação	56
6.1	Configuração Experimental	56
6.1.1	Corpus de Avaliação	56
6.1.2	Modelos, Hardware e Quantização	57
6.1.3	Condição de Geração	57
6.2	Resultados Quantitativos Agregados	58
6.3	Saturação das Métricas Automáticas e o Suporte Semântico como Eixo Discriminante	58
6.4	O Caso Q04: Métrica Automática Perfeita com Suporte Semântico Baixo	59
6.5	Recusa Correta nas Perguntas sem Resposta no Corpus	59
6.6	Discussão	59
6.6.1	Robustez do Achado entre Modelos	59
6.6.2	Custo de Inferência e o <i>Trade-off</i> Qualidade–Custo	60
6.6.3	Limitações	60
7	Considerações Parciais e Trabalhos Futuros	61
7.1	Progresso do Ciclo de Design Science Research	61
7.2	Resultados Preliminares do Artefato	62
7.2.1	Viabilidade Técnica	62
7.2.2	Verificação Funcional Preliminar	62

7.3	Desafios e Limitações Identificadas	63
7.3.1	Desafios Técnicos	63
7.3.2	Desafios Metodológicos	63
7.4	Contribuições Esperadas da Pesquisa	64
7.4.1	Contribuições Científicas	64
7.4.2	Contribuições Práticas	64
7.5	Trabalhos Futuros: Fases de Avaliação e Conclusão	65
7.6	Perspectivas de Conclusão	65
Referências		67

1

Introdução

A crescente abertura de dados governamentais no Brasil criou um paradoxo pouco discutido: os dados estão tecnicamente disponíveis, mas permanecem inacessíveis para a maior parte da população. Esta dissertação parte desse problema concreto para investigar se — e em que medida — a Inteligência Artificial Generativa pode reduzir essa distância entre disponibilidade técnica e acesso efetivo à informação parlamentar.

1.1 Contexto

A busca por um governo transparente é um pilar fundamental da democracia, onde a visibilidade do poder legitima as instituições (BOBBIO, 1986). No século XXI, essa premissa é potencializada pelo movimento de dados abertos (Open Data), que defende que os dados governamentais devam ser livremente utilizados, reutilizados e redistribuídos (Open Knowledge Brasil, 2024). Contudo, a simples disponibilização das informações sobre as atividades parlamentares não assegura, por si só, a efetividade da transparência. A proliferação de dados brutos, como os debates e discursos políticos, requer métodos de organização, recuperação e análise para que a informação pública possa ser consultada de modo inteligível — pois, como argumentam Oliveira e Ckagnazaroff (2022), a transparência efetiva exige que os dados sejam não apenas públicos, mas também claros, contextualizados e utilizáveis. Quando essa mediação não se realiza, amplia-se o fosso entre o que está formalmente disponível e o que é efetivamente acessível, aprofundando o distanciamento entre representados e representantes. Esse distanciamento insere-se em um quadro mais amplo de fragilização da confiança nas instituições representativas, para o qual Levitsky e Ziblatt (2018) chamam atenção ao discutir os processos contemporâneos de erosão democrática — sem que se lhes atribua, aqui, uma relação causal direta com a acessibilidade de dados parlamentares, tratada neste trabalho como uma dentre várias dimensões da qualidade democrática. Nesse cenário, a Inteligência Artificial (IA), com destaque para a IA Generativa, apresenta potencial para processar, classificar e sintetizar grandes volumes de dados textuais,

apoando novas formas de consulta à informação pública.

1.2 Motivação

A motivação central deste trabalho está na distância entre o que os dados parlamentares abertos prometem e o que efetivamente entregam. A API do Senado Federal disponibiliza volumes crescentes de informações sobre sessões, discursos e votações, mas consultá-la exige familiaridade com estruturas técnicas (endpoints, formatos XML/JSON) que escapam ao repertório da maioria dos cidadãos. Não se trata de um problema de vontade política na abertura dos dados — trata-se de um problema de mediação entre dado bruto e informação compreensível. A aplicação da IA Generativa nesse contexto não é uma solução trivial: ela carrega consigo riscos conhecidos de imprecisão factual e viés algorítmico que precisam ser investigados antes de qualquer uso em contextos cívicos. É exatamente essa tensão — potencial de democratização versus riscos de desinformação — que motiva a pesquisa aqui proposta.

O artefato desenvolvido nesta dissertação, denominado *AgentAI*, é uma aplicação web que integra coleta automatizada de dados parlamentares via API do Senado Federal, classificação temática de discursos com IA Generativa executada localmente, visualizações interativas e um agente conversacional para consultas em linguagem natural. A escolha por execução local — em vez de APIs proprietárias — responde a critérios científicos concretos: replicabilidade do experimento, soberania dos dados e independência de custos operacionais.

Delimita-se, desde já, o alcance do que será demonstrado. O termo *democratização do acesso*, presente no título e na motivação deste trabalho, designa um horizonte de impacto social cuja realização plena depende de fatores que extrapolam o escopo de uma dissertação. O que esta pesquisa efetivamente projeta e avalia são **pré-condições técnicas** dessa democratização: a estruturação confiável dos dados, a qualidade factual e a rastreabilidade das respostas e a disponibilização de interfaces de baixa barreira de entrada. A avaliação de acessibilidade e de impacto junto a cidadãos reais, que exigiria um estudo com participantes humanos, é reconhecida como trabalho futuro e não constitui objeto da avaliação aqui proposta. Cabe ainda distinguir, desde a introdução, as duas barreiras que o artefato busca reduzir e que serão tratadas de forma articulada ao longo do texto: a **barreira técnica** — a necessidade de manejar *endpoints*, formatos XML/JSON e linguagens de consulta para obter o dado bruto — e a **barreira cognitiva** — a dificuldade de interpretar dados e visualizações sem letramento estatístico ou familiaridade com o jargão legislativo.

1.3 Problemática, Questão de Pesquisa e Hipótese

1.3.1 Problemática

A principal problemática abordada decorre do fato de que o volume e a complexidade dos dados parlamentares abertos, embora publicamente disponíveis, representam uma barreira significativa para consulta e análise. Como discutido por [Oliveira e Ckagnazaroff \(2022\)](#), para que a transparência seja efetiva, os dados devem ser não apenas públicos, mas também claros, contextualizados e utilizáveis. Atualmente, a análise proficiente desses dados exige conhecimentos técnicos, familiaridade com as estruturas das APIs e o dispêndio de tempo considerável.

Complementarmente, [Lee, Kim e Kwon \(2017\)](#), através do VLAT (*Visualization Literacy Assessment Test*), demonstraram que a interpretação das visualizações gráficas pode variar conforme a literacia visual dos usuários. [Hornung, Pereira e Baranauskas \(2015\)](#) apontam que as pessoas sem formação em estatística ou ciência de dados podem enfrentar barreiras cognitivas ao analisar os dados complexos. Portanto, a mera disponibilização dos dados legislativos não garante, por si só, que essas informações sejam facilmente consultáveis ou compreensíveis.

Nesse contexto, a Inteligência Artificial Generativa, exemplificada pelos modelos como o Mistral 7B Instruct ([Mistral AI, 2024](#)), apresenta-se como uma abordagem promissora para apoiar a organização e a consulta dos dados legislativos textuais. Diferentemente das técnicas tradicionais de Processamento de Linguagem Natural (PLN) que dependem de palavras-chave rígidas, os modelos de linguagem podem apoiar tarefas de classificação temática, sumarização e geração de respostas em linguagem natural. A execução local do modelo também contribui para a privacidade, replicabilidade e independência das APIs proprietárias.

1.3.2 Questão de Pesquisa

Diante desse cenário, este trabalho norteia-se pela seguinte questão de pesquisa central:

QP: Em que medida um artefato computacional baseado em *dashboard* visual e agente conversacional com IA Generativa local pode estruturar, classificar e tornar consultáveis os dados parlamentares abertos do Senado Federal?

1.3.3 Hipótese de Pesquisa

Para responder a esta questão, foi formulada a seguinte hipótese de trabalho:

Hipótese: A combinação do processamento dos dados abertos, classificação temática com o Mistral 7B Instruct e interface visual/conversacional é capaz de estruturar e tornar consultáveis dados parlamentares abertos. Especificamente, espera-se que: (a) a classificação temática automática dos discursos apresente acurácia superior à de um classificador por palavras-chave utilizado como linha de base; (b) as respostas do agente conversacional sejam majoritariamente

coerentes com os dados recuperados, com a taxa de coerência factual reportada e comparada a uma configuração sem recuperação contextual; e (c) as respostas mantenham rastreabilidade explícita — podendo ser associadas aos registros de origem —, com essa rastreabilidade caracterizada tanto quantitativa quanto qualitativamente. Em vez de fixar limiares absolutos de aprovação ou reprovação, a pesquisa adota uma postura orientada à caracterização: as taxas efetivamente alcançadas serão reportadas, discutidas à luz dos *baselines* adotados e das limitações do corpus de avaliação, e os casos de insucesso — quando ocorrerem — serão analisados como resultado científico central da dissertação.

1.4 Objetivos

1.4.1 Objetivo Geral

Investigar como a aplicação da Inteligência Artificial Generativa local nos dados legislativos abertos pode apoiar a estruturação, classificação e consulta das informações parlamentares, mediante o design, implementação e avaliação técnica de um artefato computacional interativo que integra interface visual e conversacional.

1.4.2 Objetivos Específicos

Para que o objetivo geral seja alcançado, foram definidos os seguintes objetivos específicos, alinhados às etapas da metodologia *Design Science Research*:

- Realizar um mapeamento sistemático da literatura para identificar os fundamentos teóricos sobre os dados abertos, IA Generativa em contextos cívicos, interação humano-dados e consulta aos dados legislativos.
- Descrever e justificar os fundamentos teóricos para as escolhas de design do artefato, especificamente a combinação do *dashboard* visual e agente conversacional baseado na IA Generativa local.
- Implementar um protótipo funcional (*artefato computacional*) capaz de processar os dados legislativos abertos da API do Senado Federal, classificar tematicamente os discursos e responder às perguntas em linguagem natural utilizando o modelo Mistral 7B Instruct.
- Avaliar a eficácia técnica do artefato, verificando a qualidade da coleta e estruturação dos dados, a acurácia da classificação temática e a qualidade factual das respostas geradas em comparação com os dados oficiais.
- Avaliar a rastreabilidade das respostas geradas pelo agente conversacional, verificando se as informações apresentadas podem ser associadas aos dados recuperados, como discurso, votação, data, parlamentar ou matéria legislativa.

- Documentar o conhecimento científico gerado sobre o design e a avaliação dos artefatos computacionais para consulta aos dados parlamentares abertos com IA Generativa local.

1.5 Estrutura do Documento

O documento está organizado em seis capítulos. A Fundamentação Teórica (Cap. 2) apresenta os conceitos de dados abertos, PLN, IA Generativa, RAG, DSR e interação humano-dados. A Metodologia (Cap. 3) detalha as seis fases DSR e o protocolo de avaliação do artefato. O Estado da Arte (Cap. 4) mapeia sistematicamente a literatura existente e posiciona esta pesquisa em relação ao campo. O Desenvolvimento (Cap. 5) descreve a arquitetura do AgentAI e os resultados preliminares. As Considerações Parciais (Cap. 6) analisam o progresso alcançado, os desafios identificados e as perspectivas de conclusão.

A adjacência intencional entre os capítulos de Metodologia e Estado da Arte permite que o leitor conheça primeiro as decisões metodológicas adotadas — inclusive o protocolo de avaliação — para então confrontá-las com as práticas documentadas pela literatura, tornando explícita a contribuição original desta dissertação.

2

Fundamentação Teórica

2.1 Dados Abertos


Este trabalho se fundamenta na disponibilização de dados governamentais em formato aberto, livre de restrições de direitos autorais ou outros mecanismos de controle. Conforme definido pelo movimento OK Brasil ([Open Knowledge Brasil, 2024](#)) e pelo Arquivo Nacional do Reino Unido ([Arquivo Nacional, 2023](#)), os "dados abertos" são aqueles disponibilizados livremente para acesso, uso, reutilização e redistribuição por qualquer indivíduo. Para que sejam considerados como tal, é crucial que os dados estejam em formatos abertos e não proprietários, permitindo a sua fácil integração com outros sistemas e ferramentas.

No contexto da pesquisa científica, os dados abertos são essenciais para a aceleração de descobertas e a promoção da colaboração ([SAYÃO; SALES, 2014](#)). Ao tornar dados disponíveis em formato aberto, pesquisadores e cientistas sociais ganham condições concretas para replicar estudos, contestar resultados e explorar perspectivas de análise que dependem do acesso livre a fontes primárias. Sayão e Sales ([SAYÃO; SALES, 2014](#)) argumentam que essa abertura não é apenas uma mudança técnica, mas uma transformação nas práticas de comunicação científica, exigindo novas formas de gerenciamento, preservação e compartilhamento de dados ao longo do tempo.

Na gestão pública, os dados abertos são fundamentais para a transparência e a accountability. Ao disponibilizar dados sobre gastos públicos e contratos governamentais, os governos aumentam sua transparência e permitem um controle social mais rigoroso ([ZUIDERWIJK; JANSSEN, 2014](#)). No Brasil, a API do Senado Federal configura-se como uma ferramenta essencial para a democracia participativa, oferecendo dados brutos sobre o funcionamento da Instituição. Contudo, a efetividade dessa abertura depende da qualidade com que os dados são entregues aos cidadãos. Conforme argumentado por Vetro et al. ([VETRÒ et al., 2016](#)), a qualidade dos dados deve ser observada em todas as etapas de sua disponibilização, desde a

coleta até a apresentação. A Figura 1 ilustra o processo de publicação de dados abertos e os pontos críticos onde a intervenção técnica é necessária para assegurar que o dado bruto se torne informação útil.

Figura 1 – Processo de publicação e estruturação de dados abertos



Fonte: Adaptado de Villazón-Terrazas et al. (2011).

2.1.1 As 5 Estrelas dos Dados Abertos


Para maximizar o potencial de reutilização e interoperabilidade dos dados abertos, Tim Berners-Lee propôs um sistema de classificação de 5 estrelas (Figura 2), que gradua o nível de abertura e estruturação dos dados (ISOTANI; BITTENCOURT, 2015). A seguir, são descritas cada uma das etapas:

- **1 estrela:** Disponível na web (qualquer formato) com licença aberta. Este é o nível mais básico de abertura de dados.
- **2 estrelas:** Disponível como dados estruturados (por exemplo, em formatos CSV ou Excel). Nesse estágio, os dados são organizados em tabelas ou outras estruturas que facilitam a sua manipulação e análise.
- **3 estrelas:** Como 2 estrelas, mas em formato não proprietário. Aqui, os dados estão disponíveis em formatos abertos padronizados (como CSV), o que facilita sua integração com diversas ferramentas de visualização e análise.
- **4 estrelas:** Como 3 estrelas, mais uso de URIs e padrões W3C (RDF, SPARQL). Neste estágio, os dados são identificáveis na web através de URIs, o que permite a sua ligação

com outras fontes de informação. Os dados também podem ser descritos em formato RDF, permitindo a sua integração com recursos semânticos padronizados.

- **5 estrelas:** Como 4 estrelas, mais ligação (link) com outros dados para fornecer contexto (*Linked Data*). Neste ponto, os dados não apenas são abertos e interoperáveis, mas também estão conectados a outras fontes de informação relevantes. Isso permite a construção de aplicações que fornecem uma visão holística dos dados.

Figura 2 – Diagrama das 5 estrelas de Dados Abertos



Fonte: 5stardata.info.

2.2 Processamento de Linguagem Natural (PLN) e Modelos de Linguagem

O Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência Artificial que se dedica a capacitar os computadores para processar e compreender a linguagem humana (JURAFSKY; MARTIN, 2023). A abordagem clássica do PLN exigia um *pipeline* complexo de pré-processamento manual e intensivo (Figura 3), onde o texto era convertido em representações vetoriais numéricas.

Figura 3 – Abordagem Clássica de PLN




Fonte: Produção da autora.

Com o advento dos Modelos de Linguagem de Larga Escala (LLMs), essa abordagem mudou drasticamente. Como ilustrado na Figura 4, os LLMs são capazes de realizar tarefas

complexas, como tradução, resumo e geração de texto, de forma *end-to-end*, sendo instruídos por comandos em linguagem natural (*prompts*).

Figura 4 – Abordagem Generativa com LLMs




Fonte: Produção da autora.

Este trabalho adota a abordagem generativa, utilizando o modelo Mistral 7B Instruct (Mistral AI, 2024), que roda em ambiente local para executar tarefas de classificação temática e resposta a perguntas (*Question Answering*), dispensando a necessidade de treinamento de modelos específicos para cada tarefa e evitando dependência de APIs externas.

2.3 Inteligência Artificial Generativa

Os Modelos de Linguagem de Larga Escala (LLMs) são modelos fundamentados em arquiteturas de redes neurais profundas (*deep learning*), treinados com volumes massivos de dados para compreender e gerar linguagem com alta fluência (Red Hat, 2023). O fluxo típico de desenvolvimento desses modelos envolve coleta, treinamento e refinamento por *feedback* humano (RLHF), conforme a Figura 5.

Figura 5 – Fluxo de Treinamento e Refinamento de um LLM



Fonte: Produção da autora.

No contexto desta pesquisa, a IA Generativa é empregada para classificar discursos parlamentares por tema e gerar respostas em linguagem natural a partir de dados legislativos estruturados (TAMPER; TUOMINEN; HYVÖNEN, 2022). Esse uso, porém, não é isento de riscos: alucinações — respostas factualmente incorretas geradas com aparente confiança pelo modelo — e vieses presentes nos dados de treinamento representam ameaças concretas à confiabilidade do sistema (MARQUES; LAIPELT, 2023). Em contextos cívicos, onde informação imprecisa pode influenciar a percepção pública sobre representantes políticos, esses riscos não

podem ser tratados apenas como limitações técnicas; eles exigem mecanismos explícitos de verificação e rastreabilidade, que constituem, precisamente, um dos focos desta dissertação.

2.3.1 Recuperação Aumentada por Geração

Além da geração textual, este trabalho adota uma estratégia de Recuperação Aumentada por Geração (*Retrieval-Augmented Generation* – RAG). Em linhas gerais, RAG combina uma etapa de recuperação de informações relevantes em uma base de dados ou coleção documental com uma etapa de geração de resposta por modelo de linguagem (LEWIS et al., 2020). Essa abordagem é adequada para domínios em que a resposta deve permanecer ancorada em fontes verificáveis, pois o modelo não responde apenas com base em seus parâmetros internos: ele recebe, no *prompt*, um contexto recuperado previamente.

No AgentAI, a etapa de recuperação não emprega indexação vetorial densa com modelos de *embedding* e operações de similaridade semântica, mas sim **busca estruturada** sobre a base local — filtrando registros por parlamentar, período, tema ou palavras presentes no texto — e fornece esse contexto diretamente ao Mistral 7B Instruct para a geração da resposta. Por rigor terminológico, esta dissertação refere-se a tal estratégia como *recuperação estruturada com geração aumentada* (uma abordagem inspirada em RAG), reservando o termo RAG, em sentido estrito (LEWIS et al., 2020), para arquiteturas que realizam recuperação por similaridade semântica densa. Essa escolha implica um *trade-off* explícito: perde-se a capacidade de recuperar documentos por paráfrase ou sinônimo (limitação que será documentada na avaliação), mas ganha-se rastreabilidade direta — cada resposta pode ser associada aos registros exatos que a fundamentaram. Para o objetivo desta dissertação, que é justamente investigar a qualidade factual e a rastreabilidade das respostas em contexto legislativo, essa abordagem é metodologicamente coerente.

2.3.2 Mistral 7B Instruct vs. Alternativas

A escolha do modelo Mistral 7B Instruct justifica-se por múltiplos aspectos técnicos e científicos. Diferentemente de APIs proprietárias como Google Gemini, Mistral 7B oferece:

- **Privacidade e Soberania de Dados:** O modelo roda localmente, garantindo que os dados legislativos brasileiros não sejam transmitidos para servidores externos, o que se alinha com princípios de soberania digital.
- **Replicabilidade:** Por ser *open-source*, permite que outros pesquisadores reproduzam exatamente o experimento e validem os resultados de forma independente, atendendo aos critérios de rigor científico.
- **Custo Operacional:** Elimina dependência de APIs pagas, reduzindo barreiras financeiras para a replicação da pesquisa.

- **Performance Adequada:** Apesar de menor em parâmetros que os grandes modelos proprietários, o Mistral 7B Instruct apresenta desempenho competitivo em tarefas de compreensão e geração de linguagem em benchmarks gerais (JIANG et al., 2023); sua adequação específica ao domínio legislativo em português constitui, precisamente, uma das questões investigadas nesta dissertação.

Este trade-off entre capacidade absoluta (modelos proprietários maiores) e replicabilidade (modelo local open-source) representa uma escolha metodológica consciente que prioriza a sustentabilidade e transparência da pesquisa.

Reconhece-se que o Mistral 7B Instruct, lançado em 2023, não é o modelo aberto mais recente disponível ao tempo de conclusão desta dissertação. A escolha, contudo, prioriza deliberadamente a **replicabilidade** sobre a recência: um modelo congelado, amplamente documentado e de pesos abertos permite que o experimento seja reproduzido de forma idêntica por terceiros — garantia que não se obtém com modelos sujeitos a atualizações frequentes ou a descontinuação. Trata-se, portanto, de uma limitação assumida, e não de uma afirmação de superioridade do modelo. Essa opção é viabilizada pela arquitetura modular do artefato quanto ao componente de linguagem: o LLM é acessado por uma interface de inferência padronizada, de modo que a substituição por um modelo mais recente constitui trabalho futuro de baixo custo de integração, sem alteração dos demais estágios de coleta, recuperação e avaliação.

2.4 Design Science Research

O Design Science Research (DSR) é um paradigma metodológico específico para a pesquisa em Ciência da Computação, que combina rigor científico com a construção prática de artefatos tecnológicos (PEFFERS et al., 2007). Conforme definido por Peffers et al. (PEFFERS et al., 2007), DSR diferencia-se da pesquisa puramente teórica porque investiga não apenas se um artefato funciona, mas como e por que ele funciona, gerando conhecimento científico sobre seu design, sua implementação, suas limitações e sua avaliação.

Runeson et al. (RUNESON; ENGSTRÖM; STOREY, 2020) complementam ao argumentar que, em Engenharia de Software e Computação, construir um artefato (seja software, hardware ou framework) em si não constitui automaticamente conhecimento científico. O conhecimento emerge quando se documenta e avalia sistematicamente o processo e os impactos daquele artefato. Conforme Pimentel et al. (PIMENTEL; FILIPPO; SANTOS, 2020), a pesquisa em Design Science visa "a construção de artefatos como estratégia para o avanço do conhecimento".

2.4.1 Fases da Design Science Research

O ciclo de DSR, conforme proposto por Peffers et al. (PEFFERS et al., 2007), compreende seis fases que orientam o desenvolvimento de pesquisa em Computação:

1. **Motivação e Identificação do Problema:** Definição clara do problema prático que o artefato propõe-se a resolver, fundamentado em literatura e observação empírica.
2. **Objetivos da Solução:** Especificação do que a solução deve atingir e justificativa teórica para as escolhas de design.
3. **Design e Desenvolvimento:** Construção do artefato, documentando decisões técnicas e sua fundamentação.
4. **Demonstração:** Apresentação do artefato funcionando em cenários reais ou controlados, validando a viabilidade técnica.
5. **Avaliação:** Avaliação rigorosa da efetividade técnica, qualidade das respostas, rastreabilidade e limitações, comparando contra critérios pré-definidos.
6. **Reflexão e Aprendizados:** Documentação do conhecimento científico gerado, contribuições à teoria, limitações e trabalhos futuros.

2.4.2 DSR no Contexto desta Pesquisa

Este trabalho adota DSR porque seu objetivo central é a construção e avaliação de um artefato computacional (AgentAI) cuja utilidade e eficácia técnica devem ser validadas. Diferentemente de uma pesquisa exploratória que investiga "o que está acontecendo" em um contexto natural, esta pesquisa propõe e testa uma solução, investigando em que medida ela apoia a estruturação, classificação e consulta de dados parlamentares abertos. Conforme argumentado por Thuan et al. (THUAN; DRECHSLER; ANTUNES, 2019), ao formular a questão de pesquisa em DSR, deve-se focar em "Como?" (design e implementação) e "Em que medida?" (efetividade do artefato), não apenas "O quê?"

2.5 Interação Humano-Dados e Acessibilidade de Informação

Um dos desafios fundamentais na democratização de dados é garantir que os cidadãos consigam não apenas acessar informações, mas também compreendê-las e interpretá-las adequadamente. Este problema é abordado pela comunidade de pesquisa em Interação Humano-Dados.

2.5.1 Desafios de Visualização de Dados

Lee et al. (LEE; KIM; KWON, 2017), através do desenvolvimento do VLAT (*Visualization Literacy Assessment Test*), demonstraram que nem todos os usuários conseguem interpretar visualizações gráficas complexas. O estudo evidencia que usuários com pouca exposição a gráficos estatísticos cometem com frequência erros na leitura de eixos, escalas e representações multidimensionais, e que visualizações sofisticadas — como *heatmaps* e *scatter plots* tridimensionais — podem confundir mais do que esclarecer para quem não domina a linguagem gráfica. A compreensão visual de dados configura-se, assim, como uma competência que varia significativamente entre indivíduos, e não como um pressuposto universal.

2.5.2 Barreiras Cognitivas para Usuários Não-Especialistas

Hornung et al. (HORNUNG; PEREIRA; BARANAUSKAS, 2015) apontam que usuários sem formação em estatística ou ciência de dados frequentemente enfrentam barreiras cognitivas significativas ao tentar analisar dados complexos. Essas barreiras manifestam-se na falta de familiaridade com conceitos como mediana, distribuição e correlação, na dificuldade de formular hipóteses e validá-las contra os dados e na sobrecarga cognitiva decorrente de lidar simultaneamente com múltiplas dimensões de informação.


Consequentemente, a mera disponibilização de dados e interfaces visuais não garante compreensão ou participação democrática efetiva. Conforme Brito et al. (BRITO; FRANÇA; VIVACQUA, 2024), em seu trabalho sobre "Literacia de Dados para Todos", a solução requer abordagens múltiplas que reduzam progressivamente barreiras de entrada.

2.5.3 Interfaces Conversacionais como Estratégia de Acessibilidade

Neste contexto, interfaces conversacionais alimentadas por modelos de linguagem generativa representam uma estratégia complementar à visualização tradicional. Ao permitir que os usuários formulem perguntas em linguagem natural (por exemplo: "Como votou o Senador X sobre educação?"), reduz-se a necessidade de expertise técnica ou estatística. A IA Generativa traduz a pergunta em operações sobre os dados, apresentando resultados em linguagem acessível.

A combinação de duas modalidades de interação—Dashboard visual e Chatbot conversacional—permite que diferentes usuários escolham a interface que melhor se adequa ao seu estilo cognitivo e nível de expertise, aumentando a acessibilidade global da solução. A arquitetura da aplicação desenvolvida neste trabalho (Figura 6) combina essas duas abordagens para maximizar a acessibilidade.

Figura 6 – Arquitetura de interação do usuário com os dados parlamentares: Dashboard e Chatbot integrados



Fonte: Produção da autora.

Os conceitos discutidos neste capítulo não são independentes entre si: a teoria de dados abertos delimita o corpus e justifica a escolha da API do Senado Federal; os estudos sobre literacia de dados e barreiras cognitivas sustentam a decisão de oferecer duas modalidades de interação (visual e conversacional) em vez de apenas uma; o DSR fundamenta a abordagem metodológica que orienta todo o ciclo de pesquisa; e a discussão sobre RAG e alucinações em LLMs antecipa os desafios concretos que o protocolo de avaliação precisará endereçar. A articulação entre essas dimensões é o que diferencia a proposta de uma simples implementação técnica.

3

Metodologia


Quando o objetivo central de uma pesquisa é construir e avaliar um artefato computacional — e não apenas observar ou descrever um fenômeno —, a escolha metodológica deve refletir essa natureza construtiva. É nesse sentido que se adota o *Design Science Research* (DSR), um paradigma consolidado em Ciência da Computação que orienta não apenas a construção do artefato, mas a geração de conhecimento científico a partir do processo de design, implementação e avaliação (PEFFERS et al., 2007). O risco de trabalhos dessa natureza é reduzir-se a um relatório técnico de desenvolvimento de software; a DSR evita isso ao exigir que cada decisão de design seja justificada teoricamente e que os resultados sejam avaliados com rigor comparável ao de pesquisas empíricas (RUNESON; ENGSTRÖM; STOREY, 2020; PIMENTEL; FILIPPO; SANTOS, 2020). As seis fases que estruturam esta pesquisa são descritas a seguir.

3.1 Abordagem Metodológica: Design Science Research

A metodologia foi estruturada seguindo o ciclo de processo proposto por Peffers et al. (PEFFERS et al., 2007), adaptado para o contexto deste trabalho em seis fases principais, conforme ilustrado na Figura 7:

1. Identificação do Problema e Motivação
2. Definição dos Objetivos da Solução
3. Design e Desenvolvimento do Artefato
4. Demonstração
5. Avaliação
6. Reflexão e Aprendizados

Figura 7 – Fluxo metodológico baseado em Design Science Research (adaptado de Peffers et al. 2007)



Fonte: Adaptado de Peffers et al. (2007).

3.2 Fases da Pesquisa

3.2.1 Fase 1: Identificação do Problema e Motivação

A primeira etapa consistiu no reconhecimento da opacidade prática dos dados parlamentares. Embora disponíveis em formato aberto através da API do Senado Federal, a complexidade técnica e o volume massivo desses dados impedem que cidadãos comuns exerçam controle social efetivo. Segundo Oliveira e Ckagnazaroff ([OLIVEIRA; CKAGNAZAROFF, 2022](#)), para que a transparência seja efetiva, os dados devem ser não apenas públicos, mas também claros, contextualizados e utilizáveis.

Conforme apontado por Lee et al. ([LEE; KIM; KWON, 2017](#)) através do VLAT, nem todos conseguem interpretar visualizações gráficas complexas. Complementarmente, Hornung et al. ([HORNUNG; PEREIRA; BARANAUSKAS, 2015](#)) demonstram que usuários sem

formação estatística frequentemente não conseguem analisar dados de forma autônoma. Consequentemente, a mera disponibilização de dados não garante compreensão ou participação democrática.

Esta fase foi fundamentada em revisão de literatura e análise exploratória da API do Senado Federal, identificando-se a lacuna entre disponibilidade técnica de dados e acessibilidade cognitiva para cidadãos.

3.2.2 Fase 2: Definição dos Objetivos da Solução

Definiu-se que o artefato a ser construído deveria reduzir as barreiras cognitivas de acesso aos dados parlamentares. Para isso, estabeleceu-se que a solução deveria:

1. **Automatizar a extração de dados brutos:** Implementar pipeline de ETL para processar dados da API do Senado, convertendo formatos não estruturados (XML/JSON) em estruturas tabulares otimizadas para análise.
2. **Traduzir linguagem parlamentar:** Utilizar IA Generativa para categorizar e resumir discursos parlamentares complexos, tornando-os compreensíveis para cidadãos sem expertise na área.
3. **Permitir interação em linguagem natural:** Implementar interface conversacional que permita ao usuário formular perguntas em linguagem comum, dispensando conhecimento técnico de queries ou programação.
4. **Oferecer múltiplas modalidades de exploração:** Combinar Dashboard visual (para exploração livre) com Chatbot conversacional (para consultas diretas), atendendo diferentes estilos cognitivos de usuários.

3.3 Fase 3: Design e Desenvolvimento do Artefato

Nesta fase, correspondente à construção técnica da solução, a aplicação foi desenvolvida em Python sob uma arquitetura modular, visando garantir manutenibilidade e escalabilidade. A solução foi segmentada em três camadas principais:


3.3.1 Coleta e Processamento de Dados (Camada de Dados)

A coleta foi efetuada via API de Dados Abertos do Senado Federal ([Senado Federal do Brasil, s.d.](#)). O processo de ETL (*Extract, Transform, Load*) incluiu:

- **Requisição:** Uso da biblioteca *Requests* ([Python Software Foundation, 2024](#)) para extração de dados brutos (XML/JSON) dos *endpoints* mapeados via Swagger (Figura 8).

- **Estruturação:** Conversão e limpeza dos dados utilizando *Pandas* (Pandas Development Team, 2023), organizando discursos e votações em estruturas tabulares otimizadas para análise.

Figura 8 – Interface Swagger da API de Dados Abertos do Senado Federal



Fonte: Senado Federal.

3.3.2 Análise com IA Generativa (Camada de Inteligência)

O núcleo analítico utiliza o modelo Mistral 7B Instruct (Mistral AI, 2024), que roda em ambiente local. Diferente de abordagens que dependem de APIs proprietárias, esta etapa emprega engenharia de *prompts* para duas funções críticas:

- **Classificação Temática:** Categorização automática de discursos em temas (ex: "Saúde", "Educação", "Infraestrutura") utilizando *prompts* estruturados e exemplos de Few-Shot Learning.
- **Motor de Resposta (Recuperação Estruturada com Geração Aumentada):** O módulo recebe perguntas do usuário em linguagem natural, recupera da base em memória (cache de sessão) um subconjunto de registros relevantes e instrui o modelo Mistral 7B a gerar respostas contextualizadas e didáticas, compreensíveis para cidadãos não-especialistas, fundamentadas nesses registros e citando-os por identificador estável, de modo a preservar a rastreabilidade entre resposta e dados.


A justificativa detalhada para a escolha do Mistral 7B em ambiente local — replicabilidade, soberania de dados e sustentabilidade operacional —, bem como a comparação com modelos proprietários e com outros modelos abertos contemporâneos, encontra-se na fundamentação teórica (Seção 2.3.2). Aqui interessa registrar apenas que essa decisão de design condiciona o protocolo de avaliação descrito adiante, em especial a comparação da classificação temática com uma linha de base sem LLM.

3.3.3 Interface Interativa (Camada de Apresentação)

Para materializar o acesso democrático aos dados, desenvolveu-se uma interface *web* utilizando o *framework* *Streamlit* ([Streamlit Inc., 2024](#)), oferecendo dois modos de interação complementares:

- **Dashboard Visual:** Gráficos interativos gerados com *Plotly* ([Plotly Technologies Inc., 2024](#)) para exploração de tendências legislativas. O dashboard permite que usuários visualizem panoramicamente os dados, seguindo o princípio de Shneiderman ([SHNEIDERMAN, 1996](#)) de "zoom and filter"(Figura 9).
- **Agente Conversacional:** Interface de *chat* que abstrai a complexidade dos dados, permitindo consultas diretas em linguagem natural como "Como votou o Senador X sobre educação?" ou "Qual foi o tema mais debatido em 2025?"(Figura 9).

Figura 9 – Interface da Aplicação



Fonte: Produção da autora.

3.4 Fundamentos Teóricos para as Escolhas de Design

A combinação de Dashboard e Chatbot não é arbitrária, mas fundamentada em teorias de Interação Humano-Computador e Acessibilidade de Dados. Esta seção justifica essas escolhas.

3.4.1 Por que Dashboard?

Dashboards e visualizações de dados oferecem exploração livre e visão holística de um corpus de dados. Contudo, conforme Lee et al. ([LEE; KIM; KWON, 2017](#)) demonstram através do VLAT, nem todos os usuários possuem "visualization literacy"— a capacidade de compreender visualizações gráficas complexas.

Apesar dessa limitação, os *dashboards* oferecem benefícios concretos: permitem ao usuário obter uma visão panorâmica dos dados antes de descer ao detalhe — seguindo o princípio de Shneiderman ([SHNEIDERMAN, 1996](#)) —, explorar o corpus de forma autônoma e sem intermediário, identificar padrões visuais como tendências e anomalias e, ainda, filtrar e segmentar a informação interativamente. Por isso, o *dashboard* proposto adota decisões de design voltadas à acessibilidade: paleta de cores intuitiva, títulos e rótulos em linguagem comum em vez de jargão legislativo, preferência por representações simples — barras e linhas — em detrimento de *heatmaps* ou *scatter plots*, e interatividade básica baseada em filtros e em detalhamento sob demanda.

3.4.2 Por que Chatbot?

Interfaces conversacionais, especialmente aquelas alimentadas por Modelos de Linguagem Generativa, reduzem significativamente a barreira de entrada cognitiva. Um usuário sem expertise estatística pode formular perguntas em linguagem natural em vez de construir queries SQL ou manipular dados brutos.

Conforme a pesquisa em Interação Humano-Computador e Interação Humano-Dados ([HORNUNG; PEREIRA; BARANAUSKAS, 2015](#); [BRITO; FRANÇA; VIVACQUA, 2024](#)), as interfaces conversacionais reduzem a barreira de entrada — o usuário não precisa conhecer a estrutura dos dados nem uma linguagem de consulta —, apoiam-se em um formato de interação familiar, acomodam formulações distintas para uma mesma necessidade de informação e podem mediar a compreensão, traduzindo resultados técnicos em explicações acessíveis.

Essas vantagens convivem com limitações conhecidas dos *chatbots* baseados em LLMs, sobretudo o risco de alucinação (respostas factualmente incorretas) e a opacidade do processo de geração. Para mitigá-las, a implementação proposta utiliza o Mistral 7B Instruct ([JIANG et al., 2023](#)), cujo porte paramétrico reduz a incidência de alucinações em relação a modelos de menor escala; valida as respostas contra os dados reais; e — ponto central deste trabalho — garante rastreabilidade, pois o agente recupera um subconjunto de registros da base, cita-os na resposta por identificador estável e expõe, na interface, o painel de fontes utilizadas.

3.4.3 Complementaridade: Dashboard + Chatbot

A literatura em Interação Humano-Dados distingue dois padrões primários de uso em sistemas de informação pública: a exploração orientada à descoberta, em que o usuário navega pelo corpus sem uma pergunta pré-definida, e a consulta orientada a objetivos, em que há uma pergunta específica a ser respondida ([SHNEIDERMAN, 1996](#)). Esses padrões raramente são atendidos com igual eficácia por uma única modalidade de interface.

O *Dashboard* atende principalmente o primeiro padrão: permite ao usuário identificar tendências, comparar parlamentares e detectar anomalias por navegação visual, sem exigir que

ele formule uma pergunta antes de começar. O *Chatbot*, por sua vez, é mais adequado ao segundo padrão: reduz a carga cognitiva de quem sabe o que quer perguntar mas não sabe como navegar em dados estruturados. A integração de ambos em um único sistema não busca cobrir todos os perfis de usuário possíveis — uma afirmação que exigiria validação empírica — mas reconhece que restringir a interação a uma única modalidade excluiria sistematicamente parte dos potenciais usuários. Essa decisão de design será discutida nas considerações finais à luz dos resultados da avaliação.

3.5 Fase 4: Demonstração

Em DSR, a Demonstração distingue-se da Avaliação: enquanto esta confronta o artefato com critérios pré-definidos, aquela evidencia a viabilidade do artefato em uso, por meio de ao menos um cenário representativo documentado de ponta a ponta. Nesta fase, o AgentAI foi colocado em ambiente de homologação, processando dados reais da API do Senado Federal, e sua operação foi demonstrada em um fluxo completo: a partir de uma pergunta em linguagem natural (entrada), o sistema recupera os registros pertinentes da base (processamento), gera uma resposta fundamentada (saída) e exibe os registros que a embasam (fontes). Esse fluxo abrange o processamento automático de sessões legislativas reais, a classificação temática dos discursos, a resposta a consultas em linguagem natural e a visualização de tendências legislativas, confirmando a viabilidade técnica que habilita a fase de avaliação rigorosa. A verificação funcional preliminar correspondente é reportada no Capítulo 5.

3.6 Fase 5: Avaliação do Artefato

A fase de avaliação foi conduzida sem entrevistas, questionários, observação comportamental ou qualquer coleta de dados com participantes humanos. A avaliação incidiu sobre o artefato computacional, os dados públicos processados e as respostas geradas pelo modelo. Dessa forma, a pesquisa utiliza exclusivamente dados abertos, informações de domínio público e análises técnicas do sistema.

A avaliação foi organizada em quatro frentes complementares: qualidade da coleta e estruturação dos dados, classificação temática, qualidade factual das respostas e rastreabilidade das informações apresentadas pelo agente conversacional. O Quadro 1 explicita o alinhamento entre os objetivos específicos, as frentes de avaliação, as métricas e as cláusulas da hipótese, tornando rastreável a cadeia que liga a questão de pesquisa aos critérios de avaliação.

Quadro 1 – Matriz de rastreabilidade entre objetivos, frentes de avaliação, métricas e cláusulas da hipótese

Objetivo específico	Frente de avaliação	Métricas principais	Cláusula da hipótese
Processar e estruturar os dados da API do Senado	Coleta e estruturação	Compleitude, consistência, reprodutibilidade	Premissa (estruturar)
Classificar tematicamente os discursos	Classificação temática	Acurácia, precisão, revocação e F1 <i>vs. baseline</i> sem LLM	(a)
Responder em linguagem natural sobre os dados	Avaliação factual	% de respostas corretas/parciais/incorretas <i>vs.</i> configuração sem recuperação	(b)
Avaliar a rastreabilidade das respostas	Rastreabilidade	Cobertura de recuperação e de citação, precisão e suporte semântico da citação	(c)
Consolidar o uso do artefato	Cenários de uso	Síntese qualitativa dos casos de teste	Premissa (consultar)

Fonte: Produção da autora.

3.6.1 Avaliação da Coleta e Estruturação dos Dados

3.6.1.1 Pergunta

Em que medida o pipeline de coleta e processamento estrutura corretamente os dados parlamentares obtidos da API do Senado Federal?

3.6.1.2 Método

Será selecionado um conjunto de endpoints e períodos de coleta definidos no escopo do estudo. Os dados retornados pela API serão comparados com as estruturas armazenadas localmente pelo AgentAI, verificando se os campos essenciais foram preservados e se o processo de transformação não introduziu inconsistências.

3.6.1.3 Métricas

- **Compleitude:** proporção de registros coletados e armazenados com campos essenciais preenchidos.
- **Consistência:** ausência de duplicidades, datas inválidas, campos incompatíveis ou vínculos incorretos entre parlamentar, discurso, votação e matéria.
- **Reprodutibilidade:** capacidade de reexecutar o pipeline e obter uma base equivalente para o mesmo recorte temporal.

3.6.2 Avaliação da Classificação Temática

3.6.2.1 Pergunta

Em que medida o modelo Mistral 7B Instruct classifica corretamente os temas dos discursos parlamentares?

3.6.2.2 Método

As categorias temáticas serão definidas *a priori*, antes de qualquer anotação, a partir das áreas recorrentes na atividade legislativa, fixando-se um número mínimo de instâncias por categoria (ao menos 20) para assegurar a estabilidade das métricas por classe. Sobre essa base, será construída uma amostra de discursos reais do Senado Federal (mínimo de 150 registros, distribuídos entre as categorias) para compor o gabarito de referência. A anotação será realizada de forma independente por dois avaliadores, guiada por um protocolo documentado explicitamente antes do início — com a definição operacional de cada categoria e exemplos de casos limítrofes. O nível de concordância entre os avaliadores será medido pelo coeficiente Kappa de Cohen (COHEN, 1960), adotando-se, antes da anotação, o limiar de concordância substancial ($\kappa \geq 0,61$) da escala de Landis e Koch (LANDIS; KOCH, 1977) como critério mínimo aceitável; abaixo desse valor, o protocolo será revisado e a anotação refeita. Para reduzir o risco de viés compartilhado, os casos de discordância remanescentes serão resolvidos por um terceiro anotador independente, e não por discussão entre os dois anotadores iniciais; a concordância será reportada também por classe. A classificação gerada pelo modelo será então comparada com o gabarito final. O protocolo de dupla anotação independente com Kappa de Cohen e terceiro anotador aqui descrito permanece como o plano previsto para esta frente, cuja execução integra o cronograma (Quadro 2). Esta frente de classificação temática ainda não foi executada.

3.6.2.3 Métricas

- **Acurácia:** proporção de classificações coincidentes com o gabarito de referência.
- **Precisão:** proporção de discursos classificados em um tema que efetivamente pertencem a esse tema no gabarito.
- **Revocação:** proporção de discursos de um tema que foram corretamente identificados pelo modelo.
- **F1-Score:** média harmônica entre precisão e revocação.

3.6.2.4 Critério de Interpretação

Os resultados serão interpretados comparativamente em relação a um *baseline* de referência: uma classificação por correspondência de palavras-chave temáticas predefinidas (abordagem

clássica sem LLM). Essa comparação permite dimensionar o ganho — ou ausência de ganho — que o Mistral 7B Instruct oferece em relação a uma solução mais simples. A análise qualitativa complementará os números, identificando os tipos de discurso que geram maior ambiguidade e os casos em que o modelo produz classificações inconsistentes com o gabarito.

3.6.3 Avaliação Factual das Respostas do Agente Conversacional

3.6.3.1 Pergunta

As respostas geradas pelo agente conversacional são coerentes com os dados públicos recuperados da base local?

3.6.3.2 Método

Foi elaborado um conjunto de 40 perguntas representativas de consulta, definido *a priori* e estratificado pelas classes de pergunta sobre os discursos do corpus avaliado: factuais diretas, de agregação/contagem, de comparação, de busca por tema e perguntas sem resposta no corpus — estas últimas para testar o reconhecimento da ausência de dados. A avaliação recaiu sobre os discursos do *snapshot* congelado descrito no Capítulo 6; votações não integraram esta frente. Para cada pergunta, definiu-se *a priori* a evidência esperada (*gold*) a partir dos dados oficiais coletados da API do Senado Federal. Diferentemente do protocolo originalmente proposto — que previa a classificação das respostas em quatro categorias (correta, parcialmente correta, incorreta e não respondida) e uma ablação entre as configurações com e sem recuperação contextual —, a avaliação efetivamente conduzida comparou **quatro modelos geradores** sob um mesmo *pipeline* de recuperação fixo, mantendo constantes o corpus, os *prompts* e os hiperparâmetros, de modo a atribuir ao modelo qualquer diferença observada. Cada resposta foi avaliada por uma escala de **suporte semântico** (1–4), que afere se a evidência citada de fato sustenta a afirmação, complementada por completude (1–5), adequação ao português formal (1–5) e reconhecimento correto de ausência (recusa, 0/1). A anotação foi conduzida por **anotador único**, em condição cega quanto à identidade do modelo (ordem das respostas aleatorizada e modelo ocultado), com a evidência-fonte do corpus disponibilizada ao lado de cada resposta; por se tratar de avaliador único, não se calculou concordância interanotador (Kappa de Cohen), o que se declara como limitação entre as ameaças à validade interna. O protocolo de anotação foi fixado antes da execução. Constituem desvios assumidos em relação ao protocolo proposto: a substituição do esquema de quatro categorias pela escala de suporte semântico, a ausência da ablação com/sem recuperação — substituída pela comparação entre modelos — e a anotação por avaliador único em vez de dupla anotação com Kappa.

3.6.3.3 Métricas

- **Suporte semântico (1–4):** grau em que a evidência citada sustenta a afirmação — métrica primária de qualidade da resposta.
- **Compleitude (1–5):** grau em que a resposta contempla o que foi perguntado.
- **Adequação ao português formal (1–5).**
- **Recusa correta (0/1):** reconhecimento da ausência de dados nas perguntas sem resposta no corpus.
- Tipos de erro observados, como atribuição a parlamentar incorreto, omissão, generalização indevida ou citação que não sustenta a afirmação.

3.6.4 Avaliação de Rastreabilidade

3.6.4.1 Pergunta

As respostas do agente conversacional permitem identificar os dados utilizados para sua geração?

3.6.4.2 Método

O artefato já implementa rastreabilidade em dois níveis — na resposta ao usuário e na instrumentação de medição (Capítulo 5). A avaliação apoia-se nessa instrumentação: cada consulta é registrada em *log* estruturado (`qa_trace.jsonl`) contendo a pergunta, os identificadores das fontes recuperadas e a resposta gerada, e um módulo de avaliação processa esse registro para quantificar o vínculo entre resposta e dados. Sobre o mesmo conjunto de 40 perguntas da avaliação factual, a análise verificou se a resposta cita as fontes efetivamente recuperadas e se evita referenciar dados fora do contexto recuperado. Além da verificação do vínculo formal — a existência do identificador entre as fontes —, o protocolo incorpora a verificação de **suporte semântico** da citação, isto é, se o registro citado de fato sustenta a afirmação a que está associado, combinando uma checagem automática de sobreposição entre os termos da afirmação e o conteúdo da fonte com a anotação manual de uma amostra. A instrumentação, pronta e validada de ponta a ponta, foi aplicada sobre o conjunto de perguntas definido; os resultados são reportados no Capítulo 6.

3.6.4.3 Métricas

- **Cobertura de recuperação:** proporção de consultas para as quais o sistema recupera ao menos um registro da base como fonte da resposta.

- **Cobertura de citação:** proporção de respostas que citam explicitamente, por identificador, ao menos uma das fontes recuperadas.
- **Precisão de citação:** proporção de identificadores citados nas respostas que de fato correspondem a registros presentes no conjunto de fontes recuperado.
- **Suporte semântico da citação:** proporção de citações em que a fonte referenciada efetivamente sustenta a afirmação a que está associada, verificada automaticamente por sobreposição de termos e confirmada por anotação manual em uma amostra.

3.6.4.4 Limitações Assumidas

A noção *formal* de rastreabilidade — a mera existência do identificador citado entre as fontes — é insuficiente, pois uma resposta poderia citar um registro que não sustenta a afirmação. Por isso, conforme descrito no método, esta avaliação não se limita ao vínculo formal: incorpora a verificação de suporte semântico da citação, o que torna a cláusula (c) da hipótese efetivamente testável. Permanecem como limitações assumidas: (i) perguntas de natureza agregada (por exemplo, “quantos senadores discursaram sobre saúde?”) podem ser respondidas corretamente sem citar uma fonte específica, razão pela qual a cobertura de citação é reportada de forma segmentada por tipo de pergunta; e (ii) a verificação automática de suporte semântico, baseada em sobreposição lexical, é aproximada, sendo por isso complementada pela anotação manual de uma amostra.

3.6.5 Avaliação de Cenários de Uso

A avaliação final consolidará os resultados das etapas anteriores em cenários de uso definidos pela pesquisadora. Esses cenários não envolvem participantes externos; funcionam como casos de teste do artefato. Exemplos incluem: consultar o posicionamento de um parlamentar em uma votação, identificar temas recorrentes em discursos de um período e solicitar uma síntese de votações relacionadas a uma área temática.

3.7 Fase 6: Reflexão e Aprendizados

A fase final documenta o conhecimento científico gerado através da pesquisa. Não se trata apenas de documentar que o artefato funciona tecnicamente, mas de analisar sistematicamente:

- O que aprendemos sobre design de interfaces para acessibilidade de dados?
- Que padrões emergiram dos cenários de avaliação técnica?
- Quais são as limitações da abordagem com IA Generativa?
- Que contribuições esta pesquisa oferece para a comunidade científica?

3.8 Ameaças à Validade

A avaliação proposta está sujeita a ameaças à validade que, seguindo a categorização clássica adotada na pesquisa empírica em Engenharia de Software (RUNESON; ENGSTRÖM; STOREY, 2020), organizam-se em quatro dimensões. Explicitá-las é condição para interpretar corretamente os resultados.

3.8.1 Validade de Construto

Refere-se a se as métricas medem aquilo que afirmam medir. A principal ameaça está na rastreabilidade: uma métrica puramente formal — a existência do identificador citado — não captura se a fonte sustenta a afirmação. Essa ameaça é mitigada pela métrica de suporte semântico e pela anotação manual de uma amostra. Ademais, a cobertura de recuperação tende a 100% por construção, pois o mecanismo sempre retorna algum registro; por isso ela é interpretada como verificação de funcionamento, e não como evidência de qualidade.

3.8.2 Validade Interna

Diz respeito a fatores que podem distorcer a relação entre o artefato e os resultados observados. O principal risco é o viés de anotação — critérios subjetivos na construção dos gabaritos e eventual não-independência entre anotadores. Na avaliação de geração efetivamente conduzida, a anotação foi realizada por **anotador único**, em condição cega quanto à identidade do modelo (ordem aleatorizada e modelo ocultado), com critérios de pontuação definidos *a priori* e a evidência-fonte do corpus disponibilizada ao lado de cada resposta. Por se tratar de avaliador único, **não foi calculada a concordância interanotador (Kappa de Cohen)**, o que constitui limitação assumida: as médias por modelo refletem o julgamento de um único avaliador e podem conter viés sistemático não detectável por concordância; uma mitigação parcial possível seria um teste-reteste intra-anotador sobre uma subamostra. Para a frente de classificação temática, ainda não executada, permanece previsto o protocolo de dupla anotação independente com limiar de Kappa pré-fixado e terceiro anotador para desempate.

3.8.3 Validade Externa

Refere-se à generalização dos resultados. Embora o artefato processe o recorte de 2024 a 2026, a avaliação empírica recaiu sobre um *snapshot* congelado de 152 discursos do Senado Federal, coletados entre 5 e 16 de maio de 2025, de modo que os achados podem não se transferir para o recorte completo, para outros períodos, outras casas legislativas ou idiomas; do mesmo modo, ainda que a comparação abranja quatro modelos, conclusões sobre desempenho não se estendem automaticamente a outros modelos ou configurações. Essas fronteiras são declaradas, e a arquitetura modular do artefato é apontada como caminho para replicação em outros contextos.

3.8.4 Validade de Conclusão

Relaciona-se à solidez das inferências. Como a avaliação se baseia em um conjunto finito de cenários definidos pela pesquisadora, sem participantes humanos, evita-se afirmar significância estatística: os resultados são reportados de forma descritiva e caracterizadora, com o número de cenários e de instâncias por classe declarados e comparados a *baselines*. Limitações de tamanho de amostra são tratadas como restrição assumida, e não como achado conclusivo.

3.9 Cronograma de Execução

O planejamento para o período que se estende até a defesa, prevista para janeiro de 2027, foca na execução das Fases 5 e 6 (Avaliação e Reflexão) e na produção textual. O Quadro 2 detalha as atividades previstas até a defesa final.

Quadro 2 – Cronograma de Execução e Finalização da Dissertação

Atividades (Fase Final)	Trim. 1 2026	Trim. 2 2026	Trim. 3 2026	Trim. 4 2026
Ajustes pós-Qualificação (Metodologia DSR)	X			
Preparação do Gabarito Ouro (Classificação Manual)	X	X		
Execução do Experimento de Acurácia (IA)	X	X		
Avaliação factual das respostas geradas		X	X	
Avaliação de rastreabilidade e cenários de consulta		X	X	
Análise Estatística e Qualitativa dos Resultados		X	X	
Artigo Científico: PROPOR 2026 (retorno negativo, fev/2026); ERBASE 2026 (submetido)	X	X		
Escrita Final da Dissertação (Resultados + Conclusão)			X	X
Revisão e Depósito				X
Defesa da Dissertação				X

Fonte: Produção da autora.

As atividades estão distribuídas da seguinte forma:

- **1º Trimestre 2026:** Refinamento do texto da proposta conforme feedback da banca, implementação de melhorias metodológicas, preparação do dataset de controle (Gabarito Ouro) para experimento de acurácia.
- **2º Trimestre 2026:** Execução dos testes técnicos para validação de acurácia, avaliação factual das respostas, verificação de rastreabilidade e execução de cenários representativos de consulta. Registra-se que um artigo científico foi submetido ao PROPOR 2026, tendo recebido retorno negativo em fevereiro de 2026; o trabalho foi revisado e submetido ao ERBASE 2026.

- **3º Trimestre 2026:** Consolidação estatística e qualitativa dos dados obtidos na avaliação, redação dos capítulos finais da dissertação (Análise de Resultados e Conclusão), finalização e submissão do artigo científico.
- **4º Trimestre 2026:** Revisão final do texto completo da dissertação, submissão para a banca examinadora, defesa pública.

4

Estado da Arte

Este capítulo mapeia sistematicamente as pesquisas existentes na interseção entre Inteligência Artificial e dados parlamentares, com o objetivo de identificar o que já foi feito, onde estão as lacunas, e como este trabalho se posiciona em relação à literatura.


Optou-se pelo Mapeamento Sistemático da Literatura (MSL) em vez de uma revisão narrativa porque o escopo do tema é amplo e interdisciplinar — abrangendo PLN, dados abertos, transparência governamental e interação humano-dados —, o que exige um protocolo estruturado para evitar seleção tendenciosa de fontes ([KITCHENHAM, 2004](#)). A diferença entre MSL e revisão sistemática é relevante aqui: enquanto a revisão sistemática busca sintetizar evidências sobre uma intervenção específica, o mapeamento tem por objetivo caracterizar o espaço de pesquisa, identificar tendências e delimitar lacunas, o que é mais adequado para áreas emergentes como a aplicação de IA Generativa em contextos legislativos ([KITCHENHAM, 2004](#)).

O protocolo seguiu as diretrizes de Kitchenham ([KITCHENHAM, 2004](#)), estruturado em três fases: Planejamento, Execução e Análise.

4.1 Protocolo do Mapeamento Sistemático

O processo adotado seguiu as três fases críticas recomendadas pela literatura: Planejamento, Execução e Análise. Tal abordagem estruturada assegura o rigor na seleção dos estudos. A Figura 10 ilustra o fluxo de trabalho.

Figura 10 – Fases do Mapeamento Sistemático da Literatura



Fonte: Adaptado de Kitchenham (2004).

Para a organização e condução do mapeamento, utilizou-se a ferramenta *Parsifal*¹, que oferece suporte computacional para a aplicação dos critérios de seleção e extração de dados.

4.1.1 Planejamento

Nesta etapa, definiu-se a necessidade do mapeamento e o protocolo de pesquisa (BRETON et al., 2007). O objetivo central foi responder às questões de pesquisa detalhadas no Quadro 3, que orientaram a estratégia de busca.

¹ <<https://parsif.al/>>

Quadro 3 – Questões de Pesquisa do Mapeamento Sistemático

ID da Questão	Questões de Pesquisa
Q1:	Quais técnicas de Inteligência Artificial ou PLN são mais utilizadas na literatura para a análise de dados parlamentares abertos?
Q2:	Existem trabalhos que aplicam IA Generativa (LLMs) ou interfaces conversacionais (<i>chatbots</i>) para facilitar o acesso do cidadão a dados legislativos?
Q3:	Quais são as principais lacunas e desafios apontados pela literatura na democratização do acesso à informação parlamentar?
Q4:	Como a literatura trata interação humano-dados e acessibilidade de informação legislativa?

Fonte: Produção da autora.

Para responder a essas questões, foram definidos os campos de extração apresentados no Quadro 4.

Quadro 4 – Campos de Extração de Dados

Campo de Extração
Ano de Publicação
Técnica/Método de IA/PLN Utilizado
Uso de IA Generativa ou <i>Chatbot</i> ?
Contexto Legislativo (Nacional vs. Internacional)
Enfoque em Acessibilidade ou Interação Humano-Dados
Desafios/Lacunas Identificados

Fonte: Produção da autora.

Fontes de Busca:

Para esta pesquisa, a busca foi conduzida em cinco bases de dados de alto impacto internacional e nacional:

- **IEEE Xplore:** Base multidisciplinar de Engenharia e Computação
- **Scopus:** Indexador de citações com cobertura de múltiplas disciplinas
- **ACM Digital Library:** Publicações especializadas em Ciência da Computação
- **Web of Science (WoS):** Base multidisciplinar de alto fator de impacto, incluída para ampliar a cobertura de publicações internacionais em Ciências da Computação e Sistemas de Informação

- **SOL - Biblioteca Digital da SBC:** Repositório da Sociedade Brasileira de Computação (<https://sol.sbc.org.br/>) para capturar produção científica nacional relevante

O escopo temporal compreendeu o período de 2014 a 2026, refletindo a evolução das políticas de dados abertos no Brasil e a emergência recente de aplicações baseadas em IA Generativa.

Data da busca: Maio de 2026.

As palavras-chave e *strings* de busca utilizadas estão detalhadas nos Quadros 5 e 6.

Quadro 5 – Palavras-Chave da Busca

Palavras-Chave (PT)	Termos em Inglês
Dados Parlamentares	Parliamentary Data, Legislative Data, Plenary Sessions
IA Generativa	Generative Artificial Intelligence, LLM, Large Language Models
Análise de Discursos	Information Extraction, Text Analysis, Speech Mining
Dados Abertos	Open Government Data, Open Data
Interface Conversacional	Chatbot, Conversational AI, Dialog Systems
Acessibilidade de Dados	Data Accessibility, Data Literacy
Transparência Legislativa	Legislative Transparency, Open Parliament

Fonte: Produção da autora.

Quadro 6 – Strings de Busca (Conceituais)

String de Busca
(“Parliamentary Data”OR “Legislative Data”) AND (“Generative AI”OR “Large Language Models”OR “LLM”OR “Chatbot”) (“Open Government Data”) AND (“Natural Language Processing”OR “NLP”OR “Text Mining”) AND (“Parliament”OR “Legislature”) (“Legislative Transparency”) AND (“Artificial Intelligence”OR “Machine Learning”) (“Data Accessibility”) AND (“Chatbot”OR “Conversational AI”)

Fonte: Produção da autora.

O Quadro 7 apresenta os critérios estabelecidos para filtrar os trabalhos.

Quadro 7 – Critérios de Inclusão e Exclusão

Critérios de Inclusão	Critérios de Exclusão
CI1: Aborda IA/PLN/LLM para dados governamentais ou parlamentares.	CE1: Estudos duplicados em múltiplas bases.
CI2: Discute transparência ou participação política em contexto legislativo.	CE2: Literatura cinzenta ou não revisada por pares.
CI3: Aborda dados abertos em contexto público/legislativo.	CE3: Estudos secundários (revisões de revisões).
CI4: Investiga interação humano-dados ou acessibilidade.	CE4: Artigos que abordam exclusivamente aspectos legais/políticos sem componente técnico.


Fonte: Produção da autora.

4.1.2 Execução e Resultados

A execução seguiu o protocolo estabelecido, compreendendo identificação, seleção, elegibilidade e inclusão. A busca inicial nas cinco bases retornou 47 estudos: IEEE Xplore (0), Scopus (6), ACM Digital Library (39), Web of Science (2) e SOL/SBC (0). A ausência de retorno na SOL/SBC e no IEEE para as *strings* aplicadas foi registrada como resultado negativo esperado — dado o recorte temporal e temático definido — e não implica ausência de produção nacional na área. Após remoção de 2 duplicatas e aplicação dos critérios de inclusão/exclusão (triagem por título e resumo, seguida de leitura de texto completo), selecionaram-se 7 trabalhos primários como mais relevantes para contextualizar esta dissertação.

O fluxo de seleção é detalhado na Figura 11.

Figura 11 – Fluxograma de seleção dos estudos (PRISMA-ScR)



Fonte: Produção da autora.

4.2 Análise Temática dos Resultados

Diferentemente de uma mera listagem de resumos, a análise temática busca identificar padrões, convergências e divergências entre os trabalhos, conectando-os explicitamente aos objetivos desta pesquisa e às lacunas identificadas.

4.2.1 Tema 1: IA Generativa para Estruturação de Dados Legislativos

Os trabalhos de Colombo et al. (2025), Colombo (2024) e Von Lucke e Frank (2025) convergem em um ponto fundamental: **modelos de linguagem generativa conseguem, quando bem orientados, transformar dados legislativos complexos em estruturas de conhecimento compreensíveis.**

Especificidades de cada trabalho:

- [Colombo, Bernasconi e Ceri \(2025\)](#) propõem um *pipeline* assistido por LLM para construção automática de *knowledge graphs* da legislação italiana. O trabalho demonstra que IA pode extrair entidades jurídicas (leis, artigos, interpretações) de textos legislativos não estruturados e organizá-las em grafos semânticos. Limitação: foca em estruturação técnica, não em acessibilidade para cidadãos.
- [Colombo \(2024\)](#) aprofunda a discussão anterior, explorando explicitamente a sinergia entre grafos de conhecimento e LLMs para *monitoring* de sistemas legislativos — rastreamento de como leis evoluem. Contribuição: metodologia de versionamento de legislação.
- [Lucke e Frank \(2025\)](#) analisam a aplicação prática de ferramentas como ChatGPT em parlamentos, levantando questões críticas sobre potencialidades (rapidez, síntese) e riscos (alucinação, imprecisão factual). Este trabalho é particularmente relevante pois trata de LLMs em contexto parlamentar e aponta desafios de confiabilidade.

Padrão Emergente: LLMs conseguem estruturar legislação, mas confiabilidade das respostas é crítica. A literatura aponta a necessidade de validação humana.

Conexão com Este Trabalho: Esta pesquisa avança ao (1) avaliar tecnicamente a confiabilidade das respostas geradas, (2) combinar estruturação de dados com interfaces visual e conversacional, (3) focar em dados parlamentares brasileiros.

4.2.2 Tema 2: Interfaces Conversacionais para Acessibilidade

[Kim et al. \(2025\)](#) descrevem o “LegisFlow”, uma interface conversacional com “consciência temporal” para pesquisa jurídica na Coreia. Este trabalho é diretamente alinhado aos objetivos desta dissertação.

Especificidades:

- Implementa chatbot para consultas em linguagem natural sobre legislação
- Incorpora noção de tempo (como leis mudaram ao longo do tempo)
- Avalia usabilidade com usuários reais
- Contexto: público coreano sem expertise jurídica

Padrão Emergente: Interfaces conversacionais reduzem barreira de entrada para acesso legislativo. Dimensão temporal é importante.

Conexão e Diferenciação: Este trabalho dialoga com o LegisFlow, mas dele se distingue deliberadamente. A interface conversacional, em si, não é a contribuição reivindicada — ela já é demonstrada por Kim et al., inclusive com avaliação junto a usuários reais. O diferencial desta dissertação assenta-se em três eixos: (i) o contexto brasileiro e a língua portuguesa, ausentes naquele trabalho; (ii) a combinação de *dashboard* visual e agente conversacional em um mesmo artefato, atendendo a padrões de uso distintos; e (iii) o foco explícito na rastreabilidade técnica das respostas, com instrumentação e métricas próprias, em vez da usabilidade percebida. Reconhece-se, em contrapartida, que este trabalho não avalia o impacto junto a usuários reais — dimensão em que o LegisFlow avança e que aqui se delimita como trabalho futuro.

4.2.3 Tema 3: Análise de Dados Legislativos com PLN Clássico

Mendes, Ali e Charalabidis (2025) utilizam *Topic Modeling* (técnica clássica de PLN, não IA Generativa) para analisar Pedidos de Acesso à Informação brasileiros. BOJĀRS et al. (2019) apresentam “LinkedSaeima”, um dataset de dados abertos conectados (*Linked Data*) do parlamento da Letônia.

Padrão Emergente: Abordagens clássicas de PLN conseguem extrair insights, mas requerem expertise técnica. IA Generativa oferece potencial para democratizar acesso.

Conexão com Este Trabalho: Enquanto esses trabalhos usam técnicas sofisticadas (Topic Modeling, RDF/Linked Data), o foco desta pesquisa é em acessibilidade para cidadãos não-especialistas. Essa é a lacuna que esta dissertação endereça.

4.2.4 Tema 4: Desafios e Lacunas na Literatura

Papadopoulos e Charalabidis (2020) aplicam PLN para extrair *insights* de documentos de estratégias nacionais de IA, focando em mineração de textos governamentais. O trabalho, embora não focado em legislação, aponta desafios gerais na análise de textos públicos.

Lacunas Identificadas Pela Literatura:

1. **Falta de foco em acessibilidade para cidadãos:** A maioria dos trabalhos trata estruturação técnica ou análise especializada, não democratização de acesso.

2. **Confiabilidade de LLMs não é plenamente abordada:** Von Lucke e Frank apontam riscos, mas nenhum trabalho apresenta estratégia sistemática de validação.
3. **Contexto brasileiro pouco explorado:** Dos 7 trabalhos, apenas Mendes et al. e Bojārs et al. abordam contexto nacional (coreano, letão, brasileiro). Falta pesquisa em português sobre legislação brasileira com IA Generativa.
4. **Avaliação de respostas e rastreabilidade ainda é pouco explorada:** A literatura aponta riscos de alucinação e imprecisão factual em LLMs, mas ainda há espaço para protocolos de avaliação voltados à coerência entre respostas geradas e dados legislativos de origem.
5. **Combinação Dashboard + Chatbot não é explorada:** Trabalhos tratam uma ou outra modalidade, raramente ambas integradas.

4.3 Lacunas Identificadas e Contribuições Desta Pesquisa

Com base na análise sistemática, identificam-se as seguintes lacunas que esta pesquisa propõe-se a preencher:

1. **Lacuna 1: Falta de foco em acessibilidade para cidadãos não-especialistas**
 - **O que a literatura oferece:** Técnicas sofisticadas de IA para estruturação de legislação
 - **O que está faltando:** Investigação de como essas técnicas podem ser comunicadas de forma compreensível ao cidadão médio
 - **Como esta pesquisa aborda:** Design deliberado de interfaces acessíveis (Dashboard + Chatbot) e avaliação técnica de sua capacidade de organizar e consultar dados parlamentares
2. **Lacuna 2: Confiabilidade e validação de respostas IA não é sistemática**
 - **O que a literatura oferece:** Identificação de riscos (alucinação, imprecisão)
 - **O que está faltando:** Metodologia sistemática de validação antes de deploy em contexto cívico
 - **Como esta pesquisa aborda:** Avaliação técnica rigorosa por meio de comparação com gabarito de referência, análise factual das respostas e verificação de rastreabilidade
3. **Lacuna 3: Contexto e idioma brasileiros pouco explorados**
 - **O que a literatura oferece:** Exemplos internacionais (Itália, Coreia, Letônia)
 - **O que está faltando:** Pesquisa em português sobre Senado Federal brasileiro

- **Como esta pesquisa aborda:** Dados reais da API do Senado Federal, legislação e dados parlamentares em língua portuguesa, contexto brasileiro até então ausente na literatura

4. Lacuna 4: Avaliação factual e rastreável de respostas em linguagem natural

- **O que a literatura oferece:** Discussões sobre potencial de LLMs e riscos de imprecisão
- **O que está faltando:** Protocolos explícitos para verificar se respostas geradas estão ancoradas em dados legislativos oficiais
- **Como esta pesquisa aborda:** Avaliação das respostas do AgentAI por cenários de consulta, comparação com dados oficiais e análise de rastreabilidade

5. Lacuna 5: Integração de múltiplas modalidades de interação

- **O que a literatura oferece:** Dashboards OU Chatbots, raramente ambos
- **O que está faltando:** Investigação de como diferentes modalidades se complementam para diferentes usuários
- **Como esta pesquisa aborda:** Design deliberado de Dashboard + Chatbot com avaliação de como ambos contribuem ao acesso democrático

4.4 Conclusões do Mapeamento Sistemático

O mapeamento revela um campo em formação: trabalhos sobre IA Generativa aplicada a legislação são recentes (predominantemente pós-2022), concentrados em contextos europeus e asiáticos, e orientados predominantemente à estruturação técnica — não à acessibilidade para cidadãos comuns. A ausência de trabalhos em português sobre dados parlamentares brasileiros com LLMs, combinada à falta de protocolos sistemáticos para avaliação de rastreabilidade e qualidade factual de respostas geradas, configura o espaço em que esta dissertação se insere.

É importante registrar uma limitação do próprio mapeamento: o corpus de 7 estudos primários selecionados é pequeno para afirmações categóricas sobre o estado da área, e a forte concentração de retornos em uma única base (ACM Digital Library) pode enviesar as lacunas identificadas, que devem, portanto, ser lidas como indícios e não como conclusões definitivas. Essa limitação pode refletir tanto a emergência da temática quanto restrições das *strings* de busca utilizadas. Para mitigá-la, está prevista, antes da defesa, a ampliação da busca por *snowballing* — para frente e para trás — a partir dos estudos incluídos, além de busca complementar manual (incluindo a biblioteca digital da SBC e o Google Scholar) e da documentação, em apêndice, das *strings* exatas aplicadas em cada base, com os respectivos números de retorno e filtros — requisitos para a plena reprodutibilidade do mapeamento, conforme as diretrizes de Kitchenham ([KITCHENHAM, 2004](#)).

5

Desenvolvimento e Resultados Preliminares

Neste capítulo, detalha-se o estágio atual do projeto e o planejamento para a conclusão da dissertação. Como esta proposta é apresentada em um estágio avançado do mestrado, a fase de construção do artefato (aplicação *web*, *backend* e integração com IA) já se encontra concluída (Fase de Design e Desenvolvimento), permitindo que os esforços futuros se concentrem na validação científica (Fase de Avaliação) e na escrita final.

5.1 Estágio Atual do Desenvolvimento

Sob a ótica da *Design Science Research*, o artefato computacional proposto já atingiu um nível de maturidade funcional que permite a execução de testes. As seguintes etapas do ciclo de pesquisa foram concluídas:

- **Identificação do Problema e Motivação:** Mapeamento das dificuldades de acesso aos dados brutos do Senado Federal e definição da relevância para o controle social e participação democrática.
- **Definição da Solução:** Projeto de uma arquitetura baseada em Dashboard (visualização) + Chatbot (interação conversacional) para reduzir barreiras cognitivas ao acesso legislativo.
- **Design e Desenvolvimento:** Implementação completa dos módulos de coleta (ETL via API Senado), análise (Mistral 7B Instruct em ambiente local) e interface (*Streamlit* com *Plotly*), resultando em um protótipo funcional capaz de processar dados reais.
- **Demonstração:** Validação técnica preliminar mostrando que o artefato consegue processar dados parlamentares e gerar respostas coerentes.

A aplicação encontra-se implantada em ambiente de homologação, processando dados da API do Senado Federal e respondendo a consultas em linguagem natural. Esse estágio habilita

a fase de avaliação técnica do artefato, com foco em qualidade dos dados processados, acurácia da classificação temática, qualidade factual das respostas e rastreabilidade das informações geradas.

5.2 Arquitetura e Componentes do Artefato

5.2.1 Camada de Dados: Coleta e Processamento

A coleta de dados é efetuada via API de Dados Abertos do Senado Federal ([Senado Federal do Brasil, s.d.](#)). O processo de ETL (*Extract, Transform, Load*) é automatizado e inclui:

- **Extração:** Utilização da biblioteca *Requests* ([Python Software Foundation, 2024](#)) para requisição de dados brutos (XML/JSON) dos *endpoints* da API Swagger, mapeando informações sobre sessões legislativas, discursos, votações e senadores.
- **Transformação:** Conversão e limpeza dos dados utilizando *Pandas* ([Pandas Development Team, 2023](#)), normalizando formatos, removendo duplicatas, preenchendo valores ausentes e estruturando informações em tabelas relacionais otimizadas para análise.
- **Carregamento:** Os dados transformados são mantidos em memória durante a execução e persistidos em um *cache* em arquivo (`outputs/materias_cache.json`), que funciona como *snapshot* local: requisições repetidas à API são evitadas quando o mesmo período legislativo já foi coletado, e esse *snapshot* pode ser versionado para assegurar a reprodutibilidade da avaliação sobre um corpus congelado.

A atualização do corpus ocorre sob demanda, mediante reexecução do *pipeline* para o período desejado; neste estágio de prototipação não há um agendamento automático em produção. Para fins de avaliação científica, adota-se deliberadamente um *snapshot* congelado e versionado dos dados, de modo que os experimentos sejam reproduzíveis sobre exatamente o mesmo conjunto — condição necessária para que o gabarito de referência permaneça estável entre execuções.

5.2.2 Camada de Inteligência: Análise com Mistral 7B

O núcleo analítico utiliza o modelo Mistral 7B Instruct ([Mistral AI, 2024](#)), executado em ambiente local. A justificativa dessa escolha — privacidade e soberania de dados, replicabilidade, custo e adequação de desempenho —, bem como a comparação com modelos proprietários e com outros modelos abertos, foi apresentada na fundamentação teórica (Seção 2.3.2) e não é aqui repetida.

Do ponto de vista de implementação, o modelo é servido localmente por um *runtime* de inferência que expõe uma API compatível com o padrão OpenAI em `localhost` (na configuração

de referência, o LM Studio em <http://localhost:1234/v1>). O artefato comunica-se com o modelo exclusivamente por essa interface local: nenhum dado legislativo é transmitido a servidores externos, de modo que a soberania de dados é preservada mesmo havendo uma camada de *serving* compatível com OpenAI. Essa padronização da interface é também o que torna o componente de linguagem modular e substituível por outro modelo sem alteração dos demais estágios.

O modelo é utilizado para duas funções críticas:

- **Classificação Temática:** Engenharia de *prompts* estruturados instrui o modelo a categorizar discursos legislativos em temas predefinidos (Saúde, Educação, Infraestrutura, Segurança, etc.). A classificação permite organização e análise dos debates por assunto.
- **Motor de Resposta (Recuperação Estruturada com Geração Aumentada):** O módulo recebe perguntas do usuário em linguagem natural via Chatbot, recupera da base em memória um subconjunto de registros relevantes à pergunta (busca estruturada por palavras-chave sobre os dados mantidos em cache de sessão) e instrui o Mistral 7B a gerar respostas contextualizadas e didáticas, fundamentadas nesses registros e citando-os por identificador estável (por exemplo, [D1] para discursos e [V1] para votações).

5.2.3 Camada de Apresentação: Interfaces Acessíveis

Para materializar o acesso democrático aos dados, desenvolveu-se uma interface *web* utilizando o *framework* *Streamlit* ([Streamlit Inc., 2024](#)), oferecendo dois modos de interação complementares:

5.2.3.1 Dashboard Visual

Gráficos interativos gerados com *Plotly* ([Plotly Technologies Inc., 2024](#)) permitem exploração visual de tendências legislativas. O design segue o mantra de Shneiderman ([SHNEIDERMAN, 1996](#)): "primeiro o panorama geral, depois zoom e filtros, e então detalhes sob demanda".

Exemplos de visualizações disponíveis:

- Tendências de votação ao longo do tempo (linha temporal)
- Distribuição de votos por tema (gráfico de barras)
- Padrões de voto de senadores específicos (matriz ou radar)
- Comparação entre posições de diferentes grupos parlamentares (gráficos comparativos)

O Dashboard permite que usuários explorem livremente, filtrem por tema, senador ou período, e identifiquem padrões visuais em dados legislativos.

O uso do Streamlit é uma escolha compatível com o estágio de prototipação científica do artefato, pois permite rápida construção de interfaces interativas para análise de dados. Entretanto, reconhece-se que o framework possui limitações para uso em produção em larga escala, especialmente em autenticação, controle fino de permissões, escalabilidade e separação entre camadas de serviço. Assim, neste trabalho, o Streamlit é tratado como tecnologia de prototipação e demonstração do artefato, não como decisão definitiva para implantação institucional.

5.2.3.2 Chatbot Conversacional

Interface de *chat* que abstrai a complexidade dos dados legislativos, permitindo consultas em linguagem natural:

Exemplos de perguntas que o usuário pode fazer:

- "Como votou o Senador [Nome] sobre educação?"
- "Qual foi o resultado da votação em [Projeto de Lei]?"
- "Quais são os temas mais debatidos em 2025?"
- "Como o partido [X] votou no projeto sobre saúde?"
- "Qual senador votou diferente de seu partido nesta votação?"

O Chatbot traduz perguntas em linguagem comum para operações sobre a base de dados em memória, recupera as informações relevantes e retorna respostas em linguagem natural acessível a cidadãos sem expertise legislativa ou tecnológica. A Figura 12 ilustra a interface conversacional em operação com dados reais do Senado Federal.

Figura 12 – Interface do Agente Conversacional (Chatbot) do AgentAI



Fonte: Produção da autora.

5.2.4 Rastreabilidade das Respostas

Para que o agente conversacional não opere como uma "caixa-preta", o artefato foi instrumentado de modo a tornar explícita a ligação entre cada resposta e os dados que a fundamentaram. Esse mecanismo, já implementado no protótipo, opera em dois níveis complementares:

- **No artefato (rastreabilidade para o usuário):** a etapa de *retrieval* seleciona, para cada pergunta, um subconjunto de registros da base e atribui a eles identificadores curtos e estáveis ([D1], [D2], ... para discursos; [V1], [V2], ... para votações). O *prompt* instrui o modelo a fundamentar a resposta exclusivamente nesses registros e a citá-los por identificador, sendo vedado referenciar identificadores fora da lista recuperada. A interface exibe, junto a cada resposta, um painel "Fontes utilizadas" com a tabela dos registros efetivamente recuperados, preservando também o código oficial do Senado de cada item. O mecanismo aplica-se tanto ao *chat* de discursos quanto ao de votações.
- **Para avaliação (instrumentação de medição):** cada consulta gera um registro estruturado em *log* (arquivo `qa_trace.jsonl`) contendo a pergunta, os identificadores das fontes recuperadas, os códigos oficiais correspondentes e a resposta gerada. Sobre esse *log*, um módulo de avaliação calcula indicadores de rastreabilidade, também acessíveis por um painel dedicado na própria interface. Esse encadeamento — recuperação, citação, registro e medição — funciona de ponta a ponta; a medição sobre o conjunto de cenários definido, incluindo a verificação de suporte semântico das citações, integra a fase de avaliação ainda em execução, detalhada no Capítulo 3.

5.3 Fluxo de Funcionamento do Sistema

O sistema opera conforme descrito abaixo:

1. **Inicialização:** Aplicação *Streamlit* carrega dados pré-processados da API do Senado Federal, mantendo-os em memória com cache de sessão.
2. **Interação Usuário - Dashboard:** Usuário pode explorar Dashboard sem necessidade de entrada, aplicando filtros interativos para ver visualizações customizadas.
3. **Interação Usuário - Chatbot:** Usuário digita pergunta em linguagem natural.
4. **Processamento:**
 - Sistema faz *retrieval* de dados relevantes (busca estruturada por palavras-chave sobre a base local)
 - Constrói contexto com os dados recuperados

- Instrui Mistral 7B com *prompt* que inclui: pergunta do usuário, contexto de dados e instruções para responder de forma didática
5. **Resposta:** Mistral 7B gera resposta em linguagem natural, citando por identificador ([D1], [V1], etc.) quais registros recuperados foram utilizados.
 6. **Exibição:** A resposta é exibida no Chatbot, acompanhada do painel "Fontes utilizadas" que lista os registros recuperados. O usuário pode fazer pergunta de acompanhamento.

5.4 Dados Legislativos Utilizados

O artefato processa dados da API de Dados Abertos do Senado Federal, incluindo:

- **Senadores:** Nomes, partidos, estados, contatos
- **Sessões Plenárias:** Datas, tipo (ordinária, extraordinária, etc.)
- **Discursos:** Texto completo, senador autor, data, tema (quando disponível)
- **Votações:** Descrição da matéria votada, resultado, votos individuais de cada senador

Os dados cobrem o período de 2024 a 2026 e permitem a investigação de padrões legislativos contemporâneos. Esse recorte temporal poderá ser ampliado na etapa final da pesquisa, conforme a disponibilidade da API e os limites de processamento do ambiente local.

5.5 Status de Conclusão das Fases DSR

Conforme a metodologia Design Science Research (Cap. 3), o projeto encontra-se no seguinte estágio:

Quadro 8 – Progresso das Fases de Design Science Research

Fase DSR	Status	Descrição
1. Identificação do Problema	Concluída	Problema definido, fundamentado em literatura
2. Objetivos da Solução	Concluída	Objetivos do artefato claramente especificados
3. Design e Desenvolvimento	Concluída	Artefato implementado e funcional
4. Demonstração	Concluída	Artefato operacional em ambiente de homologação
5. Avaliação	Parcialmente concluída	Avaliação de geração e rastreabilidade executada (4 modelos, $n = 40$); classificação temática planejada (Trim. 2-3)
6. Reflexão e Aprendizados	Planejada	A executar após fase de avaliação (Trim. 3-4)

Fonte: Produção da autora.

5.6 Cronograma de Execução da Dissertação

O planejamento temporal das fases finais — com foco na Avaliação rigorosa (Fase 5) e na produção textual até a defesa, prevista para janeiro de 2027 — é apresentado de forma consolidada no Capítulo 3 (Quadro 2), evitando-se aqui a duplicação do cronograma. Esta seção registra apenas o encadeamento das próximas atividades imediatas, detalhado a seguir.

5.7 Próximas Ações Imediatas (Próximas 8 Semanas)

1. Implementar melhorias apontadas pelo parecer de qualificação
2. Finalizar dataset de controle para experimento de acurácia
3. Preparar o conjunto de cenários representativos de consulta
4. Executar primeira rodada de teste técnico (IA vs. Gabarito)
5. Documentar detalhes finais do protocolo de avaliação técnica

6

Resultados da Avaliação

Este capítulo reporta os resultados da avaliação de geração do AgentAI, executada conforme o protocolo da Fase 5 detalhado no Capítulo 3 (Metodologia). A avaliação cobre as cláusulas (b) — coerência factual das respostas — e (c) — rastreabilidade — da hipótese de pesquisa. A cláusula (a), relativa à classificação temática comparada a uma linha de base por palavras-chave, ainda não foi avaliada: essa frente permanece planejada e sua execução integra o cronograma (Quadro 2), constituindo limitação assumida desta versão dos resultados e não um achado a omitir.

Adianta-se o argumento central, que não é a eleição de um modelo vencedor: as métricas automáticas *saturam* nos quatro modelos avaliados — integridade referencial 1,00 e taxa de alucinação 0,00 em todos —, de modo que o **suporte semântico**, obtido por anotação humana, é o único eixo capaz de discriminar a qualidade das respostas. O caso da pergunta Q04 (Seção 6.4) demonstra concretamente que uma resposta com métrica automática perfeita pode ter suporte semântico baixo. Como esse fenômeno se sustenta nos quatro modelos, o resultado é melhor lido como evidência da *robustez do protocolo de avaliação* do que como ranqueamento de geradores.

6.1 Configuração Experimental

6.1.1 Corpus de Avaliação

A avaliação recaiu sobre um *snapshot* congelado de 152 discursos do Senado Federal, coletados entre 5 e 16 de maio de 2025 (nove datas distintas). Cada registro contém o resumo do discurso e o tema atribuído (categoria fechada), sem o texto integral. Sobre esse corpus, definiu-se *a priori* um conjunto de 40 perguntas estratificadas em cinco classes: 14 factuais diretas, 8 de agregação/contagem, 6 de comparação, 4 de busca por tema e 8 sem resposta no corpus. Estas últimas testam a robustez do gerador — isto é, se ele reconhece a ausência de informação em vez de fabricá-la. O congelamento do corpus, da recuperação e dos hiperparâmetros assegura

que qualquer diferença observada seja atribuível ao modelo gerador.

Cabe registrar que o motor de resposta emprega **recuperação estruturada com geração aumentada** por correspondência de palavra-chave, e não recuperação vetorial densa. As referências apresentadas nas respostas na forma [D1], [D2] etc. são identificadores locais e posicionais por consulta — isto é, apontam para a k -ésima fonte recuperada naquela pergunta —, e não os identificadores de discurso originais do corpus; a conferência de suporte das citações foi feita contra a evidência *gold* da pergunta.

6.1.2 Modelos, Hardware e Quantização

Foram avaliados quatro modelos de linguagem abertos, todos executados localmente no *runtime* LM Studio: Mistral 7B Instruct v0.3 (JIANG et al., 2023), Qwen2.5 7B Instruct, Llama 3.1 8B Instruct e Gemma 2 9B Instruct. Mantém-se o Mistral 7B como o modelo do artefato por razões de replicabilidade, soberania de dados e sustentabilidade operacional já justificadas na fundamentação (Seção 2.3.2); os demais entram aqui como termos de comparação sob condição idêntica.

Todos os quatro modelos foram executados na mesma quantização **Q4_K_M** (paridade confirmada pelos arquivos .gguf) e no mesmo equipamento: CPU AMD Ryzen 7 5700X (8 núcleos), 32 GB de RAM e GPU NVIDIA RTX 4060 Ti de 8 GB, sob Windows de 64 bits. A identidade de *hardware* e de quantização entre as coletas é a condição que torna as métricas de latência e *throughput* comparáveis entre os modelos; registre-se, contudo, que o consumo efetivo de VRAM e o regime de *offload* de cada execução não foram instrumentados.

Um quinto modelo, o Sabiá-7B, foi **excluído** da comparação por incompatibilidade de janela de contexto: ele aceita no máximo 2048 *tokens*, ao passo que os *prompts* da tarefa (trechos recuperados, pergunta e instruções) ultrapassam 4000 *tokens*. Incluí-lo exigiria truncar pela metade o contexto recuperado, violando o princípio de manter tudo fixo exceto o modelo e confundindo o efeito do gerador com o do *handicap* de contexto. A janela de contexto é, portanto, um critério de elegibilidade anterior à avaliação de qualidade.

6.1.3 Condição de Geração

As gerações foram realizadas com temperatura 0,1. Quanto à *seed*, embora o *script* de coleta envie o valor 42 no *payload*, o LM Studio manteve o *toggle* de *seed* aleatória ativo nas quatro coletas, de modo que esse valor foi sobrescrito e a *seed* **não foi efetivamente controlada** no *runtime* de inferência. Não se afirma, portanto, determinismo por *seed* fixa nem reprodutibilidade *byte*-idêntica — que o *runtime* local não garante mesmo com *seed* fixa, por não-determinismo de GPU. O que se assegura é a **uniformidade da condição**: os quatro modelos foram executados sob a mesma configuração (temperatura 0,1 e *seed* não controlada), o que preserva a validade da comparação. Por essa razão, métricas sensíveis à variação entre

execuções — sobretudo a recusa em perguntas sem resposta — são reportadas em agregado sobre o conjunto de perguntas, nunca a partir de uma única pergunta.

6.2 Resultados Quantitativos Agregados

O Quadro 9 consolida as métricas por modelo ($n = 40$ perguntas por modelo, 160 anotações ao todo). As médias de suporte semântico, completude, português formal e a contagem de recusa correta provêm da anotação humana cega; integridade referencial, taxa de alucinação e *throughput* provêm da instrumentação automática.

Quadro 9 – Avaliação comparativa dos quatro modelos geradores ($n = 40$ por modelo; quantização Q4_K_M)

Modelo	Suporte sem. (1–4)	Recusa (/8)	PT formal (1–5)	Completude (1–5)	Tokens/s (mediana)	Integ. ref.	Alucinação
Mistral 7B Instruct v0.3	2,62	6/8	4,72	4,20	29,6	1,00	0,00
Qwen2.5 7B Instruct	2,90	5/8	4,85	4,12	23,1	1,00	0,00
Llama 3.1 8B Instruct	2,73	7/8	4,90	4,00	29,6	1,00	0,00
Gemma 2 9B Instruct	3,17	6/8	4,95	3,95	4,15	1,00	0,00

Fonte: Produção da autora.

6.3 Saturação das Métricas Automáticas e o Suporte Semântico como Eixo Discriminante

A integridade referencial e a taxa de alucinação atingiram o teto nos quatro modelos: todas as citações apontavam para fontes efetivamente recuperadas (integridade 1,00) e nenhuma referenciava registro fora da janela recuperada (alucinação 0,00). Esse resultado **valida o *pipeline*** de recuperação e citação, mas, por saturar, não discrimina a qualidade das respostas: as duas métricas automáticas não distinguem os modelos entre si. A adequação ao português formal comporta-se de modo análogo, concentrada na faixa 4,72–4,95, alta e pouco discriminante.

A discriminação recai, assim, sobre o suporte semântico anotado, no qual os modelos se ordenam como Gemma 2 (3,17), Qwen2.5 (2,90), Llama 3.1 (2,73) e Mistral (2,62). É preciso enfatizar que essas **diferenças são modestas**: todas se situam na faixa entre “correta no núcleo, com lacunas” e “integralmente sustentada”. Como a anotação foi conduzida por avaliador único e sem cálculo de concordância interanotador (Kappa de Cohen), **não se afirma significância estatística nem dominância** de qualquer modelo; os valores caracterizam tendências, não um veredito. O ponto metodológico que se sustenta com robustez é outro: a distinção entre uma integridade referencial que satura e um suporte semântico que varia revela que a primeira mede a integridade da *referência* (o identificador existe na janela?), enquanto o segundo mede a integridade do *conteúdo* (a fonte sustenta o que foi dito?).

6.4 O Caso Q04: Métrica Automática Perfeita com Suporte Semântico Baixo

A pergunta Q04 — “Qual senador discursou sobre o aniversário de 35 anos da Conab?” — ilustra de forma concreta a insuficiência das métricas automáticas. Na resposta do Mistral, todas as referências citadas estavam dentro da janela recuperada, resultando em integridade referencial 1,00 e alucinação 0,00. A resposta, porém, continha erro semântico relevante: associava contagens fabricadas (“duas sessões”; outro parlamentar com “três discursos sobre a Conab”) e grafava incorretamente o nome do parlamentar. Na anotação cega, recebeu **suporte semântico 2** — erro relevante — apesar da pontuação automática perfeita.

O contraste na mesma pergunta torna o argumento robusto entre modelos: o Qwen2.5 identificou corretamente o parlamentar e obteve **suporte 4**, enquanto Llama 3.1 e Gemma 2 ficaram em suporte 3 (corretos no núcleo, mas com imprecisões ou resposta genérica). Ou seja, sob métricas automáticas idênticas (1,00 / 0,00 para os quatro), o suporte semântico separou uma resposta incorreta de uma correta. O caso demonstra empiricamente por que a anotação humana é indispensável e por que a avaliação de qualidade não pode se apoiar apenas na integridade referencial.

6.5 Recusa Correta nas Perguntas sem Resposta no Corpus

Nas 8 perguntas sem resposta no corpus, a recusa correta — o reconhecimento explícito da ausência de dados — foi de 7/8 para o Llama 3.1, 6/8 para Mistral e Gemma 2 e 5/8 para o Qwen2.5. Esses valores só emergem da leitura humana: o proxy automático de recusa (heurística “ausência de citação = recusa”) subestima sistematicamente a robustez, pois os modelos costumam reconhecer a ausência em prosa (“não foi registrado nos discursos analisados”) e, ainda assim, citar uma fonte de contexto, o que faz o proxy contabilizar indevidamente uma não-recusa. No caso do Mistral, por exemplo, o proxy automático marcou apenas 1/8, contra os 6/8 confirmados pela anotação humana. Reporta-se, portanto, a recusa automática como um piso, e a robustez real como aquela aferida por leitura humana.

6.6 Discussão

6.6.1 Robustez do Achado entre Modelos

O fato de os quatro modelos saturarem as métricas automáticas e de o fenômeno do caso Q04 se reproduzir independentemente do gerador confere robustez ao achado central: a avaliação de respostas ancoradas em dados não pode se apoiar em métricas de integridade de referência, que tendem a saturar, sendo necessária a verificação de suporte semântico do

conteúdo. Esse resultado é uma propriedade do protocolo de avaliação, sustentada em quatro arquiteturas distintas, e não uma característica de um modelo isolado.

6.6.2 Custo de Inferência e o *Trade-off* Qualidade–Custo

A leitura conjunta de qualidade e custo de inferência revela uma tensão. O Gemma 2, que lidera o suporte semântico, foi também o mais lento na geração por ampla margem: 4,15 *tokens/s* observados, contra 23–30 *tokens/s* dos modelos 7–8B, sob o mesmo *hardware* e a mesma quantização Q4_K_M. Reporta-se essa diferença de forma descritiva: como o consumo de VRAM e o regime de *offload* não foram instrumentados, não se isola aqui a causa do custo mais alto — que pode refletir o maior porte do modelo, características de sua arquitetura ou o comportamento do *runtime* local. A escolha de modelo configura-se, ainda assim, como um *trade-off* entre qualidade e custo, e não como dominância simples: o ganho modesto de suporte semântico do Gemma vem acompanhado de um custo de geração várias vezes maior. As implicações dessa tensão para a eventual seleção de outro gerador — viabilizada pela arquitetura modular do artefato — são discutidas entre os trabalhos futuros, no capítulo de considerações, permanecendo o Mistral 7B como o modelo do artefato por replicabilidade.

6.6.3 Limitações

Reconhecem-se as seguintes limitações desta avaliação. Primeiro, a anotação foi conduzida por **anotador único**, em condição cega quanto ao modelo, sem cálculo de concordância interanotador (Kappa de Cohen); as médias refletem o julgamento de um único avaliador e podem conter viés sistemático não detectável por concordância. Segundo, as **diferenças de suporte semântico são modestas** (2,62–3,17), o que, somado ao anotador único, desaconselha qualquer afirmação de significância ou de dominância. Terceiro, a *seed* não foi controlada no *runtime*, de modo que as métricas sensíveis à variação são reportadas em agregado. Quarto, a avaliação recai sobre um recorte de 152 discursos de maio de 2025, sem texto integral, e seus achados não se estendem automaticamente ao recorte completo do sistema (2024–2026) nem a outros períodos, casas legislativas ou idiomas. Por fim, a cláusula (a) da hipótese — classificação temática *versus* linha de base — não foi avaliada nesta etapa, permanecendo como trabalho planejado.

7

Considerações Parciais e Trabalhos Futuros

Este capítulo apresenta uma avaliação honesta do estágio atual da pesquisa: o que foi concluído, o que permanece em aberto, quais desafios emergiram durante o desenvolvimento e o que se espera produzir na fase final. O objetivo não é apenas reportar progresso, mas identificar onde os riscos metodológicos ainda precisam ser mitigados antes da defesa.

7.1 Progresso do Ciclo de Design Science Research

Conforme a metodologia DSR adotada, o ciclo de pesquisa estrutura-se em seis fases. À data desta proposta (maio de 2026), quatro fases encontram-se concluídas ou em conclusão avançada:

1. **Fase 1 - Identificação do Problema: Concluída.** Mapeamento das dificuldades de acesso aos dados parlamentares e definição da relevância para transparência e participação cívica foram estabelecidas.
2. **Fase 2 - Objetivos da Solução: Concluída.** Especificação clara dos objetivos que o artefato deve atingir (redução de barreiras cognitivas, interface acessível, múltiplas modalidades) foi documentada.
3. **Fase 3 - Design e Desenvolvimento: Concluída.** O artefato AgentAI encontra-se tecnicamente funcional, integrando coleta de dados (API Senado), processamento com IA Generativa (Mistral 7B local), e interfaces acessíveis (Dashboard + Chatbot).
4. **Fase 4 - Demonstração: Concluída.** A aplicação encontra-se em ambiente de homologação, processando dados reais da API do Senado Federal e respondendo a consultas em linguagem natural.

5. **Fase 5 - Avaliação: Em Execução.** Conforme cronograma (Capítulo 3, Quadro 2), iniciaram-se preparações para testes técnicos, avaliação factual das respostas e verificação de rastreabilidade.
6. **Fase 6 - Reflexão e Aprendizados: Planejada para Q3/Q4 2026.** Documentação do conhecimento científico gerado será realizada após conclusão dos testes.

7.2 Resultados Preliminares do Artefato

Do ponto de vista técnico e funcional, o artefato demonstrou viabilidade nas seguintes dimensões:

7.2.1 Viabilidade Técnica

A solução computacional materializa-se como uma aplicação *web* funcional que integra:

- **Coleta de Dados:** Pipeline de ETL automatizado que processa dados da API do Senado Federal com sucesso, utilizando Python e *Pandas* para estruturação.
- **Processamento com IA:** Modelo Mistral 7B Instruct, rodando localmente, consegue executar classificação temática de discursos legislativos e gerar respostas em linguagem natural alinhadas aos dados reais.
- **Interfaces:** Aplicação Streamlit com Dashboard interativo (*Plotly*) e Chatbot conversacional funcionam de forma estável em ambiente de homologação.
- **Performance:** O sistema processa um corpus legislativo realista (sessões do Senado de 2024-2026) em ambiente local, com latência preliminarmente adequada ao estágio de prototipação.

7.2.2 Verificação Funcional Preliminar

Antes da fase de avaliação formal, o artefato passou por uma verificação funcional conduzida pela pesquisadora e pelo orientador, com foco exclusivo em identificar falhas de execução — não em medir desempenho. Nessa etapa, confirmou-se que: o pipeline de ETL processa e armazena dados da API sem perda de campos essenciais; o modelo Mistral 7B Instruct gera classificações temáticas para os discursos ingeridos; e a interface Streamlit responde a consultas sem erros de execução em ambiente local.

É importante distinguir essa verificação funcional da avaliação científica planejada para as próximas etapas. Saber que o sistema funciona não é o mesmo que saber se ele funciona bem o suficiente para o propósito declarado. A avaliação sistemática — com gabarito de referência

anotado por dois avaliadores, métricas quantitativas e comparação com baseline — é o que determinará se a hipótese formulada se sustenta ou não.

7.3 Desafios e Limitações Identificadas

A execução das fases anteriores revelou desafios que constituem ameaças à validade da pesquisa e que serão tratados ou documentados nas próximas etapas:

7.3.1 Desafios Técnicos

- **Ambiguidade Semântica em Jargões Legislativos:** O modelo Mistral 7B, apesar de competente em tarefas genéricas, demonstrou limitações na interpretação de termos específicos do domínio legislativo (ex: "desarquivamento", "tramitação em urgência", "voto por delegação"). Em alguns casos, isso resultou em classificações genéricas ou imprecisas.

Plano de Mitigação: Engenharia de *prompt* avançada com Few-Shot Learning (fornecer exemplos ao modelo de cada jargão) e possível fine-tuning limitado do modelo.

- **Alucinações e Opacidade dos LLMs:** A natureza "caixa preta" (*black box*) de modelos de linguagem impõe um desafio para confiabilidade das respostas. Observou-se ocasionalmente que o Chatbot gera informações que parecem plausíveis mas não estão fundamentadas nos dados reais.

Plano de Mitigação: Implementação de mecanismo de rastreabilidade: toda resposta do Chatbot cita quais dados (senador, data, votação) foram utilizados, permitindo verificação humana.

- **Limitações de Infraestrutura:** Restrições de memória e processamento em ambiente local impactam volume de dados que podem ser processados simultaneamente. Em alguns casos, há lentidão quando processando sessões legislativas muito longas.

Plano de Mitigação: Otimização de código, caching de resultados, e possível upgrade de hardware.

7.3.2 Desafios Metodológicos

- **Construção de Gabaritos de Referência:** Avaliar classificação temática e respostas em linguagem natural exige a construção de conjuntos de referência consistentes. Há risco de subjetividade na definição das categorias e respostas esperadas.

Plano de Mitigação: Documentação explícita dos critérios de anotação, revisão pelo orientador e registro dos casos ambíguos encontrados durante a avaliação.

- **Validade dos Cenários de Consulta:** Os cenários usados para avaliar o agente conversacional precisam representar perguntas relevantes sobre dados parlamentares, sem depender de participantes externos.

Plano de Mitigação: Definição de cenários com base nas funcionalidades reais do artefato, nos dados disponíveis na API do Senado e nas lacunas identificadas no mapeamento sistemático.

7.4 Contribuições Esperadas da Pesquisa

Conforme apontado pelo Mapeamento Sistemático da Literatura (Capítulo 4), esta pesquisa posiciona-se para fazer contribuições em áreas onde há lacunas identificadas:

7.4.1 Contribuições Científicas

1. **Conhecimento sobre Design de Interfaces para Acessibilidade de Dados Legislativos:** Investigação fundamentada de como a combinação de múltiplas modalidades (Dashboard visual + Chatbot conversacional) pode favorecer as pré-condições técnicas de acesso à informação legislativa, reconhecendo-se que a verificação do efeito junto a cidadãos reais constitui trabalho futuro.
2. **Compreensão de Efetividade Técnica de IA Generativa em Contextos Cívicos:** Avaliação rigorosa de como IA Generativa local pode apoiar classificação temática, consulta em linguagem natural e geração de respostas rastreáveis sobre dados parlamentares.
3. **Metodologia para Validação de Confiabilidade de LLMs em Contextos Críticos:** Documentação de estratégia de validação de respostas IA contra dados reais, aplicável a outros domínios além legislação.
4. **Conhecimento Localizado (Brasil/Português):** Investigação situada no contexto brasileiro, em língua portuguesa, contribuindo para uma lacuna ainda pouco explorada na literatura sobre IA Generativa e dados parlamentares.

7.4.2 Contribuições Práticas

1. **Artefato Funcional:** Protótipo funcional que pode subsidiar futuras aplicações por pesquisadores, organizações civis e instituições interessadas em transparência legislativa.
2. **Código Aberto:** Publicação do código-fonte no GitHub permite que outros pesquisadores repliquem, modifiquem e estendam a solução.
3. **Guidelines de Design:** Recomendações práticas para design de interfaces cívicas que combinam IA com acessibilidade.

7.5 Trabalhos Futuros: Fases de Avaliação e Conclusão

As fases restantes do ciclo DSR — Avaliação e Reflexão — constituem o núcleo científico da dissertação. É nelas que a hipótese será testada e o conhecimento gerado. O cronograma detalhado das atividades está descrito no Capítulo 3, Quadro 2; registra-se aqui apenas a priorização das atividades críticas:

A construção do protocolo de anotação e do gabarito de referência precede qualquer execução de experimento — sem um gabarito metodologicamente sólido, as métricas de acurácia e F1 carecem de validade. Em seguida, a execução dos testes de classificação com baseline comparativo permitirá dimensionar o real ganho do uso do LLM. Por fim, a avaliação de rastreabilidade e os cenários de consulta fecharão o ciclo de evidências sobre a hipótese central.

7.6 Perspectivas de Conclusão

A fase que determina o valor científico desta dissertação ainda está por ser executada: a avaliação rigorosa do artefato. O desenvolvimento do AgentAI demonstrou viabilidade técnica, mas viabilidade não é o mesmo que efetividade — e é exatamente a distinção entre essas duas condições que a fase de avaliação precisa endereçar.

Cabe reiterar o alcance do que se promete. O título e a motivação evocam a *democratização do acesso*, mas o que esta dissertação efetivamente projeta e avalia são as **pré-condições técnicas** dessa democratização — a qualidade factual, a rastreabilidade das respostas e a disponibilização de interfaces de baixa barreira de entrada. A demonstração do efeito democratizante junto a cidadãos reais, que exigiria um estudo com participantes, é reconhecida como trabalho futuro e não é reivindicada como resultado deste trabalho.

O principal risco no horizonte imediato é a construção do gabarito de referência: se os critérios de anotação não forem documentados com precisão antes do início da classificação, a avaliação perde credibilidade metodológica. Por isso, a primeira atividade do próximo trimestre é a elaboração do protocolo de anotação — incluindo definição operacional das categorias temáticas, exemplos de casos limítrofes e regras de desempate — antes que qualquer discurso seja anotado.

Se as fases de Avaliação e Reflexão forem executadas com o rigor descrito neste documento, o trabalho poderá contribuir com dois resultados concretos para a comunidade: um protocolo replicável para avaliação de sistemas RAG sobre dados parlamentares em português, e um conjunto de dados anotados sobre discursos do Senado Federal que pode ser disponibilizado para pesquisas futuras. Esses resultados têm valor independente do desempenho absoluto do modelo — porque documentam tanto o que funciona quanto o que não funciona, e ambos são contribuições científicas legítimas.

Próximas Ações Imediatas:

1. Refinamento final do documento de proposta conforme feedback da banca examinadora
2. Preparação do dataset de controle (Gabarito Ouro) para experimento de acurácia
3. Preparação de cenários representativos de consulta
4. Implementação de melhorias metodológicas apontadas por este parecer
5. Execução da primeira rodada de avaliação técnica (próximas 8 semanas)

Referências

Arquivo Nacional. *Dados Abertos*. 2023. Acesso em: maio de 2026. Disponível em: <https://www.gov.br/arquivonacional/>. Citado na página 15.

BOBBIO, N. *O Futuro da Democracia*. São Paulo: Companhia das Letras, 1986. Citado na página 10.

BOJĀRS, U. et al. Linkedsaime: A linked open dataset of latvia's parliamentary debates. In: *Proceedings of the 15th SEMANTiCS Conference*. [S.l.]: Springer, 2019. v. 11702, p. 50–56. Citado na página 46.

BRERETON, P. et al. Lessons from applying the systematic literature review process within the software engineering domain. *Journal of Systems and Software*, v. 80, n. 4, p. 571–583, 2007. Citado na página 40.

BRITO, L.; FRANÇA, J.; VIVACQUA, A. Literacia de dados para todos: Desafios da educação em computação na era da interação humano-dados. In: *I Seminário dos Grandes Desafios da Educação em Computação no Brasil*. São Paulo: [s.n.], 2024. Citado 2 vezes nas páginas 22 e 29.

COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960. Citado na página 32.

COLOMBO, A. *Knowledge Graphs and Large Language Models for Legislative Monitoring*. 2024. Preprint. Citado na página 45.

COLOMBO, A.; BERNASCONI, A.; CERI, S. An llm-assisted etl pipeline to build a high-quality knowledge graph of the italian legislation. *Information Processing & Management*, v. 62, n. 4, p. 104082, 2025. Citado na página 45.

HORNUNG, H. R.; PEREIRA, R.; BARANAUSKAS, M. C. C. Challenges for human-data interaction – a semiotic perspective. In: *Human-Computer Interaction: Part I, HCII 2015*. Cham: Springer, 2015. (Lecture Notes in Computer Science, v. 9169), p. 37–48. Citado 4 vezes nas páginas 12, 22, 25 e 29.

ISOTANI, S.; BITTENCOURT, I. I. *Dados Abertos Conectados*. São Paulo: Novatec, 2015. Citado na página 16.

JIANG, A. Q. et al. Mistral 7b. *arXiv preprint arXiv:2310.06825*, 2023. Disponível em: <https://arxiv.org/abs/2310.06825>. Disponível em: <https://arxiv.org/abs/2310.06825>. Citado 3 vezes nas páginas 20, 29 e 57.

JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.: s.n.], 2023. Draft. Citado na página 17.

KIM, J. et al. Legisflow: Enhancing korean legal research with temporal-aware llm interfaces. In: *Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology*. [S.l.: s.n.], 2025. p. 1–29. Citado na página 45.

KITCHENHAM, B. *Procedures for Performing Systematic Reviews*. [S.l.], 2004. Citado 2 vezes nas páginas 39 e 48.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977. Citado na página 32.

LEE, S.; KIM, S. H.; KWON, B. C. Vlat: Development of a visualization literacy assessment test. *IEEE Transactions on Visualization and Computer Graphics*, v. 23, n. 1, p. 551–560, 2017. Citado 4 vezes nas páginas 12, 22, 25 e 28.

LEVITSKY, S.; ZIBLATT, D. *Como as Democracias Morrem*. Rio de Janeiro: Zahar, 2018. Citado na página 10.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2020. v. 33, p. 9459–9474. Citado na página 19.

LUCKE, J. von; FRANK, A. Approaching the integration of large language models in the parliamentary workspace. *Frontiers in Political Science*, v. 7, p. 1625394, 2025. Citado na página 45.

MARQUES, R. M.; LAIPELT, R. d. C. F. Inteligência artificial generativa e desafios informacionais. *Ciência da Informação em Revista*, v. 10, 2023. Citado na página 18.

MENDES, M.; ALI, M.; CHARALABIDIS, Y. Analyzing the freedom of information requests using topic modeling: Towards user-driven open government data ecosystems. In: *Proceedings of the International Conference on Theory and Practice of Electronic Governance*. [S.l.: s.n.], 2025. Citado na página 46.

Mistral AI. *Mistral 7B Instruct: A High-Quality Open-Source Language Model*. 2024. Acesso em: maio de 2026. Disponível em: <<https://mistral.ai/>>. Citado 4 vezes nas páginas 12, 18, 27 e 50.

OLIVEIRA, G.; CKAGNAZAROFF, I. Transparência no poder legislativo brasileiro: Um desafio para a democracia. *Revista de Administração Pública*, v. 56, n. 2, p. 145–165, 2022. Citado 3 vezes nas páginas 10, 12 e 25.

Open Knowledge Brasil. *Guia de Dados Abertos*. 2024. Acesso em: maio de 2026. Disponível em: <<https://www.ok.org.br/>>. Citado 2 vezes nas páginas 10 e 15.

Pandas Development Team. *Pandas: Python Data Analysis Library*. 2023. Acesso em: maio de 2026. Disponível em: <<https://pandas.pydata.org/>>. Citado 2 vezes nas páginas 27 e 50.

PAPADOPOULOS, T.; CHARALABIDIS, Y. What do governments plan in the field of artificial intelligence? analysing national ai strategies using nlp. In: *Proceedings of the 13th International Conference on Theory and Practice of Electronic Governance*. [S.l.: s.n.], 2020. Citado na página 46.

PEFFERS, K. et al. A design science research methodology for information systems research. *Journal of Management Information Systems*, v. 24, n. 3, p. 45–77, 2007. Citado 3 vezes nas páginas 20, 21 e 24.

PIMENTEL, M.; FILIPPO, D.; SANTOS, T. M. Design science research: pesquisa científica atrelada ao design de artefatos. *RE@D - Revista de Educação a Distância e Elearning*, v. 3, n. 1, p. 1–20, 2020. Citado 2 vezes nas páginas 20 e 24.

Plotly Technologies Inc. *Plotly: The Open-Source Graphing Library for Python*. 2024. Acesso em: maio de 2026. Disponível em: <<https://plotly.com/python/>>. Citado 2 vezes nas páginas 28 e 51.

Python Software Foundation. *Requests: HTTP Library for Python*. 2024. Acesso em: maio de 2026. Disponível em: <<https://requests.readthedocs.io/>>. Citado 2 vezes nas páginas 26 e 50.

Red Hat. *What are Large Language Models?* 2023. Acesso em: maio de 2026. Disponível em: <<https://www.redhat.com/>>. Citado na página 18.

RUNESON, P.; ENGSTRÖM, E.; STOREY, M.-A. The design science paradigm as a frame for empirical software engineering. In: FELDERER, M.; TRAVASSOS, G. H. (Ed.). *Contemporary Empirical Methods in Software Engineering*. Cham: Springer International Publishing, 2020. p. 127–147. Citado 3 vezes nas páginas 20, 24 e 36.

SAYÃO, L. F.; SALES, L. F. Dados abertos de pesquisa: ampliando o conceito de acesso livre. *Revista Eletrônica de Comunicação, Informação e Inovação em Saúde*, v. 8, n. 2, 2014. Citado na página 15.

Senado Federal do Brasil. *Portal de Dados Abertos do Senado Federal*. s.d. Acesso em: maio de 2026. Disponível em: <<https://www.senado.gov.br/transparencia/dados-abertos>>. Citado 2 vezes nas páginas 26 e 50.

SHNEIDERMAN, B. The eyes have it: A task by data type taxonomy for information visualizations. *Proceedings of IEEE Symposium on Visual Languages*, p. 336–343, 1996. Citado 3 vezes nas páginas 28, 29 e 51.

Streamlit Inc. *Streamlit: The Fastest Way to Build Data Apps*. 2024. Acesso em: maio de 2026. Disponível em: <<https://streamlit.io/>>. Citado 2 vezes nas páginas 28 e 51.

TAMPER, M.; TUOMINEN, J.; HYVÖNEN, E. Knowledge graphs and parliamentsampo: Linked open data services for parliamentary data. *Semantic Web*, v. 13, n. 6, p. 1003–1021, 2022. Citado na página 18.

THUAN, N. H.; DRECHSLER, A.; ANTUNES, P. Construction of design science research questions. *Communications of the Association for Information Systems*, v. 44, n. 1, p. 84–106, 2019. Citado na página 21.

VETRÒ, A. et al. Open data quality measurement framework: Definition and application to open government data. *Government Information Quarterly*, v. 33, n. 2, p. 325–337, 2016. Citado na página 15.

ZUIDERWIJK, A.; JANSSEN, M. Open data policies, their implementation and impact: A framework for comparison. *Government Information Quarterly*, v. 31, n. 1, p. 17–29, 2014. Citado na página 15.